

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN, ĐHQG-HCM
KHOA CÔNG NGHỆ THÔNG TIN



Nhập môn học máy

BÁO CÁO ĐỒ ÁN 3

CÁC BƯỚC TIỀN MỞI TRONG GEOMETRIC MACHINE LEARNING

Giảng viên hướng dẫn: ThS. Lê Nhựt Nam

Sinh viên:	23120195	Lê Hà Thanh Chương
	23120197	Trà Văn Sỹ
	23120199	Huỳnh Đức Thịnh
	23120257	Bùi Trung Hiếu
	23120330	Lê Công Phúc

TP. HỒ CHÍ MINH, THÁNG 6 NĂM 2026



Mục lục

Danh sách các hình	iii
Danh sách các bảng	v
Danh sách các ký hiệu và chữ viết tắt	vi
Danh mục các thuật ngữ	viii
Lời mở đầu	1
1 Giới thiệu	2
1.1 Bối cảnh và động lực thực hiện	2
1.1.1 Vấn đề phân mảnh kiến trúc và lời nguyên đa chiều	2
1.1.2 Tính đối xứng tham số và học không gian trọng số	3
1.1.3 Ý nghĩa và tầm quan trọng thực tiễn	3
1.2 Kỷ nguyên của dữ liệu hình học	4
1.3 Sự dịch chuyển sang không gian trọng số	5
1.4 Mục tiêu và phạm vi của đề án	6
1.4.1 Mục tiêu nghiên cứu	6
1.4.2 Phạm vi và cấu trúc báo cáo	7
2 Kiến thức nền tảng	8
2.1 Khái niệm cơ bản về Đối xứng (Symmetry)	8
2.2 Tính Bất biến (Invariance) và Đồng biến (Equivariance)	8
2.3 Cơ sở Lý thuyết Nhóm (Group, Group Actions, Orbit)	8
2.4 Tác động Nhóm và Quỹ đạo (Group Action Orbits)	8
3 Các phương pháp xây dựng mô hình bảo toàn tính đối xứng	9
3.1 Hướng 1: Can thiệp dữ liệu trên các mô hình có sẵn	9
3.1.1 Tăng cường dữ liệu	9
3.1.2 Chuẩn hóa	12
3.1.3 Lấy trung bình Nhóm và Khung (Group/Frame Averaging)	14
3.2 Hướng 2: Xây dựng kiến trúc tương biến từ đầu	15



3.2.1	Lớp tuyến tính tương biến và cơ chế chia sẻ tham số	15
3.2.2	Tích chập nhóm	17
3.2.3	Lý thuyết bất biến và tham số hóa qua đại lượng bất biến	18
3.2.4	Phương pháp tensor và giới hạn của bổ đề Schur	19
3.2.5	Ứng dụng: mạng đồ thị tương biến và bài toán hệ nguyên tử	20
3.3	Ứng dụng: Equivariance trong Robotics	22
3.4	Giới hạn: Vấn đề Symmetry Breaking	22
3.5	So sánh hai hướng tiếp cận	23
4	Lý thuyết nâng cao và các hướng nghiên cứu mới	24
4.1	Lợi ích về độ phức tạp mẫu (Sample Complexity Gains)	24
4.2	Giải quyết chi phí tính toán bằng Expanders	24
4.3	Kiểm định tính đối xứng trong dữ liệu (Symmetry Testing)	25
4.4	Tính đối xứng tham số mạng nơ-ron (Neural Parameter Symmetries)	25
4.5	Cảnh quan hàm mất mát và Gộp mô hình	25
4.6	Học trên không gian trọng số (Weight Space Learning)	26
4.7	Đối xứng linh hoạt và Khám phá đối xứng	26
4.8	Mô hình bất kỳ chiều (Any-dimensional Models)	26
4.9	Hình học vượt đối xứng: Topology và Curvature	26
5	Thực nghiệm và Demo minh họa	27
5.1	Bài toán và Tập dữ liệu	27
5.2	Mô tả mô hình cài đặt	27
5.3	Môi trường thực nghiệm	27
5.4	Kết quả và Phân tích	27
6	Đánh giá và Kết luận	28
6.1	Thảo luận: Có nên luôn mã hóa tính đối xứng?	28
6.2	Ưu điểm và Hạn chế của Geometric Machine Learning	28
6.3	Các hướng nghiên cứu tương lai	28
6.4	Kết luận	28
6.5	Phân công nhiệm vụ và Tự đánh giá	28
	Phụ lục: Phân công công việc nhóm	29
	Tài liệu tham khảo	30



Danh sách các hình

1.1	Phân loại các miền hình học theo khung 5G (Grids, Groups, Graphs, Geodesics, Gauges). Nguồn: <i>Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges</i> (Bronstein et al., 2021).	4
1.2	Sơ đồ giao hoán toán học. (a) Tính đẳng biến (Equivariance): Biến đổi đầu vào tương đương với việc áp dụng phép biến đổi tương ứng lên đầu ra. (b) Tính bất biến (Invariance): Đầu ra không bị ảnh hưởng bởi phép biến đổi nhóm $\mathbf{g}$.	5
3.1	Sơ đồ giao hoán (commutative diagram) của học biểu diễn equivariant: áp dụng phép tăng cường a lên đầu vào rồi mã hóa, hoặc mã hóa trước rồi tác động T_a trong không gian ẩn — hai hướng đi đều cho cùng kết quả.	11
3.2	Pipeline chuẩn hóa: đầu vào x được ánh xạ về dạng chuẩn $c(x)$, xử lý bằng mô hình f , sau đó áp dụng phép biến đổi ngược c^{-1} để đạt equivariance. Nếu chỉ cần invariance thì bỏ qua bước cuối.	12
3.3	Minh họa vấn đề tính liên tục trong chuẩn hóa: hai đám mây điểm chỉ khác nhau rất nhỏ (số 3 so với 3.01) nhưng sau khi sắp xếp lại cho ra hai dạng chuẩn xa nhau về khoảng cách Euclidean. Nguồn: ^[1] , trang 14.	13
3.4	Cấu trúc tổng quát của mô hình tương biến: xen kẽ các lớp tuyến tính tương biến với hàm kích hoạt phi tuyến σ , kết thúc bằng một lớp gộp bất biến toàn cục.	15
3.5	Ma trận trọng số $\mathbf{W}$ sau khi áp ràng buộc tương biến với nhóm dịch chuyển tuần hoàn C_5 . Các ô cùng màu chia sẻ cùng một giá trị tham số. Cấu trúc này chính xác là ma trận circulant của phép tích chập.	16
3.6	Ma trận trọng số $\mathbf{W}$ sau khi áp ràng buộc tương biến với nhóm hoán vị S_n . Toàn bộ ma trận $n \times n$ chỉ còn 2 giá trị: α_1 trên đường chéo và α_2 ở tất cả vị trí còn lại.	17
3.7	So sánh tích chập thông thường và tích chập nhóm. Tích chập nhóm là sự tổng quát hóa trực tiếp: thay vì chỉ trượt theo phép tịnh tiến, bộ lọc được trượt qua toàn bộ các phần tử của nhóm G .	18
3.8	Minh họa định lý cơ bản: mọi hàm bất biến với $O(d)$ đều có thể được tính từ ma trận Gram của các tích vô hướng, bất kể số chiều d hay số điểm n .	19



- 3.9 Phương pháp tensor: nâng đầu vào lên không gian tensor bậc k để vượt qua giới hạn của bổ đề Schur và đạt được tính phổ quát. 20
- 3.10 Minh họa bài toán hệ nguyên tử: phân tử H_2O được biểu diễn dưới dạng đồ thị. Mỗi nút mang đặc trưng vô hướng h_i (loại nguyên tử) và tọa độ vector $\mathbf{r}_i$. Mô hình cần dự đoán năng lượng E bất biến với mọi phép biến đổi $E(3)$ 21
- 3.11 Cơ chế cập nhật tương biến: hàm message φ chỉ nhận khoảng cách bình phương $\|\mathbf{x}_i - \mathbf{x}_j\|^2$ (một đại lượng bất biến) thay vì tọa độ tuyệt đối, đảm bảo kết quả tương biến với nhóm $E(3)$ 21
- 3.12 Sơ đồ tính lực qua vi phân tự động: mô hình chỉ được huấn luyện dự đoán năng lượng E (vô hướng), nhưng đồng thời cung cấp $3N$ thành phần lực vector nhất quán và đảm bảo tính đối xứng. 22



Danh sách các bảng



Danh sách các ký hiệu và chữ viết tắt

Ký hiệu / Viết tắt	Ý nghĩa
Chữ viết tắt	
API	Giao diện lập trình ứng dụng (Application Programming Interface)
AUC	Diện tích dưới đường cong ROC (Area Under the Curve)
CNN	Mạng tích chập (Convolutional Neural Network)
DA	Tăng cường dữ liệu (Data Augmentation)
GNN	Mạng nơ-ron đồ thị (Graph Neural Network)
MLP	Perceptron đa lớp (Multi-Layer Perceptron)
PCA	Phân tích thành phần chính (Principal Component Analysis)
SSL	Học tự giám sát (Self-Supervised Learning)
Không gian và tập hợp	
$\mathbb{R}$	Tập hợp các số thực
G	Nhóm đối xứng (symmetry group)
$g \in G$	Phần tử nhóm, đại diện cho một phép biến đổi
$g \cdot x$	Tác động của phần tử g lên điểm dữ liệu x
$\text{Orb}_G(x)$	Quỹ đạo của x dưới tác động của G : tập $\{g \cdot x \mid g \in G\}$
S_n	Nhóm hoán vị n phần tử
$SO(d)$	Nhóm quay đặc biệt trong $\mathbb{R}^d$
$E(3)$	Nhóm Euclidean trong $\mathbb{R}^3$ (quay, phản xạ, tịnh tiến)
T_a, R_a	Phép biến đổi tuyến tính trong không gian ảnh tương ứng với phép tăng cường a
$c(x)$	Dạng chuẩn (canonical form) của điểm dữ liệu x
$\mathcal{L}$	Hàm mất mát (loss function)
Toán tử, hàm số và phép toán	



Ký hiệu / Viết tắt	Ý nghĩa (tiếp theo)
--------------------	---------------------

$K(x, y)$	Hàm hạt nhân đánh giá giữa hai điểm x và y
-----------	--

Biến số, chỉ số và ký hiệu Hy Lạp

α	Biên an toàn (margin) / Giới hạn độ tin cậy / Ngưỡng kiểm soát tỷ lệ lỗi
----------	--



Danh mục các thuật ngữ

Thuật ngữ tiếng Anh	Thuật ngữ tiếng Việt
Absolute convergence	Hội tụ tuyệt đối
Accepting path	Đường đi chấp nhận
Canonical form / Canonicalization	Dạng chuẩn / Chuẩn hóa
Contrastive learning	Học tương phản
Data augmentation	Tăng cường dữ liệu
Equivariance	Tương biến (equivariance)
Frame averaging	Lấy trung bình khung
Graph isomorphism	Đồng cấu đồ thị
Group	Nhóm (đại số)
Group averaging / Reynolds operator	Lấy trung bình nhóm / Toán tử Reynolds
Invariance	Bất biến (invariance)
Latent space	Không gian ẩn
Orbit	Quỹ đạo
Point cloud	Đám mây điểm
Representation learning	Học biểu diễn
Symmetry	Tính đối xứng



Lời mở đầu

Đồ án của nhóm tập trung vào



Chương 1

Giới thiệu

1.1 Bối cảnh và động lực thực hiện

Trong thập kỷ qua, sự thành công của các mô hình học sâu trong việc giải quyết những bài toán phức tạp của trí tuệ nhân tạo là điều không thể phủ nhận. Tuy nhiên, sự phát triển này lại đi kèm với những thách thức to lớn về mặt lý thuyết và thực tiễn, đặt ra yêu cầu cấp thiết về một khung toán học thống nhất và sự hiểu biết sâu sắc hơn về bản chất của các mô hình nơ-ron nhân tạo.

1.1.1. Vấn đề phân mảnh kiến trúc và lời nguyên đa chiều

Hạn chế đầu tiên và rõ rệt nhất của lĩnh vực học sâu hiện đại là sự thiếu vắng các nguyên lý thống nhất. Hiện nay, cộng đồng nghiên cứu đang chứng kiến sự bùng nổ của vô số kiến trúc mạng nơ-ron khác nhau, được thiết kế riêng biệt cho từng định dạng dữ liệu. Sự phân mảnh này dẫn đến tình trạng các khái niệm cơ bản liên tục được phát minh lại và định danh dưới những tên gọi khác nhau trong các lĩnh vực ứng dụng riêng biệt, làm lu mờ đi bản chất toán học cốt lõi của bài toán.

Bên cạnh đó, dưới góc độ lý thuyết học thống kê, việc xấp xỉ một hàm số tổng quát trong không gian đa chiều mà không dựa trên bất kỳ giả định tiên nghiệm nào là một bài toán bị chi phối nặng nề bởi lời nguyên đa chiều. Nếu chỉ dựa trên giả định về tính trơn cục bộ, độ phức tạp mẫu yêu cầu để học chính xác hàm mục tiêu sẽ tăng theo cấp số nhân so với số chiều của dữ liệu, khiến bài toán trở nên bất khả thi trong thực tế ngay cả với năng lực tính toán hiện đại.

Khai thác tiên nghiệm hình học phá vỡ lời nguyên đa chiều

Tuy nhiên, dữ liệu trong thế giới thực hiếm khi tồn tại dưới dạng các vector vô hướng ngẫu nhiên; chúng luôn mang theo những quy luật vật lý và cấu trúc hình học đặc thù, chẳng hạn như tính chu kỳ trong tín hiệu, cấu trúc lưới trong hình ảnh, hoặc các liên kết tô-pô trong phân tử hóa học. Việc khai thác các tiên nghiệm hình học này, đặc biệt là tính bất biến và tính đẳng biến thông qua lăng kính của *Geometric Deep Learning*, đóng vai trò như một cơ chế lọc tự nhiên, giúp giới hạn triệt để không gian hàm cần tìm kiếm, qua đó trực tiếp phá vỡ lời nguyên đa chiều



và cung cấp một bản thiết kế chung để hệ thống hóa toàn bộ các kiến trúc mạng hiện hành như CNN, RNN và GNN.

1.1.2. Tính đối xứng tham số và học không gian trọng số

Sự chuyển dịch bối cảnh thứ hai xuất phát từ chính cấu trúc bên trong của các mô hình ngôn ngữ và mô hình tạo sinh quy mô lớn hiện nay. Các mô hình học sâu hiện đại có đặc điểm chung là bị siêu tham số hóa, dẫn đến sự suy biến nghiêm trọng trong không gian tối ưu: có vô số cấu hình trọng số khác nhau nhưng lại sản sinh ra cùng một hàm tính toán ở đầu ra.

Tính đôi dư này bắt nguồn từ tính đối xứng không gian tham số. Khác với đối xứng của dữ liệu đầu vào trong *Geometric Deep Learning* truyền thống, đối xứng tham số là những phép biến đổi áp dụng trực tiếp lên các ma trận trọng số mà không làm thay đổi hành vi của toàn bộ mạng. Sự tồn tại của các đa tạp chứa điểm cực tiểu tương đương này định hình cấu trúc của cảnh quan hàm mất mát, gây ra các hiện tượng như sự kết nối cực tiểu và làm phức tạp hóa quá trình tối ưu hóa.

Xu hướng học không gian trọng số trong kỷ nguyên mô hình nền tảng

Với sự bùng nổ của hàng triệu mô hình được lưu trữ trên các nền tảng mã nguồn mở, cộng đồng đang chứng kiến một hệ quả tất yếu là sự ra đời của hướng nghiên cứu học không gian trọng số. Hướng đi này coi chính các kiến trúc mạng nơ-ron là dữ liệu đầu vào, sử dụng *meta-networks* để phân tích, nén và tinh chỉnh trực tiếp trên cấu trúc tham số. Trong kỷ nguyên của mô hình nền tảng, việc hiểu và tận dụng các đối xứng tham số linh hoạt thay vì *hard-coding* trở thành chìa khóa để cải thiện định luật tỷ lệ và tăng cường hiệu quả tính toán.

1.1.3. Ý nghĩa và tầm quan trọng thực tiễn

Sự kết hợp giữa lý thuyết hình học của dữ liệu và tính đối xứng trong không gian tham số mang lại những bước tiến mang tính bản lề cho toàn bộ vòng đời của hệ thống học máy. Về mặt lý thuyết toán học, các chứng minh mới nhất cho thấy việc mã hóa tính đối xứng giúp cải thiện mạnh mẽ độ phức tạp mẫu, giảm thiểu nhu cầu dữ liệu lên đến nhiều bậc độ lớn, và gia tăng khả năng tổng quát hóa ngoài phân phối một cách nghiêm ngặt.


Ứng dụng khoa học mũi nhọn trong thế giới thực

Hơn thế nữa, các mô hình học sâu dựa trên nền tảng hình học và đối xứng đang đóng vai trò trung tâm trong việc giải quyết những bài toán khoa học mũi nhọn. Từ việc mô phỏng hệ nguyên tử, dự đoán năng lượng tương tác phân tử, đến việc ứng dụng tính đẳng biến nhóm $SE(3)$ trong Robotics để điều khiển thao tác trong không gian vật lý, *Geometric Deep Learning* đang chứng minh tiềm năng to lớn trong việc định hình các hệ thống trí tuệ nhân tạo có khả năng tương tác trực tiếp với các định luật vật lý của thế giới thực.

1.2 Kỹ nguyên của dữ liệu hình học


Lĩnh vực học máy đang chứng kiến nỗ lực to lớn nhằm hợp nhất các mô hình phân mảnh thành một hệ thống lý thuyết chặt chẽ thông qua lăng kính hình học. Nỗ lực này được truyền cảm hứng sâu sắc từ Chương trình Erlangen của nhà toán học Felix Klein, trong đó đề xuất rằng hình học nên được nghiên cứu thông qua các thuộc tính được bảo toàn dưới tác động của các nhóm phép biến đổi.

Geometric Deep Learning kế thừa tư duy này để định hình lại cách hệ thống trí tuệ nhân tạo tiếp nhận dữ liệu. Thay vì xử lý dữ liệu như các vector vô hướng, phương pháp này mô hình hóa dữ liệu dưới dạng các tín hiệu nằm trên năm miền hình học cơ bản, thường được gọi là khung 5G bao gồm Grids, Groups, Graphs, Geodesics và Gauges. Việc gắn kết dữ liệu vào các miền hình học cụ thể cho phép khai thác triệt để các quy luật tự nhiên, chẳng hạn như tính chu kỳ của ảnh trên miền Grids hay liên kết hóa học trên miền Graphs.



Hình 1.1: Phân loại các miền hình học theo khung 5G (Grids, Groups, Graphs, Geodesics, Gauges). Nguồn: *Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges* (Bronstein et al., 2021).

Từ sự phân loại này, một bản thiết kế chung được đề xuất nhằm chuẩn hóa cấu trúc của mạng nơ-ron. Cấu trúc này bao gồm bốn thành phần tính toán cốt lõi: lớp đồng biến tuyến tính, hàm kích hoạt phi tuyến, lớp gộp cục bộ để trích xuất đặc trưng đa tỷ lệ, và lớp gộp bất biến toàn cục ở cuối mạng. Trong đó, hai khái niệm toán học đóng vai trò nền tảng là Invariance và Equivariance. Invariance đảm bảo đầu ra của mô hình không thay đổi khi dữ liệu đầu vào bị biến đổi, trong khi Equivariance yêu cầu đầu ra phải biến thiên một cách tương ứng theo đúng phép biến đổi của đầu vào.



Hình 1.2: Sơ đồ giao hoán toán học. (a) Tính đẳng biến (Equivariance): Biến đổi đầu vào tương đương với việc áp dụng phép biến đổi tương ứng lên đầu ra. (b) Tính bất biến (Invariance): Đầu ra không bị ảnh hưởng bởi phép biến đổi nhóm g .

Bản thiết kế này cung cấp một khuôn khổ toán học minh bạch, chứng minh rằng các kiến trúc thành công nhất hiện nay như CNN, RNN, GNN và Transformer thực chất chỉ là các biến thể khác nhau của cùng một nguyên lý đối xứng khi áp dụng lên các miền dữ liệu hình học khác nhau.

1.3 Sự dịch chuyển sang không gian trọng số

Nếu như giai đoạn đầu của Geometric Deep Learning tập trung giải quyết các bài toán liên quan đến đối xứng trong không gian dữ liệu, thì xu hướng nghiên cứu hiện đại đang chứng kiến một bước chuyển dịch chiến lược sang việc phân tích tính đối xứng ngay bên trong cấu trúc của mạng nơ-ron, được gọi là Parameter space symmetry.

Các mô hình học sâu hiện đại thường ở trạng thái siêu tham số hóa, dẫn đến hiện tượng vô số cấu hình trọng số khác nhau nhưng lại sản sinh ra cùng một hàm tính toán ở đầu ra. Sự dư thừa này bắt nguồn từ các phép biến đổi nội tại, chẳng hạn như hoán vị các nơ-ron ẩn hoặc thay đổi tỷ lệ trọng số của hàm kích hoạt ReLU, mà không làm thay đổi giá trị dự đoán cuối cùng. Việc nhận diện Parameter space symmetry giúp giải mã



cấu trúc phức tạp của Loss landscape, giải thích nguyên nhân hình thành các vùng bình nguyên và hiện tượng Mode connectivity giữa các điểm cực tiểu cục bộ.

Kỹ thuật Teleportation và Equivariant Metanetworks

Khám phá này mở ra những kỹ thuật tối ưu hóa đột phá, điển hình là phương pháp Teleportation, cho phép thuật toán Gradient Descent chủ động dịch chuyển tham số đến các cấu hình tương đương mang đặc tính hội tụ tốt hơn. Quan trọng hơn, sự hiểu biết về đối xứng tham số là tiền đề cho lĩnh vực Weight space learning. Trong mô hình này, các tập hợp trọng số được xem như dữ liệu đầu vào cho một hệ thống Equivariant Metanetworks. Kiến trúc cấp cao này có khả năng dự đoán khả năng tổng quát hóa, nén mô hình và hợp nhất các điểm cực tiểu một cách hiệu quả mà không cần tiến hành suy luận trực tiếp trên dữ liệu gốc.

1.4 Mục tiêu và phạm vi của đề án

1.4.1. Mục tiêu nghiên cứu

Đề án này hướng tới việc hệ thống hóa và thực nghiệm các kỹ thuật tiên tiến nhất trong lĩnh vực học máy hình học, dựa trên nền tảng lý thuyết từ các hội nghị đầu ngành. Việc tích hợp các tiên nghiệm hình học vào mô hình nhằm chứng minh ba lợi ích cốt lõi sau:

- **Giảm bậc tự do và tăng Data efficiency:** Bằng cách ràng buộc không gian tìm kiếm thông qua các phép đối xứng, mô hình có thể đạt được độ chính xác cao với lượng dữ liệu huấn luyện ít hơn nhiều bậc độ lớn so với các phương pháp truyền thống.
- **Cải thiện OOD generalization và Robustness:** Kiến trúc tôn trọng các phép biến đổi hình học giúp hệ thống duy trì tính ổn định và khả năng ngoại suy chính xác khi đối mặt với dữ liệu nằm ngoài phân phối huấn luyện ban đầu.
- **Hỗ trợ các tác vụ tạo sinh:** Hiểu rõ cơ chế duy trì và phá vỡ đối xứng cung cấp nền tảng toán học vững chắc cho việc thiết kế các mô hình tạo sinh cấu trúc phức tạp như phân tử thuốc hay protein.



1.4.2. Phạm vi và cấu trúc báo cáo

Báo cáo tổng hợp các kỹ thuật từ nền tảng toán học cơ bản đến những hướng tiếp cận mới nhất về đối xứng tham số và học không gian trọng số. Nội dung chi tiết được tổ chức thành năm chương tiếp theo:

- **Chương 2** trình bày kiến thức nền tảng toán học, tập trung vào lý thuyết nhóm, tính bất biến và tính đẳng biến.
- **Chương 3** phân tích các phương pháp cốt lõi để xây dựng mô hình tương biến, bao gồm các phép tích chập nhóm và cơ chế chia sẻ tham số.
- **Chương 4** mở rộng sang các kỹ thuật xử lý dữ liệu hiện đại như Frame averaging và các lý thuyết mới về học không gian trọng số.
- **Chương 5** mô tả chi tiết thiết lập thực nghiệm, cấu hình phần cứng và phân tích kết quả so sánh giữa mô hình đề xuất và các phương pháp cơ sở.
- **Chương 6** tổng hợp các đánh giá ưu nhược điểm, rút ra kết luận về tính ứng dụng thực tiễn và định hướng các nghiên cứu trong tương lai.



Chương 2

Kiến thức nền tảng

2.1 Khái niệm cơ bản về Đối xứng (Symmetry)

2.2 Tính Bất biến (Invariance) và Đồng biến (Equivariance)

Định nghĩa Bất biến: $f(T(x))=f(x)$ (Kèm ví dụ dịch chuyển ảnh con mèo). Định nghĩa Đồng biến: $f(T(x))=T(f(x))$ (Kèm ví dụ dự đoán thuộc tính nút trên đồ thị hoặc cánh tay robot).

2.3 Cơ sở Lý thuyết Nhóm (Group, Group Actions, Orbit)

Định nghĩa toán học của một Nhóm (Group G) với 4 tính chất: Kết hợp, Phần tử đơn vị, Phần tử nghịch đảo, và Tính đóng

2.4 Tác động Nhóm và Quỹ đạo (Group Action Orbits)

Định nghĩa cách nhóm tác động lên dữ liệu x (ví dụ phép quay, tịnh tiến, hoán vị) và định nghĩa quỹ đạo (Orbit) của x



Chương
3

Các phương pháp xây dựng mô hình bảo toàn tính đối xứng

3.1 Hướng 1: Can thiệp dữ liệu trên các mô hình có sẵn

Trước khi đi vào các phương pháp xây dựng kiến trúc hoàn toàn mới, một hướng tiếp cận tự nhiên hơn là tận dụng lại những mô hình học máy đã được huấn luyện tốt — thứ mà cộng đồng nghiên cứu đã đổ rất nhiều công sức phát triển — rồi can thiệp vào phía dữ liệu để ép mô hình phải tôn trọng tính đối xứng. Hướng này được gọi là hướng can thiệp dữ liệu, hay còn được gọi là cách tiếp cận với mô hình hộp đen.

Ưu điểm cốt lõi của hướng này là mô hình cơ sở — dù là Transformer, CNN hay bất kỳ kiến trúc nào khác — được giữ nguyên hoàn toàn, kéo theo toàn bộ sức mạnh biểu diễn, kỹ thuật tối ưu, và quy trình huấn luyện của nó vẫn còn hiệu lực. Điều đó có nghĩa là người dùng không cần thiết kế lại bất cứ điều gì từ đầu. Ngoài ra, nếu mô hình cơ sở đã có sẵn một số tính chất đối xứng nhất định, việc kết hợp thêm các nhóm đối xứng khác thông qua can thiệp dữ liệu là hoàn toàn khả thi mà không gây mâu thuẫn.

Trong hướng này, có ba kỹ thuật chính: tăng cường dữ liệu, chuẩn hóa, và lấy trung bình nhóm/khung (mục này được Lê Công Phúc trình bày riêng). Ba kỹ thuật này nằm trên một phổ liên tục: từ một phép biến đổi duy nhất ở một đầu, đến lấy trung bình trên toàn bộ nhóm G ở đầu kia, với lấy trung bình khung nằm ở giữa như một điểm cân bằng giữa chi phí tính toán và chất lượng đảm bảo tính đối xứng.

3.1.1. Tăng cường dữ liệu

Ý tưởng cơ bản. Tăng cường dữ liệu là kỹ thuật đơn giản và phổ biến nhất để đưa tính đối xứng vào mô hình: với mỗi điểm dữ liệu x trong tập huấn luyện, ta sinh thêm các biến thể $g \cdot x$ cho nhiều phần tử $g \in G$ khác nhau và đưa chúng vào tập huấn luyện cùng nhãn gốc. Khi tập huấn luyện bao phủ đủ nhiều biến thể của quỹ đạo $\text{Orb}_G(x)$, mô hình sẽ dần học được rằng phép biến đổi g không làm thay đổi nhãn, tức là dần hình thành tính bất biến.




Kỹ thuật này cực kỳ linh hoạt vì nó có thể áp dụng cho cả học có giám sát lẫn học tự giám sát. Trong học tương phản, người ta thường tạo cặp dữ liệu $(x, g \cdot x)$ và đặt chúng ở vị trí “dương” (positive pair), buộc mô hình phải đặt cả hai vào cùng một vùng trong không gian ẩn. Qua đó, toàn bộ quỹ đạo của x dưới tác động của G sẽ được ánh xạ về một biểu diễn duy nhất.

Giới hạn: chỉ đảm bảo tính đối xứng xấp xỉ. Dù đơn giản và hiệu quả trong thực tế, tăng cường dữ liệu mang một hạn chế quan trọng về mặt lý thuyết: nó không đảm bảo tính bất biến ở mọi điểm. Nói cách khác, sau khi huấn luyện, không có gì chắc chắn rằng với một điểm dữ liệu mới x' chưa thấy, mô hình sẽ cho ra cùng một kết quả cho x' và $g \cdot x'$. Mô hình có thể đã *học ước lượng* tính bất biến trong vùng lân cận của dữ liệu huấn luyện, nhưng không có gì đảm bảo điều đó khái quát hóa ra ngoài phân phối. Đây là lý do tại sao slide của khóa học mô tả tăng cường dữ liệu là phương pháp “không đảm bảo tính bất biến ở mọi nơi” (*does not guarantee invariance everywhere*).

Mở rộng: học biểu diễn equivariant. Một bước phát triển thú vị từ tăng cường dữ liệu là học biểu diễn *equivariant* thay vì chỉ *invariant*. Trong bài toán học biểu diễn, đôi khi ta không muốn hoàn toàn “quên đi” phép biến đổi mà dữ liệu đã trải qua; ta muốn không gian ẩn ghi nhớ lại sự biến đổi đó theo một cách có cấu trúc. Cụ thể, nếu a là một phép tăng cường và f là mạng mã hóa, thì mục tiêu là:

$$f(a(x)) = T_a \cdot f(x), \quad (3.1)$$

trong đó T_a là một phép biến đổi nào đó tác động lên không gian ẩn, tương ứng với a . Đây chính là định nghĩa equivariance áp dụng vào bài toán học biểu diễn. Sơ đồ giao hoán 3.1 minh họa trực quan ý tưởng này.



Hình 3.1: Sơ đồ giao hoán (commutative diagram) của học biểu diễn equivariant: áp dụng phép tăng cường a lên đầu vào rồi mã hóa, hoặc mã hóa trước rồi tác động T_a trong không gian ẩn — hai hướng đi đều cho cùng kết quả.

Một cách tiếp cận trực tiếp là dùng một mạng nhỏ $\text{MLP}(a, f(x))$ để dự đoán $f(a(x))$, từ đó đặt hàm mất mát:

$$\mathcal{L} = \|f(a(x)) - \text{MLP}(a, f(x))\|. \quad (3.2)$$

Tuy nhiên, cách này có một nhược điểm: không có gì đảm bảo T_a sẽ tương thích với phép kết hợp nhóm, tức là $T_{a_2 \circ a_1} \neq T_{a_2} \circ T_{a_1}$ có thể xảy ra.

Phiên bản tuyến tính: ràng buộc bảo toàn tích vô hướng. Để khắc phục hạn chế đó, các nghiên cứu sau này đề xuất một cách đơn giản hơn: giả định rằng T_a là một phép quay tác động lên không gian ẩn, tức là $T_a = R_a$ là ma trận trực giao. Khi đó, ta không cần trực tiếp học R_a , mà thay vào đó tận dụng tính chất của phép quay: nó bảo toàn tích vô hướng giữa hai vector. Cụ thể, nếu $f(a(x'))^\top f(a(x)) = f(x')^\top f(x)$ với mọi cặp (x, x') và phép tăng cường a , thì T_a nhất thiết phải là một phép quay. Hàm mất mát tương ứng là:

$$\mathbb{E}_{a, x, x'} [f(a(x'))^\top f(a(x)) - f(x')^\top f(x)]^2 = 0. \quad (3.3)$$


Khi hàm mất mát bằng 0, mỗi $T_a = R_a$ là một phép quay trong không gian ẩn và tự động tương thích với phép kết hợp nhóm — tức là $\{T_a\}_{a \in G}$ tạo thành một biểu diễn nhóm của G . Điều đáng chú ý là phép tăng cường a tác động lên đầu vào không nhất thiết phải là một phép quay; đây là hệ quả của định lý Peter–Weyl trong lý thuyết nhóm. Hướng này được phát triển bởi Shakerinava et al. (2022) và Gupta et al. (2023).

3.1.2. Chuẩn hóa

Ý tưởng cơ bản. Kỹ thuật chuẩn hóa theo đuổi một chiến lược hoàn toàn khác: thay vì làm phong phú tập dữ liệu bằng nhiều biến thể, ta chuyển mỗi điểm dữ liệu x về một dạng chuẩn duy nhất trước khi đưa vào mô hình. Miễn là hàm chuẩn hóa $c(\cdot)$ ánh xạ mọi phần tử trong cùng một quỹ đạo về cùng một điểm duy nhất, thì mô hình sẽ tự động bất biến:

$$c(g \cdot x) = c(x) \quad \forall g \in G. \quad (3.4)$$

Ví dụ điển hình nhất là sắp xếp cho bài toán invariant với hoán vị: với bất kỳ chuỗi nào, ta sắp xếp nó theo thứ tự tăng dần trước khi đưa vào mô hình. Vì mọi hoán vị của cùng một chuỗi đều cho ra cùng một dạng đã sắp xếp, mô hình luôn nhận cùng một đầu vào và cho ra cùng một kết quả. Để đạt equivariance thay vì chỉ invariance, ta thực hiện thêm một bước: sau khi mô hình xử lý dạng chuẩn, ta áp dụng phép biến đổi ngược để khôi phục thứ tự ban đầu. Hình 3.2 minh họa toàn bộ quy trình này.



Hình 3.2: Pipeline chuẩn hóa: đầu vào x được ánh xạ về dạng chuẩn $c(x)$, xử lý bằng mô hình f , sau đó áp dụng phép biến đổi ngược c^{-1} để đạt equivariance. Nếu chỉ cần invariance thì bỏ qua bước cuối.

Trong ví dụ sắp xếp, nếu dãy $[5, 3, 4]$ được sắp thành $[3, 4, 5]$, mô hình xử lý và cho ra kết quả theo thứ tự đó, rồi ta hoán vị ngược lại để đầu ra có thứ tự tương ứng với đầu vào gốc.

Hàm chuẩn hóa $c(\cdot)$ không nhất thiết phải được thiết kế bằng tay; nó cũng có thể được học từ dữ liệu thông qua một mạng neural phụ trợ^[2]. Hướng này mở ra khả năng tận dụng sức mạnh của deep learning để tự động tìm ra cách biểu diễn chuẩn phù hợp nhất cho bài toán cụ thể.

Thách thức 1: không phải lúc nào cũng dễ xác định dạng chuẩn. Đối với chuỗi số, sắp xếp là một lựa chọn tự nhiên và đơn giản. Nhưng không phải mọi loại dữ liệu đều có một dạng chuẩn rõ ràng. Hãy lấy ví dụ với đồ thị: một đồ thị n nút có thể được mô tả bởi $n!$ ma trận kề khác nhau, tương ứng với $n!$ cách đánh số các nút. Tìm một biểu diễn chuẩn chung cho tất cả các cách đánh số đó về cơ bản tương đương với việc giải bài

toán kiểm tra đẳng cấu đồ thị (graph isomorphism) — một bài toán đã được nghiên cứu trong nhiều thập kỷ nhưng vẫn chưa có thuật toán đa thức được chứng minh. Tương tự với đám mây điểm trong không gian 3D kết hợp đối xứng quay và hoán vị, việc chuẩn hóa trở nên rất phức tạp.

Thách thức 2: vấn đề tính liên tục. Đây là hạn chế lý thuyết nghiêm trọng nhất của kỹ thuật chuẩn hóa. Tính liên tục yêu cầu rằng nếu hai đầu vào gần nhau thì hai đầu ra cũng phải gần nhau. Với chuỗi số vô hướng, sắp xếp duy trì tính liên tục vì một thay đổi nhỏ thường không làm đảo lộn toàn bộ thứ tự. Tuy nhiên, câu chuyện hoàn toàn khác khi dữ liệu là các vector đa chiều.

Hãy xem xét ví dụ cụ thể từ slides của khóa học (trang 14 trong file slides NeurIPS 2025): ta có hai đám mây điểm gần nhau, mỗi đám gồm hai vector. Đám thứ nhất chứa $[5, 3, 3]^T$ và $[1, 7, 8]^T$; đám thứ hai chứa $[5, 3.01, 3]^T$ và $[1, 7, 8]^T$ — chỉ thay đổi một phần tử nhỏ từ 3 thành 3.01. Nếu ta sắp xếp các vector theo thứ tự từ điển, thì thứ tự sắp xếp của hai đám sẽ khác nhau hoàn toàn vì 3.01 khiến thứ tự tương đối của hai chiều thứ hai và thứ ba bị đảo ngược. Kết quả là hai đầu vào cực kỳ gần nhau lại được ánh xạ đến hai dạng chuẩn rất xa nhau về khoảng cách Euclidean.



Example adapted from Dym et al 2024

Hình 3.3: Minh họa vấn đề tính liên tục trong chuẩn hóa: hai đám mây điểm chỉ khác nhau rất nhỏ (số 3 so với 3.01) nhưng sau khi sắp xếp lại cho ra hai dạng chuẩn xa nhau về khoảng cách Euclidean. Nguồn: ^[1], trang 14.

Kết quả lý thuyết của Dym et al. (2024) và Zhang et al. (2020) chỉ ra rằng đây không phải vấn đề của riêng một cách sắp xếp cụ thể nào, mà là một giới hạn căn bản không thể tránh được:

Định lý 3.1 (Không tồn tại chuẩn hóa liên tục, Dym et al. 2024). *Không tồn tại hàm chuẩn hóa liên tục nào cho nhóm hoán vị S_n tác động lên $\mathbb{R}^{d \times n}$ với $n, d > 1$. Tương tự, không tồn tại frame hữu hạn liên tục nào cho $SO(2)$ trong trường hợp tổng quát.*



Hệ quả thực tiễn của định lý này là: dù ta thiết kế hàm chuẩn hóa khéo léo đến đâu, sẽ luôn tồn tại những cặp đầu vào gần nhau nhưng có dạng chuẩn cách xa nhau, dẫn đến hành vi không ổn định của mô hình. Đây là lý do frame averaging — sẽ được trình bày ở mục tiếp theo — trở thành một lựa chọn hấp dẫn hơn: bằng cách lấy trung bình trên nhiều phép biến đổi thay vì chỉ chọn một, frame averaging khắc phục được vấn đề liên tục này.

Tổng kết về chuẩn hóa. Nhìn chung, chuẩn hóa là kỹ thuật hiệu quả và rẻ về tính toán so với lấy trung bình nhóm, đặc biệt khi nhóm G lớn. Nó phù hợp nhất trong các trường hợp dạng chuẩn tự nhiên và dễ xác định (như sắp xếp cho hoán vị trên vô hướng), và cần thận trọng với các bài toán yêu cầu tính ổn định cao trước các nhiễu nhỏ. Bảng ?? ở cuối mục này tóm tắt so sánh ba kỹ thuật.

3.1.3. Lấy trung bình Nhóm và Khung (Group/Frame Averaging)

Một trong những phương pháp mạnh mẽ nhất để trang bị tính bất biến (invariance) hoặc tương biến (equivariance) cho một mô hình học máy thông thường là sử dụng toán tử Reynolds, hay còn gọi là kỹ thuật lấy trung bình nhóm (Group Averaging). Cụ thể, cho một mạng nơ-ron cơ sở Φ , ta có thể tạo ra một hàm tương biến $\langle \Phi \rangle_G$ bằng cách tính trung bình đầu ra của Φ trên toàn bộ các phép biến đổi g thuộc nhóm đối xứng G :

$$\langle \Phi \rangle_G(X) = \frac{1}{|G|} \sum_{g \in G} \rho_2(g) \Phi(\rho_1(g)^{-1} X) \quad (3.5)$$

Mặc dù phương pháp này đảm bảo tính đối xứng tuyệt đối và bảo toàn khả năng biểu diễn của mô hình cơ sở, nó vấp phải trở ngại cực lớn về độ phức tạp tính toán khi nhóm G quá lớn hoặc có số phần tử vô hạn (ví dụ: nhóm hoán vị S_n hoặc nhóm phép quay $SO(3)$).


Để giải quyết bài toán tính toán này, kỹ thuật **Frame Averaging (Trung bình hóa Khung)** đã được đề xuất^[3]. Thay vì tính trung bình trên toàn bộ nhóm G , phương pháp này chỉ thực hiện lấy trung bình trên một tập hợp con nhỏ $\mathcal{F}(X) \subset G$ được gọi là “khung” (frame). Tập hợp $\mathcal{F}(X)$ này được trích xuất dựa trên chính đặc trưng của dữ liệu đầu vào X . Để đảm bảo tính tương biến, khung $\mathcal{F}$ phải thỏa mãn điều kiện $\mathcal{F}(\rho_1(g)X) = g\mathcal{F}(X)$. Khi đó, công thức xấp xỉ trở thành:

$$\langle \Phi \rangle_{\mathcal{F}}(X) = \frac{1}{|\mathcal{F}(X)|} \sum_{g \in \mathcal{F}(X)} \rho_2(g) \Phi(\rho_1(g)^{-1} X) \quad (3.6)$$

Ứng dụng PCA Frame cho Đám mây điểm (Point Clouds): Trong thực tiễn, đối với dữ liệu không gian 3 chiều như đồ thị phân tử hoặc đám mây điểm, Phân tích thành phần chính (PCA) thường được sử dụng để xây dựng khung. Thuật toán tính tâm của đám mây điểm và trích xuất các vector riêng (eigenvectors) từ ma trận hiệp phương sai. Khi dữ liệu đầu vào bị xoay hoặc tịnh tiến, PCA Frame tự động tính phép xoay ngược để chiếu dữ liệu về canonical frame trước khi đưa qua mạng. Phương pháp này đạt tính bất biến với $E(3)$ với chi phí tính toán cực kỳ thấp.

3.2 Hướng 2: Xây dựng kiến trúc tương biến từ đầu

Nếu Hướng 1 xem mô hình học máy như một hộp đen và truyền đạt tính đối xứng từ bên ngoài thông qua thao tác dữ liệu, thì Hướng 2 lựa chọn con đường triệt để hơn: mã hóa cứng tính đối xứng vào chính kiến trúc của mạng. Mô hình tương biến được xây dựng theo cấu trúc tổng quát sau.



Hình 3.4: Cấu trúc tổng quát của mô hình tương biến: xen kẽ các lớp tuyến tính tương biến với hàm kích hoạt phi tuyến σ , kết thúc bằng một lớp gộp bất biến toàn cục.

Ưu điểm cốt lõi của hướng này:

- Tính đối xứng được đảm bảo tuyệt đối tại mọi điểm dữ liệu, kể cả những điểm chưa thấy trong quá trình huấn luyện.
- Số tham số giảm mạnh do cơ chế chia sẻ, dẫn đến hiệu quả dữ liệu cao hơn.
- Đặc biệt phù hợp khi tính đối xứng là điều chắc chắn về mặt vật lý hoặc toán học (phân tử, robot, đồ thị).

3.2.1. Lớp tuyến tính tương biến và cơ chế chia sẻ tham số


Nguyên lý xây dựng. Một lớp tuyến tính $\mathbf{W} \in \mathbb{R}^{n \times n}$ đảm bảo tính tương biến với nhóm G khi và chỉ khi nó thỏa mãn ràng buộc sau với mọi phần tử $\tau \in G$:

$$P_{\tau} \mathbf{W} P_{\tau}^{\top} = \mathbf{W} \quad (3.7)$$

Ràng buộc này kéo theo một hệ quả quan trọng: nếu tồn tại phép biến đổi $\tau \in G$ ánh xạ cặp chỉ số (i, j) thành (k, l) , thì bắt buộc $W_{ij} = W_{kl}$. Đây là cơ chế **chia sẻ tham số**: các vị trí cùng quỹ đạo trong G phải mang cùng giá trị, và mỗi quỹ đạo chỉ tương ứng với một tham số tự do duy nhất.

Ví dụ 1: Nhóm dịch chuyển tuần hoàn dẫn đến phép tích chập.

Xét tín hiệu một chiều với nhóm dịch chuyển $G = C_n = \{t_0, t_1, \dots, t_{n-1}\}$, trong đó $t_i(j) = i + j \pmod{n}$.




Ma trận $\mathbf{W}$ sau khi áp ràng buộc: chỉ $n = 5$ tham số

Hình 3.5: Ma trận trọng số $\mathbf{W}$ sau khi áp ràng buộc tương biến với nhóm dịch chuyển tuần hoàn C_5 . Các ô cùng màu chia sẻ cùng một giá trị tham số. Cấu trúc này chính xác là ma trận circulant của phép tích chập.

- Số tham số giảm từ n^2 xuống còn n , tiết kiệm n lần.
- Cấu trúc lặp lại theo đường chéo này chính là định nghĩa của phép **tích chập** (convolution).
- *Kết luận*: mạng tích chập không phải là thiết kế tùy hứng mà là hệ quả tất yếu của việc áp đặt tính tương biến với nhóm dịch chuyển.

Ví dụ 2: Nhóm hoán vị toàn phần dẫn đến kiến trúc DeepSets.

Xét đầu vào là tập hợp n vector $\{x_1, \dots, x_n\} \subset \mathbb{R}^d$ và ta muốn mô hình bất biến với mọi phép hoán vị phần tử, tức $G = S_n$.



Ma trận $\mathbf{W}$ với $G = S_5$: chỉ **2** tham số

Hình 3.6: Ma trận trọng số $\mathbf{W}$ sau khi áp ràng buộc tương biến với nhóm hoán vị S_n . Toàn bộ ma trận $n \times n$ chỉ còn 2 giá trị: α_1 trên đường chéo và α_2 ở tất cả vị trí còn lại.

Kết quả là lớp tuyến tính tương biến có dạng cực kỳ đơn giản:

$$[\mathbf{F}(\mathbf{X})]_i = \alpha_1 x_i + \alpha_2 \sum_{j \neq i} x_j \quad (3.8)$$

- Số tham số giảm từ n^2 xuống còn **2**, bất kể kích thước n .
- Mỗi điểm được biến đổi kết hợp giữa chính nó và tổng tất cả điểm còn lại.
- Đây chính xác là kiến trúc **DeepSets** và **PointNet**.
- Mở rộng: với tensor bậc cao hơn hoặc các nhóm phức tạp hơn (ví dụ hoán vị ma trận kề của đồ thị), số phần tử cơ sở tăng lên nhưng vẫn ít hơn rất nhiều so với n^2 . Với hoán vị đồng thời hàng và cột của ma trận kề, số cơ sở chỉ là 15.

3.2.2. Tích chập nhóm

Từ tích chập thông thường đến tích chập nhóm.

Tích chập thông thường trên lưới $\mathbb{Z}^2$ thực hiện phép trượt bộ lọc ψ qua toàn bộ các phép tịnh tiến:

$$(f \star \psi)(x) := \sum_{y \in \mathbb{Z}^2} f(y) \psi(y - x) \quad (3.9)$$

Quan sát rằng phép trừ $y - x$ chính là tác động của phép tịnh tiến ngược. Điều này gợi ý cách tổng quát hóa tự nhiên: thay toàn bộ phép tịnh tiến bằng một nhóm đối xứng bất kỳ G .

CNN thông thường

Bộ lọc trượt theo
phép **tịnh tiến**
Tương biến tịnh tiến

$\Rightarrow$
tổng quát hóa

Tích chập nhóm

Bộ lọc trượt theo
mọi phần tử của G
Tương biến với G

Hình 3.7: So sánh tích chập thông thường và tích chập nhóm. Tích chập nhóm là sự tổng quát hóa trực tiếp: thay vì chỉ trượt theo phép tịnh tiến, bộ lọc được trượt qua toàn bộ các phần tử của nhóm G .

- Nếu G là nhóm tịnh tiến trên $\mathbb{Z}^2$, tích chập nhóm hoàn toàn trùng với CNN thông thường.
- Nếu G bổ sung thêm các phép xoay 90 và phản chiếu, bộ lọc sẽ tự động bất biến với 8 phép đối xứng của hình vuông (nhóm dihedral D_4).
- Tích chập nhóm là nền tảng của **mạng tích chập tương biến nhóm**, mở rộng CNN sang các nhóm đối xứng tùy ý.


3.2.3. Lý thuyết bất biến và tham số hóa qua đại lượng bất biến

Ý tưởng cốt lõi. Thay vì thiết kế lại toàn bộ kiến trúc, ta có thể tham số hóa trực tiếp các hàm bất biến thông qua một tập hợp nhỏ các đại lượng vô hướng bất biến đơn giản.

Định lý 3.2 (Định lý cơ bản cho nhóm $O(d)$). Mọi hàm $f : (\mathbb{R}^d)^n \rightarrow \mathbb{R}$ bất biến với nhóm xoay và phản chiếu $O(d)$ đều có thể biểu diễn dưới dạng:

$$f(v_1, \dots, v_n) = h\left(\{v_i^\top v_j\}_{i,j=1}^n\right) \quad (3.10)$$

trong đó h là một hàm bất kỳ tác động lên ma trận Gram của các tích vô hướng.



Hình 3.8: Minh họa định lý cơ bản: mọi hàm bất biến với $O(d)$ đều có thể được tính từ ma trận Gram của các tích vô hướng, bất kể số chiều d hay số điểm n .

- **Tại sao đúng:** phép xoay và phản chiếu bảo toàn góc và khoảng cách, tức là bảo toàn chính xác các tích vô hướng $v_i^\top v_j$.
- **Tại sao mạnh:** định lý đảm bảo tính phổ quát, không có thông tin bất biến nào bị bỏ sót.
- **Với hàm tương biến $O(d)$:** mở rộng thêm tổng tuyến tính của các vector:
 $f(v_1, \dots, v_n) = h(\{v_i^\top v_j\}) \cdot \sum_t v_t$.
- **Với tính bất biến tịnh tiến:** chỉ cần chuyển sang hệ tọa độ tương đối:
 $f(v_1, \dots, v_n) = h(v_2 - v_1, v_3 - v_1, \dots, v_n - v_1)$.
- **Thực tiễn:** hàm h được tham số hóa bởi một mạng nơ-ron thông thường đặt trên đầu các đặc trưng bất biến đã tính sẵn.

3.2.4. Phương pháp tensor và giới hạn của bổ đề Schur

Vấn đề: tại sao lớp tuyến tính tương biến đơn thuần không đủ?

- Mạng nhiều lớp tuyến tính tương biến xen kẽ hàm kích hoạt đặt ra câu hỏi: liệu có đủ sức biểu diễn để xấp xỉ mọi hàm tương biến liên tục không?
- **Bổ đề Schur** từ lý thuyết biểu diễn nhóm chỉ ra: với một số nhóm liên tục, các ánh xạ tuyến tính tương biến bị hạn chế nghiêm trọng.

Ví dụ 3.3. Với nhóm xoay $SO(2)$ tác động trên $\mathbb{R}^2$, ánh xạ tuyến tính tương biến duy nhất là bội của ma trận đơn vị: $L(x) = \lambda x$, $\lambda \in \mathbb{R}$. Lớp tuyến tính tương biến không thể tạo ra bất kỳ biểu diễn phong phú nào.

Giải pháp: nâng đầu vào lên không gian tensor.

Thay vì làm việc trực tiếp với $x \in \mathbb{R}^d$, ta dùng lũy thừa tensor bậc k :

$$x^{\otimes k} = \underbrace{x \otimes x \otimes \cdots \otimes x}_{k \text{ lần}} \in (\mathbb{R}^d)^{\otimes k} \quad (3.11)$$



không gian biểu diễn phong phú với k đủ lớn


Hình 3.9: Phương pháp tensor: nâng đầu vào lên không gian tensor bậc k để vượt qua giới hạn của bổ đề Schur và đạt được tính phổ quát.

- Không gian tensor $(\mathbb{R}^d)^{\otimes k}$ có cấu trúc biểu diễn nhóm vô cùng phong phú, vượt qua giới hạn của bổ đề Schur.
- Xây dựng MLP tương biến trên $x^{\otimes k}$ đạt được tính phổ quát khi k đủ lớn.
- **Thách thức kỹ thuật:** phân rã biểu diễn nhóm trên $(\mathbb{R}^d)^{\otimes k}$ đòi hỏi tính toán hệ số Clebsch-Gordan.
 - Với nhóm xoay $SO(d)$ và phản chiếu $O(d)$: giải được hiệu quả.
 - Với các nhóm hữu hạn tổng quát: là bài toán khó nổi tiếng trong lý thuyết biểu diễn.

3.2.5. Ứng dụng: mạng đồ thị tương biến và bài toán hệ nguyên tử

Bài toán và cấu trúc dữ liệu.

- Một hệ nguyên tử gồm N nguyên tử được biểu diễn dưới dạng một đồ thị có định hướng.
- Mỗi nút i mang: đặc trưng loại nguyên tử $h_i \in \mathbb{R}^c$ (vô hướng) và tọa độ không gian $\mathbf{r}_i \in \mathbb{R}^3$ (vector).
- Bài toán yêu cầu dự đoán năng lượng toàn phần E của hệ, vốn là một hàm bất biến với nhóm Euclide $E(3)$ gồm phép xoay, phản chiếu và tịnh tiến, đồng thời bất biến với mọi phép hoán vị nguyên tử cùng loại.




Hình 3.10: Minh họa bài toán hệ nguyên tử: phân tử H_2O được biểu diễn dưới dạng đồ thị. Mỗi nút mang đặc trưng vô hướng h_i (loại nguyên tử) và tọa độ vector $\mathbf{r}_i$. Mô hình cần dự đoán năng lượng E bất biến với mọi phép biến đổi $E(3)$.

Cơ chế truyền thông tin tương biến.

Mạng nơ-ron tương biến cập nhật lặp lại cả đặc trưng ẩn $h_i^{(\ell)}$ lẫn tọa độ $\mathbf{x}_i^{(\ell)}$ tại mỗi lớp ℓ , đảm bảo toàn bộ quá trình tương biến với $E(3)$:

$$\mathbf{x}_i^{(\ell+1)} = \mathbf{x}_i^{(\ell)} + C \sum_{j \neq i} \left(\mathbf{x}_i^{(\ell)} - \mathbf{x}_j^{(\ell)} \right) \cdot \varphi \left(h_i^{(\ell)}, h_j^{(\ell)}, \left\| \mathbf{x}_i^{(\ell)} - \mathbf{x}_j^{(\ell)} \right\|^2, a_{ij} \right) \quad (3.12)$$

trong đó φ là một mạng nơ-ron nhỏ và a_{ij} là đặc trưng cạnh bổ sung.




Hình 3.11: Cơ chế cập nhật tương biến: hàm message φ chỉ nhận khoảng cách bình phương $\|\mathbf{x}_i - \mathbf{x}_j\|^2$ (một đại lượng bất biến) thay vì tọa độ tuyệt đối, đảm bảo kết quả tương biến với nhóm $E(3)$.

- Hàm φ chỉ nhận **khoảng cách bình phương** $\|\mathbf{x}_i - \mathbf{x}_j\|^2$, một đại lượng bất biến với $E(3)$, thay vì tọa độ tuyệt đối.
- Cập nhật tọa độ theo hướng $(\mathbf{x}_i - \mathbf{x}_j)$ đảm bảo đầu ra tương biến: xoay đầu vào thì đầu ra cũng xoay theo đúng cách đó.
- Đặc trưng vô hướng h_i và tọa độ vector $\mathbf{x}_i$ được cập nhật đồng thời qua nhiều lớp, làm giàu dần biểu diễn.

Lợi ích đặc biệt: tính toán lực miễn phí qua vi phân tự động.

Sau khi mô hình dự đoán được năng lượng E , lực tác dụng lên từng nguyên tử thu được hoàn toàn miễn phí:

$$\mathbf{F}_i = -\frac{\partial E}{\partial \mathbf{r}_i} \quad (3.13)$$



Hình 3.12: Sơ đồ tính lực qua vi phân tự động: mô hình chỉ được huấn luyện dự đoán năng lượng E (vô hướng), nhưng đồng thời cung cấp $3N$ thành phần lực vector nhất quán và đảm bảo tính đối xứng.

- Mô hình chỉ cần học dự đoán một đại lượng vô hướng (năng lượng), nhưng đồng thời cung cấp dự đoán cho $3N$ thành phần lực vector.
- Các lực này **nhất quán** với nhau và với năng lượng theo định luật bảo toàn, vì chúng đến từ cùng một hàm thế năng.
- Đây là lợi thế quyết định so với các mô hình dự đoán lực trực tiếp, vốn không đảm bảo tính nhất quán.

Ứng dụng mở rộng. Nguyên lý tương biến $E(3)$ trong mạng đồ thị không chỉ giới hạn ở hệ nguyên tử, mà còn được áp dụng rộng rãi trong:

- **Sinh protein:** các mô hình Chroma và RFDiffusion dùng GNN tương biến kết hợp với hệ tọa độ địa phương để tạo sinh cấu trúc protein.
- **Dự đoán liên kết phân tử:** tương biến $SE(3)$ cho phép mô hình nắm bắt hướng và hình dạng của túi liên kết kháng nguyên-kháng thể.
- **Điều khiển robot:** tương biến $SO(2)/SE(3)$ trong học tăng cường cho phép chính sách tối ưu tự động điều chỉnh khi robot bị xoay hoặc dịch chuyển trong không gian (được trình bày chi tiết ở Mục 3.3).

3.3 Ứng dụng: Equivariance trong Robotics

3.4 Giới hạn: Vấn đề Symmetry Breaking



3.5 So sánh hai hướng tiếp cận



Chương
4

Lý thuyết nâng cao và các hướng nghiên cứu mới

4.1 Lợi ích về độ phức tạp mẫu (Sample Complexity Gains)

Trong thực tiễn, các mô hình học máy tích hợp tính đối xứng thường đạt hiệu suất cao hơn nhờ yêu cầu lượng dữ liệu huấn luyện ít hơn đáng kể. Dưới góc độ lý thuyết, điều này được chứng minh bằng toán học thông qua sự giảm thiểu độ phức tạp mẫu (Sample Complexity).

Cụ thể, giả sử dữ liệu đầu vào nằm trên một đa tạp compact M có số chiều d và hàm mục tiêu cần học có tính bất biến với nhóm G . Dựa trên định luật Weyl mở rộng (Extended Weyl's Law) áp dụng cho các phương pháp phổ trên đa tạp, sai số tổng quát hóa được chứng minh:

$$\mathbb{E}[\|\hat{f} - f_{\star}\|_2^2] \lesssim \left(\frac{C_d \text{vol}(M/G)}{n} \right)^{\frac{s}{s+d'}} \quad (4.1)$$

Trong đó $d' = \dim(M) - \dim(G)$ là số chiều hiệu dụng sau khi loại bỏ bậc tự do nhờ đối xứng, và s là bậc Sobolev. Kết quả này là minimax optimal.

4.2 Giải quyết chi phí tính toán bằng Expanders

Để giải quyết vấn đề này, lý thuyết đồ thị Cayley ngẫu nhiên (Expanders) đã được áp dụng. Các nghiên cứu chứng minh rằng ta hoàn toàn không cần duyệt qua toàn bộ nhóm G . Thay vào đó, chỉ cần lấy mẫu một tập hợp con ngẫu nhiên $\mathcal{S} \subset G$ có kích thước $|\mathcal{S}| = \mathcal{O}(\log |G|)$ là đủ.



4.3 Kiểm định tính đối xứng trong dữ liệu (Symmetry Testing)

4.4 Tính đối xứng tham số mạng nơ-ron (Neural Parameter Symmetries)

Góc nhìn của Geometric Machine Learning không chỉ dừng lại ở dữ liệu đầu vào mà còn được mở rộng vào sâu bên trong không gian tham số của chính mạng nơ-ron. Bản thân cấu trúc trọng số của các mạng học sâu chứa đựng rất nhiều tính đối xứng nội tại:

- **Bất biến hoán vị (Permutation Invariance):** Hoán đổi hai nơ-ron ẩn (kèm theo trọng số kết nối) không thay đổi hàm tính toán đầu ra.
- **Bất biến tỷ lệ (Scale Invariance):** Với hàm kích hoạt thuần nhất như ReLU, nhân lớp trước với α và chia lớp sau cho α cho kết quả giống hệt.
- **Bất biến $GL(r)$ trong Attention và LoRA:** $UV^T = UR \cdot R^{-1}V^T$ cho bất kỳ ma trận khả nghịch R .

4.5 Cảnh quan hàm mất mát và Gộp mô hình

Sự tồn tại của các đối xứng tham số dẫn đến một hệ quả quan trọng về cảnh quan hàm mất mát. Rất nhiều điểm cực tiểu cục bộ thực chất chỉ là các phiên bản hoán vị của cùng một trạng thái tối ưu. Điều này mở ra hiện tượng **Kết nối các điểm cực tiểu** (Mode Connectivity), cho phép các điểm cực tiểu được nối bằng các đường cong có giá trị hàm mất mát thấp liên tục.

Gộp mô hình (Model Merging / Git Re-Basin): Thay vì huấn luyện lại, ta dùng các phép hoán vị để “căn chỉnh” (align) các mạng về chung một thung lũng cực tiểu. Sau khi căn chỉnh, lấy trung bình trọng số tạo ra mô hình mới thừa hưởng sức mạnh của tất cả các mô hình gốc.



4.6 Học trên không gian trọng số (Weight Space Learning)

Xu hướng **Học trên không gian trọng số (Weight Space Learning)** đang nổi lên như một hướng đi tiên phong trong kỷ nguyên Foundation Models. Thay vì nhận dữ liệu hình ảnh hay văn bản, các “Siêu mạng” (Metanetworks) sử dụng chính bộ trọng số của các mạng nơ-ron khác làm dữ liệu đầu vào. Việc thiết kế Metanetworks equivariant cho phép đánh giá tốc độ hội tụ, kiểm tra bản quyền, hoặc tinh chỉnh trực tiếp các mô hình ngôn ngữ lớn (LLMs) nhanh hơn hàng chục nghìn lần so với phương pháp truyền thống.

4.7 Đối xứng linh hoạt và Khám phá đối xứng

4.8 Mô hình bất kỳ chiều (Any-dimensional Models)

4.9 Hình học vượt đối xứng: Topology và Curvature



Chương 5

Thực nghiệm và Demo minh họa

5.1 Bài toán và Tập dữ liệu

5.2 Mô tả mô hình cài đặt

5.3 Môi trường thực nghiệm

5.4 Kết quả và Phân tích



Chương 6

Đánh giá và Kết luận

- 6.1 Thảo luận: Có nên luôn mã hóa tính đối xứng?
- 6.2 Ưu điểm và Hạn chế của Geometric Machine Learning
- 6.3 Các hướng nghiên cứu tương lai
- 6.4 Kết luận
- 6.5 Phân công nhiệm vụ và Tự đánh giá



Phụ lục: Phân công công việc nhóm



Tài liệu tham khảo

- [1] S. Jegelka and B. Tahmasebi, “Recent developments in geometric machine learning: Foundations, models, and more,” Tutorial at NeurIPS 2025, San Diego, CA, 2025.
- [2] S.-O. Kaba, A. K. Mondal, Y. Zhang, Y. Bengio, and S. Ravanbakhsh, “Equivariance with learned canonicalization functions,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [3] O. Puny, M. Atzmon, E. J. Smith, I. Misra, A. Grover, H. Ben-Hamu, and Y. Lipman, “Frame averaging for invariant and equivariant network design,” in *International Conference on Learning Representations (ICLR)*, 2022. [Online]. Available: <https://openreview.net/forum?id=zIUyj55nXR>