

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN, ĐHQG-HCM
KHOA CÔNG NGHỆ THÔNG TIN



Nhập môn học máy

BÁO CÁO ĐỒ ÁN 3

CÁC BƯỚC TIỀN MỞI TRONG GEOMETRIC MACHINE LEARNING

Giảng viên hướng dẫn: ThS. Lê Nhựt Nam

Sinh viên:	23120195	Lê Hà Thanh Chương
	23120197	Trà Văn Sỹ
	23120199	Huỳnh Đức Thịnh
	23120257	Bùi Trung Hiếu
	23120330	Lê Công Phúc

TP. HỒ CHÍ MINH, THÁNG 6 NĂM 2026



Mục lục

Danh sách các hình	vi
Danh sách các bảng	ix
Danh sách các ký hiệu và chữ viết tắt	x
Danh mục các thuật ngữ	xv
Lời mở đầu	1
1 Giới thiệu	2
1.1 Bối cảnh và động lực thực hiện	2
1.1.1 Vấn đề phân mảnh kiến trúc và lời nguyên đa chiều	2
1.1.2 Tính đối xứng tham số và học không gian trọng số	3
1.1.3 Ý nghĩa và tầm quan trọng thực tiễn	3
1.2 Kỷ nguyên của dữ liệu hình học	4
1.3 Sự dịch chuyển sang không gian trọng số	5
1.4 Mục tiêu và phạm vi của đề án	6
1.4.1 Mục tiêu nghiên cứu	6
1.4.2 Phạm vi và cấu trúc báo cáo	7
2 Kiến thức nền tảng	9
2.1 Khái niệm về đối xứng, bất biến và tương biến	9
2.1.1 Tính bất biến	9
2.1.2 Tính đẳng biến / tương biến	11
2.1.3 Vì sao tính đối xứng lại quan trọng?	13
2.2 Cơ sở lý thuyết nhóm	14
2.2.1 Tác động nhóm và biểu diễn nhóm	15
2.2.2 Quỹ đạo	16
2.2.3 Phát biểu hình thức của bất biến và đẳng biến	17
3 Các phương pháp xây dựng mô hình bảo toàn tính đối xứng	18
3.1 Hướng 1: Can thiệp dữ liệu trên các mô hình có sẵn	18



3.1.1	Tăng cường dữ liệu	18
3.1.2	Chuẩn hóa	22
3.1.3	Lấy trung bình nhóm	26
3.1.4	Lấy trung bình khung	28
3.2	Hướng 2: Xây dựng kiến trúc tương biến từ đầu	30
3.2.1	Lớp tuyến tính tương biến và cơ chế chia sẻ tham số	31
3.2.2	Tích chập nhóm	33
3.2.3	Lý thuyết bất biến và tham số hóa qua đại lượng bất biến	34
3.2.4	Phương pháp tensor và giới hạn của bổ đề Schur	35
3.2.5	Ứng dụng: mạng đồ thị tương biến và bài toán hệ nguyên tử	36
3.3	NequIP: Mạng nơ-ron đồ thị tương biến cho thể năng nguyên tử	38
3.3.1	Bài toán và động lực nghiên cứu	38
3.3.2	Kiến trúc NequIP và cơ chế tương biến	39
3.3.3	Kết quả thực nghiệm và hiệu quả dữ liệu	40
3.4	PointNet: Học sâu trên tập hợp điểm cho bài toán ba chiều	42
3.4.1	Bài toán và động lực nghiên cứu	42
3.4.2	Ba đặc tính cốt lõi của dữ liệu đám mây điểm	43
3.4.3	Kiến trúc PointNet và cơ chế hoạt động	43
3.4.4	Khung xương vật thể và tính bền vững	44
3.4.5	Đánh giá hiệu năng và độ phức tạp tính toán	44
3.5	Ứng dụng: Equivariance trong Robotics	45
3.6	Giới hạn: Vấn đề phá vỡ tính đối xứng	49
3.7	So sánh hai hướng tiếp cận	50
4	Lý thuyết nâng cao và các hướng nghiên cứu mới	53
4.1	Lợi ích về độ phức tạp mẫu	53
4.1.1	Động lực: một lý thuyết cần đủ tổng quát	53
4.1.2	Thiết lập bài toán: hồi quy Sobolev bất biến	54
4.1.3	Kết quả chính: hai trục giảm độ phức tạp mẫu	54
4.1.4	Trực giác hình học: phép phản xạ trên vòng tròn	55
4.1.5	Ý tưởng chứng minh: định luật Weyl mở rộng	56
4.1.6	Mở rộng và liên hệ với các kết quả khác	57
4.2	Giải quyết chi phí tính toán bằng Expanders	59
4.2.1	Tập sinh và tiết kiệm theo hàm mũ	59
4.2.2	Đồ thị Cayley ngẫu nhiên và expander	60
4.2.3	Ứng dụng trong học máy hình học	61



4.2.4	Phân biệt giữa bất biến chính xác và bất biến xấp xỉ	62
4.3	Kiểm định tính đối xứng trong dữ liệu	63
4.3.1	Phát biểu bài toán kiểm định	63
4.3.2	Độ khó tính toán	64
4.3.3	Giải pháp ngẫu nhiên hóa	64
4.3.4	Thuật toán tất định khai thác cấu trúc nhóm	65
4.3.5	Ý nghĩa đối với học máy hình học	66
4.4	Tính đối xứng tham số mạng nơ-ron	66
4.4.1	Các dạng đối xứng tham số phổ biến	67
4.4.2	Hệ quả thực tiễn	67
4.5	Tổng quan hàm mất mát và gộp mô hình	68
4.5.1	Mode connectivity và đối xứng liên tục	68
4.5.2	Đối xứng rời rạc và các bản sao cực tiểu	69
4.5.3	Gộp mô hình thông qua căn chỉnh orbit	70
4.5.4	Ứng dụng trong tối ưu hóa và suy luận	71
4.6	Học trên không gian trọng số	71
4.6.1	Động lực: kho mô hình như dữ liệu	71
4.6.2	Các tác vụ trên không gian trọng số	72
4.6.3	Kiến trúc tương biến cho không gian trọng số	73
4.6.4	Thách thức về mở rộng và căn chỉnh	73
4.7	Đối xứng linh hoạt và khám phá đối xứng	74
4.7.1	Hạn chế của việc mã hóa cứng đối xứng	74
4.7.2	Lựa chọn đối xứng theo ngữ cảnh	74
4.7.3	Khám phá đối xứng từ dữ liệu	75
4.8	Mô hình không phụ thuộc số chiều	76
4.8.1	Nền tảng lý thuyết	76
4.8.2	Ý nghĩa đối với khả năng ngoại suy kích thước	77
4.8.3	Câu hỏi mở	77
4.9	Hình học vượt đối xứng: Topology và Curvature	77
4.9.1	Topological Deep Learning	78
4.9.2	Lý thuyết học và độ cong	78
5	Thực nghiệm và kết quả	80
5.1	Tổng quan thực nghiệm	80
5.2	Hiệu quả dữ liệu và định luật tỷ lệ	80
5.3	Thực nghiệm về xấp xỉ lấy trung bình nhóm	81



5.4	Học không gian trọng số thông qua mạng meta	82
5.5	Tổng quan hàm mất mát và kỹ thuật gộp mô hình	83
5.6	Kiểm định tính đối xứng của dữ liệu và quan sát trên tập QM9	84
6	Đánh giá và kết luận	87
6.1	Thảo luận: Có nên luôn dùng mô hình equivariant?	87
6.1.1	Xét về quy mô dữ liệu và scaling laws	87
6.1.2	Loại đối xứng trong dữ liệu	88
6.1.3	Tính đa năng so với chuyên môn hóa	88
6.2	Tổng hợp ưu điểm và hạn chế	89
6.3	Các hướng nghiên cứu tương lai	90
6.3.1	Cởi mở hơn với tính đối xứng	90
6.3.2	Mô hình không phụ thuộc số chiều	90
6.3.3	Kiểm định tính đối xứng	90
6.3.4	Học trên không gian trọng số	91
6.3.5	Topo học và độ cong	91
6.4	Kết luận	91
7	Demo minh họa	93
7.1	Tổng quan thực nghiệm	93
7.2	Demo thực nghiệm Part 1: Nhận diện chữ số viết tay bất biến với phép xoay	95
7.2.1	Kiến trúc nền chung	95
7.2.2	Baseline CNN	95
7.2.3	Augmented CNN	96
7.2.4	Frame Averaging CNN	96
7.3	Demo thực nghiệm Part 2: Phân loại đám mây điểm ba chiều với PointNet	97
7.3.1	Dữ liệu và tiền xử lý	98
7.3.2	Hai biến thể PointNet được so sánh	98
7.3.3	Thiết lập huấn luyện và kết quả	99
7.3.4	Kiểm tra tính bất biến hoán vị	100
7.3.5	Robustness và critical points	100
7.4	Demo thực nghiệm Part 3: Dự đoán năng lượng phân tử với NequIP	101
7.4.1	Bài toán và tính bất biến $E(3)$	102
7.4.2	Dữ liệu và thiết lập thực nghiệm	102
7.4.3	Kiến trúc NequIP	103
7.4.4	Luồng inference trong demo	105



7.4.5	So sánh bất biến và đẳng biến: hiệu quả dữ liệu	105
7.5	Thảo luận chung và liên kết lý thuyết	107
7.5.1	Tính bất biến xấp xỉ và tính bất biến do kiến trúc	107
7.5.2	Hiệu quả dữ liệu và giới hạn của demo	107
7.5.3	Đối chiếu hai hướng tiếp cận	108
Phụ lục: Phân công công việc nhóm		110
Tài liệu tham khảo		113



Danh sách các hình

1.1	Phân loại các miền hình học theo khung 5G	4
1.2	Sơ đồ giao hoán toán học	5
2.1	Bất biến với phép tịnh tiến	10
2.2	Bất biến với phép hoán vị	10
2.3	Đẳng biến hoán vị của GNN	11
2.4	Đẳng biến $SE(3)$ trong dự đoán lực phân tử.	12
2.5	Sơ đồ giao hoán của bất biến và đẳng biến	13
2.6	Minh họa tác động của ba nhóm tiêu biểu	15
2.7	Tác động hoán vị lên một mảng	16
2.8	Quỹ đạo của một điểm dưới nhóm C_4	16
2.9	Trực quan bất biến và đẳng biến	17
3.1	Sơ đồ giao hoán của học biểu diễn equivariant	20
3.2	Pipeline chuẩn hóa	23
3.3	Chuẩn hóa mảng 1 chiều	24
3.4	Minh họa sự phá vỡ tính liên tục trong chuẩn hóa nhiều chiều	24
3.5	Minh họa tính chất equivariance của hàm khung	29
3.6	Cấu trúc tổng quát của mô hình tương biến: xen kẽ các lớp tuyến tính tương biến với hàm kích hoạt phi tuyến σ , kết thúc bằng một lớp gộp bất biến toàn cục.	31
3.7	Ma trận trọng số $\mathbf{W}$ sau khi áp ràng buộc tương biến với nhóm dịch chuyển tuần hoàn C_5 . Các ô cùng màu chia sẻ cùng một giá trị tham số. Cấu trúc này chính xác là ma trận circulant của phép tích chập.	32
3.8	Ma trận trọng số $\mathbf{W}$ sau khi áp ràng buộc tương biến với nhóm hoán vị S_n . Toàn bộ ma trận $n \times n$ chỉ còn 2 giá trị: α_1 trên đường chéo và α_2 ở tất cả vị trí còn lại.	32
3.9	So sánh tích chập thông thường và tích chập nhóm. Tích chập nhóm là sự tổng quát hóa trực tiếp: thay vì chỉ trượt theo phép tịnh tiến, bộ lọc được trượt qua toàn bộ các phần tử của nhóm G	33
3.10	Minh họa định lý cơ bản: mọi hàm bất biến với $O(d)$ đều có thể được tính từ ma trận Gram của các tích vô hướng, bất kể số chiều d hay số điểm n . .	34



3.11	Phương pháp tensor: nâng đầu vào lên không gian tensor bậc k để vượt qua giới hạn của bổ đề Schur và đạt được tính phổ quát.	35
3.12	Minh họa bài toán hệ nguyên tử: phân tử H_2O được biểu diễn dưới dạng đồ thị. Mỗi nút mang đặc trưng vô hướng h_i (loại nguyên tử) và tọa độ vector $\mathbf{r}_i$. Mô hình cần dự đoán năng lượng E bất biến với mọi phép biến đổi $E(3)$	36
3.13	Cơ chế cập nhật tương biến: hàm message φ chỉ nhận khoảng cách bình phương $\ \mathbf{x}_i - \mathbf{x}_j\ ^2$ (một đại lượng bất biến) thay vì tọa độ tuyệt đối, đảm bảo kết quả tương biến với nhóm $E(3)$	37
3.14	Sơ đồ tính lực qua vi phân tự động: mô hình chỉ được huấn luyện dự đoán năng lượng E (vô hướng), nhưng đồng thời cung cấp $3N$ thành phần lực vector nhất quán và đảm bảo tính đối xứng.	37
3.15	Luồng dữ liệu qua ba khối chính của mô hình NequIP.	39
3.16	Quy trình tính lực qua vi phân tự động trong NequIP.	40
3.17	Minh họa đường cong học tập của NequIP so với các mô hình tiêu biểu trên bài toán mô phỏng nước.	41
3.18	Luồng trích xuất đặc trưng toàn cục của PointNet.	43
3.19	Mô phỏng nguyên lý của mạng lưới.	44
3.20	Tính nhất quán hình học giữa state và action trong robot manipulation.	45
3.21	Phân loại symmetry group theo bậc tự do của bài toán robot manipulation.	47
3.22	Minh họa sự cản trở của vấn đề phá vỡ đối xứng.	50
4.1	Phản xạ qua trục tung gập vòng tròn thành nửa vòng tròn, chỉ một nửa số Fourier modes còn lại nên $\text{vol}(M/G) = \frac{1}{2}\text{vol}(M)$	56
4.2	Cùng một mức sai số mục tiêu, mô hình bất biến đạt được với số mẫu nhỏ hơn, và nhóm đối xứng càng lớn thì đường cong càng dốc.	58
4.3	Minh họa đồ thị Cayley sinh bởi một tập con $\mathcal{S}$	61
4.4	Quy trình kiểm định tính đối xứng ở cấp độ phân bố	64
4.5	Minh họa lợi ích của việc khai thác cấu trúc nhóm	66
4.6	Minh họa ảnh hưởng của đối xứng hoán vị đối với gộp mô hình	70
4.7	Khái quát học trên không gian trọng số	72
4.8	Minh họa đối xứng phụ thuộc ngữ cảnh. Biến ngữ cảnh xác định nhóm con phù hợp, sau đó mô hình chỉ cần tương biến với nhóm con đó thay vì toàn bộ nhóm ban đầu.	75
4.9	Minh họa cấu trúc topo học bậc cao.	78



5.1	Đường cong định luật tỷ lệ so sánh giữa mô hình cơ sở và mô hình tương biến	81
5.2	Khắc phục rào cản hàm mất mát thông qua căn chỉnh hoán vị Git Re-Basin	84
5.3	Quan sát thực nghiệm cho thấy các phân tử trong tập QM9 và rMD17 phần lớn đã được chuẩn hóa hệ tọa độ ngầm định	85
6.1	Tác động của tính đối xứng lên scaling laws	88
6.2	Sáu hướng nghiên cứu mở trong Geometric Machine Learning	91
7.1	So sánh trực giác giữa ba hướng xử lý phép xoay trong demo MNIST.	97
7.2	Năm lớp point cloud được sử dụng trong demo Part 2.	98
7.3	Đường cong huấn luyện của hai biến thể PointNet trên tập 5 lớp.	99
7.4	Minh họa critical points được trích xuất từ PointNet trên point cloud mẫu.	101
7.5	Minh họa xu hướng robustness của PointNet khi point cloud chịu perturbation.	101
7.6	Bảy phân tử mẫu cài sẵn trong demo Part 3	103
7.7	Luồng chuyển đổi từ dữ liệu người dùng nhập vào đến đầu ra năng lượng U_0 .	105
7.8	Đường học log-log của hai cấu hình NequIP trên QM9	105
7.9	Đường cong huấn luyện bốn thí nghiệm NequIP	106



Danh sách các bảng

2.1	So sánh hai loại đối xứng cơ bản.	17
3.1	So sánh ba phương pháp can thiệp dữ liệu để đưa tính đối xứng vào mạng neural. Lấy trung bình khung nổi lên như một điểm cân bằng hoàn hảo giữa chi phí triển khai thực tế và sức mạnh lý thuyết toán học.	30
3.2	Bảng tổng hợp đối chiếu ưu nhược điểm giữa phương pháp hộp đen (Hướng 1) và phương pháp xây dựng từ lỗi (Hướng 2).	51
4.1	Hai cơ chế giảm độ phức tạp mẫu theo loại nhóm tác động	55
4.2	Ánh xạ một số mô hình bất biến quen thuộc vào khung lý thuyết đa tạp và nhóm tác động.	58
5.1	Hiệu suất dự đoán của mạng meta trên không gian trọng số LoRA. Các mô hình nhận thức đối xứng (Invariant) hoạt động ổn định, trong khi mô hình Naive dễ gặp lỗi OOM.	83
6.1	Tóm tắt ưu nhược điểm của geometric machine learning	89
7.2	Tổng quan ba demo thực nghiệm và liên kết với các phân tích lý thuyết trong đề án.	93
7.4	Tổng hợp đặc tính của ba mô hình trong demo Part 1.	97
7.6	Kết quả huấn luyện hai biến thể PointNet.	100
7.7	Kết quả kiểm tra tính bất biến hoán vị của PointNetFull.	100
7.8	Siêu tham số của mô hình NequIP triển khai trong demo Part 3.	104
7.10	Đối chiếu ba demo thực nghiệm qua lăng kính ba hướng tiếp cận geometric machine learning.	108
7.12	Bảng tự đánh giá mức độ đóng góp	112



Danh sách các ký hiệu và chữ viết tắt

Ký hiệu / Viết tắt	Ý nghĩa
Chữ viết tắt	
ADF	Hàm phân bố góc (Angular Distribution Function)
API	Giao diện lập trình ứng dụng (Application Programming Interface)
ARC-C	Đánh giá suy luận logic (AI2 Reasoning Challenge)
AUC	Diện tích dưới đường cong ROC (Area Under the Curve)
CCSD(T)	Phương pháp cụm liên kết với kích thích đơn, đôi và nhiễu loạn ba (Coupled Cluster Single Double and Perturbative Triple)
CNN	Mạng nơ-ron tích chập (Convolutional Neural Network)
DA	Tăng cường dữ liệu (Data Augmentation)
DFT	Lý thuyết phiếm hàm mật độ (Density Functional Theory)
DQN	Deep Q-Network, thuật toán học tăng cường dựa trên xấp xỉ Q -function bằng mạng nơ-ron
FLOPs	Số phép toán dấu phẩy động mỗi giây / Chi phí tính toán (Floating Point Operations Per Second)
GDL	Học sâu hình học (Geometric Deep Learning)
GML	Học máy hình học (Geometric Machine Learning)
GNN	Mạng nơ-ron đồ thị (Graph Neural Network)
KRR	Hồi quy kernel ridge (Kernel Ridge Regression)
LLM	Mô hình ngôn ngữ lớn (Large Language Model)
LoRA	Kỹ thuật tinh chỉnh tham số thấp (Low-Rank Adaptation)
MD-17 / rMD-17	Tập dữ liệu động lực học phân tử
MDP	Quá trình quyết định Markov (Markov Decision Process)
MLP	Mạng nơ-ron truyền thẳng đa lớp / Perceptron đa lớp (Multi-Layer Perceptron)



Ký hiệu / Viết tắt	Ý nghĩa (tiếp theo)
MVCNN	Mạng chập đa góc nhìn (Multi-view Convolutional Neural Network)
NequIP	Tên một kiến trúc mạng nơ-ron đồ thị tương biến
NP-hard	Bài toán siêu khó đa thức (Non-deterministic Polynomial-time hard)
OOD	Ngoài phân phối (Out-of-Distribution)
OOM	Lỗi tràn bộ nhớ (Out of Memory)
PCA	Phân tích thành phần chính (Principal Component Analysis)
QM9	Tập dữ liệu lượng tử phân tử quy mô 9 nguyên tử nặng
RDF	Hàm phân bố xuyên tâm (Radial Distribution Function)
ResNet	Mạng nơ-ron phần dư (Residual Network)
RKHS	Không gian Hilbert tái sinh (Reproducing Kernel Hilbert Space)
RNN	Mạng nơ-ron hồi quy (Recurrent Neural Network)
SAC	Soft Actor-Critic, thuật toán actor-critic có entropy regularization
SiLU	Hàm kích hoạt tuyến tính sigmoid (Sigmoid Linear Unit)
SSL	Học tự giám sát (Self-Supervised Learning)
Không gian, tập hợp và cấu trúc hình học	
$\mathbb{R}$	Tập hợp các số thực
(M, g)	Đa tạp Riemann compact, liên thông, không biên với metric g
$\mathcal{X}$	Không gian dữ liệu / không gian đầu vào
$\mathcal{Y}$	Không gian đầu ra của mô hình
$\mathcal{H}$	Không gian Hilbert tái sinh của kernel Sobolev
$H_{\text{inv}}^s(M)$	Không gian Sobolev bậc s gồm các hàm bất biến trên M
M/G	Không gian thương gồm các quỹ đạo $[x] = \{\tau(x) : \tau \in G\}$
$\text{Orb}_G(x)$	Quỹ đạo của x dưới tác động của G : tập $\{g \cdot x \mid g \in G\}$
$\mathcal{P}_n$	Tập các ma trận hoán vị kích thước n
$\mathcal{F}(X)$	Tập hợp khung (Frame) trích xuất từ điểm dữ liệu X



Ký hiệu / Viết tắt	Ý nghĩa (tiếp theo)
Nhóm đối xứng và tác động nhóm	
G	Nhóm đối xứng (tác động lên đa tạp M , không gian trạng thái, hoặc hành động)
$\mathcal{G}$	Nhóm đối xứng toàn cục
g	Một phần tử thuộc nhóm đối xứng G , đại diện cho một phép biến đổi
$g \cdot x$	Tác động của phần tử g lên điểm dữ liệu x
S_n	Nhóm hoán vị n phần tử
C_n, C_4	Nhóm xoay tuần hoàn; C_4 gồm bốn phép quay cách nhau 90°
$SO(d)$	Nhóm quay đặc biệt trong $\mathbb{R}^d$ ($SO(2)$ cho phép xoay trong mặt phẳng)
$SE(2), SE(3)$	Nhóm Euclid đặc biệt trong 2D/3D (gồm các phép tịnh tiến và xoay)
$E(3)$	Nhóm đối xứng Euclid trong không gian ba chiều (quay, phản xạ, tịnh tiến)
$GL(V)$	Nhóm các ánh xạ tuyến tính khả nghịch trên không gian vector V
MDP, state, action và robotics	
$\mathcal{M}$	Quá trình quyết định Markov biểu diễn bài toán ra quyết định của robot
$\mathcal{S}$	Không gian trạng thái (State space) / Tập con được lấy mẫu ngẫu nhiên
$\mathcal{A}$	Không gian hành động (Action space) của MDP
$\mathcal{T}$	Hàm chuyển đổi trạng thái (Transition function) của MDP
$\mathcal{R}$	Hàm phần thưởng (Reward function) của MDP
γ	Hệ số chiết khấu (Discount factor) trong MDP
s	Trạng thái (State) của robot hoặc môi trường
a	Hành động (Action) của robot
$g \cdot s$	Trạng thái sau khi chịu tác động của phép biến đổi g
$g \cdot a$	Hành động sau khi chịu tác động của phép biến đổi g



Ký hiệu / Viết tắt	Ý nghĩa (tiếp theo)
π^*	Chính sách tối ưu (Optimal policy)
Q^*	Hàm giá trị hành động tối ưu (Optimal action-value function)
V^*	Hàm giá trị tối ưu (Optimal value function)
Toán tử, hàm số và phép toán	
f	Mô hình hoặc hàm ánh xạ từ đầu vào sang đầu ra
T, T'	Phép biến đổi trên không gian đầu vào và không gian đầu ra tương ứng
τ_v	Phép tịnh tiến theo vector v
P, P_σ	Mã trận hoán vị dùng để đánh số lại phần tử (hoặc biểu diễn hoán vị σ)
$\rho, \rho(g)$	Biểu diễn nhóm, ánh xạ phần tử nhóm thành phép biến đổi tuyến tính
ρ_1, ρ_2	Các biểu diễn nhóm (group representations)
$K(x, y)$	Hàm hạt nhân đánh giá sự tương đồng giữa hai điểm x và y
$f_\star$	Hàm mục tiêu bất biến / hàm sinh nhãn thật
$\hat{f}$	Hàm ước lượng học được từ dữ liệu huấn luyện
η	Tham số điều chuẩn trong hồi quy kernel ridge
$\text{vol}(M/G)$	Thể tích của không gian thương M/G
T_a, R_a	Phép biến đổi tuyến tính trong không gian ẩn tương ứng với phép tăng cường a
A	Mã trận biến đổi afin dự đoán bởi mạng học sâu (ví dụ T-Net)
$c(x)$	Dạng chuẩn (canonical form) của điểm dữ liệu x
$\mathcal{L}$	Hàm mất mát (Loss function)
$\langle \Phi \rangle_G$	Phép toán lấy trung bình nhóm (Group averaging)
$\langle \Phi \rangle_{\mathcal{F}}$	Phép toán lấy trung bình khung (Frame averaging)
L_{reg}	Hàm mất mát chính quy hóa (Regularization loss)
R^2	Hệ số xác định (đo lường độ phù hợp của mô hình)
Biến số, chỉ số và ký hiệu Hy Lạp	
n, N	Số lượng phần tử hoặc số lượng điểm đầu vào



Ký hiệu / Viết tắt	Ý nghĩa (tiếp theo)
H_0	Giả thuyết không trong kiểm định thống kê
H_1	Giả thuyết đối trong kiểm định thống kê
α	Biên an toàn (margin) / Giới hạn độ tin cậy / Ngưỡng kiểm soát tỷ lệ lỗi
d'	Số chiều hiệu dụng sau khi loại bỏ bậc tự do đối xứng ($d' = \dim(M) - \dim(G)$)
μ	Phân phối dữ liệu
ϵ_i	Nhiều quan sát của mẫu thứ i
σ^2	Phương sai của nhiều quan sát
σ	Một hoán vị, thường là phần tử của nhóm hoán vị S_n



Danh mục các thuật ngữ

Thuật ngữ tiếng Anh	Thuật ngữ tiếng Việt
Absolute convergence	Hội tụ tuyệt đối
Accepting path	Đường đi chấp nhận
Affine transformation	Phép biến đổi afin
Alternative hypothesis	Giả thuyết đối
Any-dimensional model	Mô hình đa chiều
Approximate group averaging	Xấp xỉ lấy trung bình nhóm
Autograd	Vi phân tự động
Baseline	Mô hình cơ sở
Canonical form / Canonicalization / Canonicalized	Dạng chuẩn / Tiêu chuẩn hóa / Chuẩn hóa
Clebsch-Gordan coefficient	Hệ số Clebsch-Gordan
Commutative diagram	Sơ đồ giao hoán
Compact Lie group	Nhóm Lie compact
Contrastive learning	Học tương phản
Coupled cluster	Phương pháp cụm liên kết
Critical points	Điểm tới hạn
Curse of dimensionality	Lời nguyền đa chiều
Cyclic group	Nhóm tuần hoàn
Data augmentation	Tăng cường dữ liệu
Data efficiency	Hiệu quả dữ liệu
Data membership	Thành viên dữ liệu
Density functional theory	Lý thuyết phiếm hàm mật độ
Divergence	Độ phân kỳ
Embedding	Nhúng
Epoch	Vòng lặp huấn luyện



Thuật ngữ tiếng Anh	Thuật ngữ tiếng Việt (tiếp theo)
Equivariance / Equivariant	Tính đẳng biến / Tương biến
Equivariant graph neural network	Mạng nơ-ron đồ thị tương biến
Equivariant layer	Lớp đồng biến tuyến tính
Equivariant Metanetworks / Meta-network	Mạng meta tương biến / Mạng meta
Euclidean group	Nhóm Euclid
Foundation model	Mô hình nền tảng
Frame averaging	Lấy trung bình khung / Trung bình hóa khung
Generator (of a group)	Tập sinh (của một nhóm)
Geometric Deep Learning	Học sâu Hình học
Global invariant pooling	Gộp bất biến toàn cục
Graph isomorphism	Đẳng cấu đồ thị
Grasp learning	Bài toán học cách xác định và thực hiện thao tác gấp vật thể
Group	Nhóm (đại số)
Group action	Tác động nhóm
Group averaging / Reynolds operator	Lấy trung bình nhóm / Toán tử Reynolds
Group representation	Biểu diễn nhóm
Interaction	Tương tác
Interatomic potential	Thế năng tương tác nguyên tử
Invariance	Tính bất biến
Kernel	Hàm nhân / Hàm hạt nhân
Latent space	Không gian ẩn
Learning curve	Đường cong học tập
Linear mode connectivity	Kết nối cực tiểu tuyến tính
Local pooling	Gộp cục bộ
Loss landscape	Cảnh quan hàm mất mát
Max pooling	Gộp cực đại



Thuật ngữ tiếng Anh	Thuật ngữ tiếng Việt (tiếp theo)
Mode connectivity	Sự kết nối cực tiểu
Monte Carlo	Phương pháp Monte Carlo
Null hypothesis	Giả thuyết không
Orbit	Quỹ đạo
Orthogonal matrix	Ma trận trực giao
Out of memory (OOM)	Lỗi tràn bộ nhớ
Out-of-distribution (OOD) generalization	Tổng quát hóa ngoài phân phối
Parameter space symmetry	Tính đối xứng không gian tham số
Partially equivariant model	Mô hình chỉ áp dụng equivariance cho một phần state/action phù hợp với đối xứng của bài toán
Permutation group	Nhóm hoán vị
Permutation symmetry	Đối xứng hoán vị
Point cloud	Đám mây điểm
Quotient space	Không gian thương
Representation learning	Học biểu diễn
Representer theorem	Định lý biểu diễn nghiệm
Reproducing kernel Hilbert space (RKHS)	Không gian Hilbert tái sinh
Riemannian manifold	Đa tạp Riemann
Robot manipulation	Bài toán điều khiển robot tương tác vật lý với vật thể
Robust frames	Khung bền vững
Robustness	Tính mạnh mẽ
Rotation group	Nhóm xoay
Sample complexity	Độ phức tạp mẫu
Sample-efficient learning	Khả năng học được chính sách tốt với ít dữ liệu hoặc ít lần tương tác hơn



Thuật ngữ tiếng Anh	Thuật ngữ tiếng Việt (tiếp theo)
Scaling laws	Định luật tỷ lệ
Self-supervised learning	Học tự giám sát
Set equivariance	Tương biến tập hợp
Sign-invariance	Bất biến lật dấu
Sobolev space	Không gian Sobolev
Spatial action space	Action space có cấu trúc không gian (gắn với vị trí, hướng)
Spectral averaging	Lấy trung bình phổ
Spherical harmonics	Hàm điều hòa cầu
Standard interpolation	Nội suy tiêu chuẩn
Symmetry	Tính đối xứng
Symmetry discovery	Khám phá đối xứng
Symmetry function	Hàm đối xứng
Symmetry testing	Kiểm định tính đối xứng
Teleportation	Dịch chuyển tham số
Tensor product	Tích tensor
Test loss	Hàm mất mát trên tập kiểm tra
Toy experiment	Thực nghiệm mô phỏng
Translation group	Nhóm tịnh tiến
Universal approximation	Xấp xỉ phổ quát
Weight space learning	Học không gian trọng số
Weighted frame	Khung có trọng số



Lời mở đầu

Đồ án của nhóm tập trung vào chủ đề *các bước tiến mới trong Geometric Machine Learning*, xuất phát từ thực trạng phân mảnh của lĩnh vực học sâu hiện đại, nơi các kiến trúc mạng nơ-ron được thiết kế riêng biệt cho từng định dạng dữ liệu mà thiếu đi một khung lý thuyết thống nhất. Mục tiêu cốt lõi là hệ thống hóa, phân tích và thực nghiệm các kỹ thuật tiên tiến nhất trong học máy hình học, lấy tính đối xứng làm nguyên lý trung tâm, cải thiện hiệu quả sử dụng dữ liệu và nâng cao khả năng tổng quát hóa ngoài phân phối.

Để hiện thực hóa mục tiêu trên, nhóm triển khai theo bốn trục nội dung có tính bổ trợ lẫn nhau. *Thứ nhất*, nền tảng lý thuyết toán học được thiết lập bao gồm lý thuyết nhóm, tác động nhóm, biểu diễn nhóm và hai khái niệm cốt lõi là bất biến và đẳng biến, cung cấp ngôn ngữ chính xác để mô tả các phép đối xứng trên dữ liệu hình học. *Thứ hai*, ba họ phương pháp xây dựng mô hình bảo toàn tính đối xứng được phân tích đối chiếu: tăng cường dữ liệu và học biểu diễn đẳng biến, chuẩn hóa kèm định lý bất khả thi của Dym et al. (2024) về tính liên tục, cùng với lấy trung bình nhóm và lý thuyết Frame Averaging của Puny et al. (2022) như một điểm cân bằng tối ưu giữa chi phí tính toán và đảm bảo đối xứng tuyệt đối. *Thứ ba*, lý thuyết nâng cao về lợi ích định lượng của tính đối xứng được trình bày, bao gồm kết quả minimax optimal về độ phức tạp mẫu của Tahmasebi & Jegelka (2023) trên đa tạp compact với nhóm Lie tùy ý, kỹ thuật giảm chi phí tính toán thông qua đồ thị Cayley và expander, kiểm định thống kê tính đối xứng trong dữ liệu, cũng như hướng nghiên cứu học không gian trọng số dựa trên đối xứng tham số. *Thứ tư*, ba demo tương tác được xây dựng để minh chứng thực nghiệm: nhận diện chữ số viết tay bất biến với phép xoay $SO(2)$ trên MNIST, phân loại đám mây điểm ba chiều bất biến hoán vị với PointNet trên ModelNet40, và dự đoán năng lượng phân tử bất biến $E(3)$ với NequIP trên tập con QM9.

Toàn bộ nội dung lý thuyết được xây dựng dựa trên tutorial *Recent Developments in Geometric Machine Learning* tại NeurIPS 2025 của Jegelka & Tahmasebi^[1] cùng các công trình nghiên cứu gốc từ các hội nghị đầu ngành. Kết quả thực nghiệm cho thấy mô hình NequIP với đặc trưng đẳng biến $\ell_{\max} = 1$ vượt trội so với mô hình bất biến thuần túy $\ell_{\max} = 0$ ở mọi quy mô dữ liệu, với khoảng cách MAE rõ rệt nhất trong chế độ dữ liệu khan hiếm ($N = 100$), xác nhận rằng việc mã hóa đúng tính đối xứng hình học vào kiến trúc mang lại lợi ích thực chất về cả hiệu quả dữ liệu lẫn định luật tỷ lệ.



Chương 1

Giới thiệu

1.1 Bối cảnh và động lực thực hiện

Trong thập kỷ qua, sự thành công của các mô hình học sâu trong việc giải quyết những bài toán phức tạp của trí tuệ nhân tạo là điều không thể phủ nhận. Tuy nhiên, sự phát triển này lại đi kèm với những thách thức to lớn về mặt lý thuyết và thực tiễn, đặt ra yêu cầu cấp thiết về một khung toán học thống nhất và sự hiểu biết sâu sắc hơn về bản chất của các mô hình nơ-ron nhân tạo.

1.1.1. Vấn đề phân mảnh kiến trúc và lời nguyên đa chiều

Hạn chế đầu tiên và rõ rệt nhất của lĩnh vực học sâu hiện đại là sự thiếu vắng các nguyên lý thống nhất. Hiện nay, cộng đồng nghiên cứu đang chứng kiến sự bùng nổ của vô số kiến trúc mạng nơ-ron khác nhau, được thiết kế riêng biệt cho từng định dạng dữ liệu. Sự phân mảnh này dẫn đến tình trạng các khái niệm cơ bản liên tục được phát minh lại và định danh dưới những tên gọi khác nhau trong các lĩnh vực ứng dụng riêng biệt, làm lu mờ đi bản chất toán học cốt lõi của bài toán.

Bên cạnh đó, dưới góc độ lý thuyết học thống kê, việc xấp xỉ một hàm số tổng quát trong không gian đa chiều mà không dựa trên bất kỳ giả định tiên nghiệm nào là một bài toán bị chi phối nặng nề bởi lời nguyên đa chiều. Nếu chỉ dựa trên giả định về tính trơn cục bộ, độ phức tạp mẫu yêu cầu để học chính xác hàm mục tiêu sẽ tăng theo cấp số nhân so với số chiều của dữ liệu, khiến bài toán trở nên bất khả thi trong thực tế ngay cả với năng lực tính toán hiện đại.

Khai thác tiên nghiệm hình học phá vỡ lời nguyên đa chiều

Tuy nhiên, dữ liệu trong thế giới thực hiếm khi tồn tại dưới dạng các vector vô hướng ngẫu nhiên; chúng luôn mang theo những quy luật vật lý và cấu trúc hình học đặc thù, chẳng hạn như tính chu kỳ trong tín hiệu, cấu trúc lưới trong hình ảnh, hoặc các liên kết tô-pô trong phân tử hóa học. Việc khai thác các tiên nghiệm hình học này, đặc biệt là tính bất biến và tính đẳng biến thông qua lăng kính của *Geometric Deep Learning*, đóng vai trò như một cơ chế lọc tự nhiên, giúp giới hạn triệt để không gian hàm cần tìm kiếm, qua đó trực tiếp phá vỡ lời nguyên đa chiều



và cung cấp một bản thiết kế chung để hệ thống hóa toàn bộ các kiến trúc mạng hiện hành như CNN, RNN và GNN.

1.1.2. Tính đối xứng tham số và học không gian trọng số

Sự chuyển dịch bối cảnh thứ hai xuất phát từ chính cấu trúc bên trong của các mô hình ngôn ngữ và mô hình tạo sinh quy mô lớn hiện nay. Các mô hình học sâu hiện đại có đặc điểm chung là bị siêu tham số hóa, dẫn đến sự suy biến nghiêm trọng trong không gian tối ưu: có vô số cấu hình trọng số khác nhau nhưng lại sản sinh ra cùng một hàm tính toán ở đầu ra.

Tính đôi dư này bắt nguồn từ tính đối xứng không gian tham số. Khác với đối xứng của dữ liệu đầu vào trong *Geometric Deep Learning* truyền thống, đối xứng tham số là những phép biến đổi áp dụng trực tiếp lên các ma trận trọng số mà không làm thay đổi hành vi của toàn bộ mạng. Sự tồn tại của các đa tạp chứa điểm cực tiểu tương đương này định hình cấu trúc của cảnh quan hàm mất mát, gây ra các hiện tượng như sự kết nối cực tiểu và làm phức tạp hóa quá trình tối ưu hóa.

Xu hướng học không gian trọng số trong kỷ nguyên mô hình nền tảng

Với sự bùng nổ của hàng triệu mô hình được lưu trữ trên các nền tảng mã nguồn mở, cộng đồng đang chứng kiến một hệ quả tất yếu là sự ra đời của hướng nghiên cứu học không gian trọng số. Hướng đi này coi chính các kiến trúc mạng nơ-ron là dữ liệu đầu vào, sử dụng *meta-networks* để phân tích, nén và tinh chỉnh trực tiếp trên cấu trúc tham số. Trong kỷ nguyên của mô hình nền tảng, việc hiểu và tận dụng các đối xứng tham số linh hoạt thay vì *hard-coding* trở thành chìa khóa để cải thiện định luật tỷ lệ và tăng cường hiệu quả tính toán.

1.1.3. Ý nghĩa và tầm quan trọng thực tiễn

Sự kết hợp giữa lý thuyết hình học của dữ liệu và tính đối xứng trong không gian tham số mang lại những bước tiến mang tính bản lề cho toàn bộ vòng đời của hệ thống học máy. Về mặt lý thuyết toán học, các chứng minh mới nhất cho thấy việc mã hóa tính đối xứng giúp cải thiện mạnh mẽ độ phức tạp mẫu, giảm thiểu nhu cầu dữ liệu lên đến nhiều bậc độ lớn, và gia tăng khả năng tổng quát hóa ngoài phân phối một cách nghiêm ngặt.


Ứng dụng khoa học mũi nhọn trong thế giới thực

Hơn thế nữa, các mô hình học sâu dựa trên nền tảng hình học và đối xứng đang đóng vai trò trung tâm trong việc giải quyết những bài toán khoa học mũi nhọn. Từ việc mô phỏng hệ nguyên tử, dự đoán năng lượng tương tác phân tử, đến việc ứng dụng tính đẳng biến nhóm $SE(3)$ trong Robotics để điều khiển thao tác trong không gian vật lý, *Geometric Deep Learning* đang chứng minh tiềm năng to lớn trong việc định hình các hệ thống trí tuệ nhân tạo có khả năng tương tác trực tiếp với các định luật vật lý của thế giới thực.

1.2 Kỹ nguyên của dữ liệu hình học

Lĩnh vực học máy đang chứng kiến nỗ lực to lớn nhằm hợp nhất các mô hình phân mảnh thành một hệ thống lý thuyết chặt chẽ. Đóng góp nền tảng mang tính bước ngoặt cho nỗ lực này là công trình nghiên cứu *Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges* của Bronstein và cộng sự (2021)^[2]. Hệ thống lý thuyết này được truyền cảm hứng sâu sắc từ chương trình Erlangen của nhà toán học Felix Klein, trong đó đề xuất rằng hình học nên được nghiên cứu thông qua các thuộc tính được bảo toàn dưới tác động của các nhóm phép biến đổi.


Nghiên cứu của Bronstein và cộng sự đã định hình lại cách các hệ thống trí tuệ nhân tạo tiếp nhận dữ liệu. Thay vì xử lý dữ liệu như các vector vô hướng, phương pháp này mô hình hóa dữ liệu dưới dạng tín hiệu nằm trên năm miền hình học cơ bản, được hệ thống hóa thành khung 5G bao gồm Grids, Groups, Graphs, Geodesics và Gauges. Việc gắn kết dữ liệu vào các miền hình học cụ thể cho phép khai thác triệt để các quy luật tự nhiên, chẳng hạn như tính chu kỳ của ảnh trên miền Grids hay liên kết hóa học trên miền Graphs.



Hình 1.1: Phân loại các miền hình học theo khung 5G

Ghi chú: Các miền hình học cơ bản bao gồm Grids, Groups, Graphs, Geodesics và Gauges. Nguồn: Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges (Bronstein et al., 2021).

Từ sự phân loại này, một bản thiết kế chung được đề xuất nhằm chuẩn hóa cấu trúc của mạng nơ-ron. Cấu trúc này bao gồm bốn thành phần tính toán cốt lõi: lớp đồng biến tuyến tính, hàm kích hoạt phi tuyến, lớp gộp cục bộ để trích xuất đặc trưng đa tỷ lệ, và lớp gộp bất biến toàn cục ở cuối mạng. Trong đó, hai khái niệm toán học đóng vai trò nền tảng là Invariance và Equivariance. Invariance đảm bảo đầu ra của mô hình không thay đổi khi dữ liệu đầu vào bị biến đổi, trong khi Equivariance yêu cầu đầu ra phải biến thiên một cách tương ứng theo đúng phép biến đổi của đầu vào.



Hình 1.2: Sơ đồ giao hoán toán học

Ghi chú: (a) Tính đẳng biến (Equivariance): Biến đổi đầu vào tương đương với việc áp dụng phép biến đổi tương ứng lên đầu ra. (b) Tính bất biến (Invariance): Đầu ra không bị ảnh hưởng bởi phép biến đổi nhóm g.

Bản thiết kế này cung cấp một khuôn khổ toán học minh bạch, chứng minh rằng các kiến trúc thành công nhất hiện nay như CNN, RNN, GNN và Transformer thực chất chỉ là các biến thể khác nhau của cùng một nguyên lý đối xứng khi áp dụng lên các miền dữ liệu hình học khác nhau.

1.3 Sự dịch chuyển sang không gian trọng số

Nếu như giai đoạn đầu của Geometric Deep Learning tập trung giải quyết các bài toán liên quan đến đối xứng trong không gian dữ liệu, thì xu hướng nghiên cứu hiện đại đang chứng kiến một bước chuyển dịch chiến lược. Sự dịch chuyển này được khảo sát và hệ thống hóa một cách toàn diện trong nghiên cứu *Symmetry in Neural Network Parameter Spaces* do Zhao và cộng sự (2026) thực hiện^[3]. Nhóm tác giả đã chuyển hướng phân tích



trọng tâm từ dữ liệu đầu vào sang việc khám phá tính đối xứng nằm ngay bên trong cấu trúc tham số của mạng nơ-ron.

Theo phân tích của Zhao và cộng sự, các mô hình học sâu hiện đại thường ở trạng thái siêu tham số hóa, dẫn đến hiện tượng vô số cấu hình trọng số khác nhau nhưng lại sản sinh ra cùng một hàm tính toán ở đầu ra. Sự dư thừa này bắt nguồn từ các phép biến đổi nội tại, chẳng hạn như hoán vị các nơ-ron ẩn hoặc thay đổi tỷ lệ trọng số của hàm kích hoạt ReLU, mà không làm thay đổi giá trị dự đoán cuối cùng. Việc nhận diện Parameter space symmetry giúp giải mã cấu trúc phức tạp của Loss landscape, giải thích nguyên nhân hình thành các vùng bình nguyên và hiện tượng Mode connectivity giữa các điểm cực tiểu cục bộ.

Kỹ thuật Teleportation và Equivariant Metanetworks

Khám phá này mở ra những kỹ thuật tối ưu hóa đột phá, điển hình là phương pháp Teleportation, cho phép thuật toán Gradient Descent chủ động dịch chuyển tham số đến các cấu hình tương đương mang đặc tính hội tụ tốt hơn. Quan trọng hơn, sự hiểu biết về đối xứng tham số là tiền đề cho lĩnh vực Weight space learning. Trong mô hình này, các tập hợp trọng số được xem như dữ liệu đầu vào cho một hệ thống Equivariant Metanetworks. Kiến trúc cấp cao này có khả năng dự đoán khả năng tổng quát hóa, nén mô hình và hợp nhất các điểm cực tiểu một cách hiệu quả mà không cần tiến hành suy luận trực tiếp trên dữ liệu gốc.

1.4 Mục tiêu và phạm vi của đề án

1.4.1. Mục tiêu nghiên cứu

Đề án này hướng tới việc hệ thống hóa và thực nghiệm các kỹ thuật tiên tiến nhất trong lĩnh vực học máy hình học, dựa trên nền tảng lý thuyết từ các hội nghị đầu ngành. Việc tích hợp các tiên nghiệm hình học vào mô hình nhằm chứng minh ba lợi ích cốt lõi sau:

- **Giảm bậc tự do và tăng Data efficiency:** Bằng cách ràng buộc không gian tìm kiếm thông qua các phép đối xứng, mô hình có thể đạt được độ chính xác cao với lượng dữ liệu huấn luyện ít hơn nhiều bậc độ lớn so với các phương pháp truyền thống.
- **Cải thiện OOD generalization và Robustness:** Kiến trúc tôn trọng các phép



biến đổi hình học giúp hệ thống duy trì tính ổn định và khả năng ngoại suy chính xác khi đối mặt với dữ liệu nằm ngoài phân phối huấn luyện ban đầu.

- **Hỗ trợ các tác vụ tạo sinh:** Hiểu rõ cơ chế duy trì và phá vỡ đối xứng cung cấp nền tảng toán học vững chắc cho việc thiết kế các mô hình tạo sinh cấu trúc phức tạp như phân tử thuốc hay protein.

1.4.2. Phạm vi và cấu trúc báo cáo

Báo cáo tổng hợp các kỹ thuật từ nền tảng toán học cơ bản đến những hướng tiếp cận mới nhất về đối xứng tham số và học không gian trọng số. Nội dung chi tiết được cấu trúc thành sáu chương tiếp theo:

- **Chương 2 (Kiến thức nền tảng):** Thiết lập cơ sở toán học cho báo cáo bằng cách giới thiệu lý thuyết nhóm, tác động nhóm, biểu diễn nhóm và khái niệm quỹ đạo. Chương này cũng trình bày các định nghĩa hình thức của tính bất biến và tính đẳng biến, làm tiền đề lý thuyết để xây dựng các mô hình nhận thức được hình học của dữ liệu.
- **Chương 3 (Các phương pháp xây dựng mô hình bảo toàn tính đối xứng):** Hệ thống hóa hai hướng tiếp cận chính để tích hợp tính đối xứng. Hướng thứ nhất can thiệp trên dữ liệu thông qua tăng cường dữ liệu, chuẩn hóa dữ liệu cùng định lý giới hạn về tính liên tục, lấy trung bình nhóm và lấy trung bình khung. Hướng thứ hai thiết kế kiến trúc tương biến từ đầu thông qua các lớp tuyến tính tương biến và cơ chế chia sẻ tham số như tích chập nhóm và DeepSets.
- **Chương 4 (Lý thuyết nâng cao và các hướng nghiên cứu mới):** Khảo sát các kết quả lý thuyết mới về độ phức tạp mẫu minimax optimal và các phương pháp tối ưu chi phí tính toán bằng đồ thị expander. Chương này cũng phân tích các bài toán kiểm định đối xứng trong dữ liệu, tính đối xứng không gian tham số của mạng nơ-ron, học không gian trọng số và các hướng mở rộng như mô hình không phụ thuộc số chiều hay học sâu tô-pô.
- **Chương 5 (Thực nghiệm và kết quả):** Trình bày các kết quả thực nghiệm định lượng trên các tập dữ liệu chuẩn để kiểm chứng lý thuyết. Các thực nghiệm bao gồm phân tích định luật tỷ lệ của NequIP trên QM9, kiểm chứng độ chính xác xấp xỉ lấy trung bình nhóm, học không gian trọng số qua mạng meta trên LoRA, gộp mô hình bằng căn chỉnh hoán vị Git Re-Basin và đánh giá định hướng của dữ liệu QM9.



- **Chương 6 (Đánh giá và kết luận):** Thảo luận chi tiết về các điều kiện áp dụng mô hình tương biến trong thực tế, bao gồm việc so sánh hiệu quả dữ liệu với định luật tỷ lệ khi tăng quy mô tính toán, phân biệt đối xứng chính xác và đối xứng xấp xỉ, đồng thời tổng hợp các ưu nhược điểm cốt lõi và định hướng phát triển tương lai.
- **Chương 7 (Demo minh họa):** Trình bày quá trình hiện thực hóa ba demo tương tác trên giao diện web sử dụng Next.js và FastAPI. Các demo minh họa hành vi của ba phương pháp: nhận diện chữ số viết tay bất biến với phép xoay trên MNIST, phân loại đám mây điểm bất biến với phép hoán vị bằng PointNet trên ModelNet40, và dự đoán năng lượng phân tử bất biến với nhóm Euclidean $E(3)$ bằng NequIP.



Chương 2

Kiến thức nền tảng

Chương này thiết lập ngôn ngữ toán học dùng xuyên suốt báo cáo. Kim chỉ nam xuyên suốt của Geometric Machine Learning là khái niệm đối xứng: những thuộc tính của dữ liệu được bảo toàn dưới tác động của một họ phép biến đổi^[2]. Để mô hình hoá ý tưởng này một cách chặt chẽ, nhóm trình bày theo trình tự từ trực giác đến hình thức: trước hết là hai khái niệm cốt lõi bất biến và đẳng biến; tiếp đó là công cụ đại số dùng để định nghĩa chính xác họ phép biến đổi hay còn gọi là lý thuyết nhóm, bao gồm tác động nhóm, biểu diễn nhóm và quỹ đạo; cuối cùng quay lại phát biểu hình thức của bất biến và đẳng biến dưới ngôn ngữ nhóm.

2.1 Khái niệm về đối xứng, bất biến và tương biến

Một cách trực quan, đối xứng của một đối tượng là phép biến đổi tác động lên đối tượng đó nhưng giữ nguyên những thuộc tính mà ta quan tâm. Chẳng hạn, nếu x là một bức ảnh chứa con mèo và T là phép tịnh tiến con mèo sang vị trí khác trong khung hình, thì bản chất đây là con mèo hoàn toàn độc lập với vị trí của nó. Khi xây dựng một mô hình f (ví dụ bộ phân loại, bộ phân đoạn ảnh, hay mạng nơ-ron đồ thị), ta mong muốn f tôn trọng các đối xứng này. Có hai cách tôn trọng cơ bản, tương ứng với hai loại bài toán: bất biến và tương biến / đẳng biến.

Định nghĩa 2.1 (Phép đối xứng). Cho đối tượng x thuộc không gian dữ liệu $\mathcal{X}$ và một phép biến đổi $T : \mathcal{X} \rightarrow \mathcal{X}$. Ta nói T là một phép đối xứng đối với một thuộc tính P nếu $P(T(x)) = P(x)$ với mọi x . Tập hợp tất cả các phép đối xứng đối với một họ thuộc tính cho trước tạo thành một nhóm, cấu trúc sẽ được định nghĩa ở mục 2.2^[2].


2.1.1. Tính bất biến

Định nghĩa 2.2 (Bất biến). Hàm $f : \mathcal{X} \rightarrow \mathcal{Y}$ được gọi là bất biến đối với phép biến đổi T nếu^[2]

$$f(T(x)) = f(x), \quad \forall x \in \mathcal{X}. \quad (2.1)$$

Nói cách khác, đầu ra của mô hình không thay đổi khi đầu vào bị biến đổi bởi T .

Ví dụ 2.3 (Phân loại ảnh: bất biến với phép tịnh tiến). Gọi x là ảnh đầu vào và $T = \tau_v$ là phép tịnh tiến nội dung ảnh theo vector v . Bộ phân loại f cần thỏa $f(\tau_v(x)) = f(x)$: dù con chó nằm ở góc nào trong khung hình, nhận dự đoán vẫn là chó.




Hình 2.1: Bất biến với phép tịnh tiến.

Ghi chú: Dù con chó nằm ở vị trí nào trong khung hình (x hay bản tịnh tiến $\tau_v(x)$), bộ phân loại f vẫn cho cùng một nhãn, tức $f(\tau_v(x)) = f(x)$.

Ví dụ 2.4 (Phân loại đồ thị: bất biến với phép hoán vị). Một đồ thị n đỉnh thường được biểu diễn bằng ma trận kề $A \in \mathbb{R}^{n \times n}$, trong đó cách đánh số đỉnh là hoàn toàn tùy ý. Nếu ta đánh số lại các đỉnh bằng một hoán vị, biểu diễn chuyển thành PAP^T với P là ma trận hoán vị, nhưng vẫn là cùng một đồ thị. Do đó một mô hình dự đoán thuộc tính ở mức đồ thị, ví dụ phân tử có độc hay không, cần bất biến hoán vị:

$$f(PAP^T) = f(A), \quad \forall P \in \mathcal{P}_n. \quad (2.2)$$



Hình 2.2: Bất biến với phép hoán vị.

Ghi chú: Đồ thị A và bản đánh số lại PAP^T thực chất là cùng một đồ thị, nên mô hình dự đoán ở mức đồ thị phải cho cùng kết quả, tức $f(PAP^T) = f(A)$.

Lập luận tương tự áp dụng cho point cloud: một vật thể được mô tả bởi một tập

vector toạ độ, và thứ tự liệt kê các vector này không mang ý nghĩa hình học nên mô hình cần bất biến với hoán vị các điểm.

2.1.2. Tính đẳng biến / tương biến

Bất biến phù hợp khi đầu ra là một đại lượng toàn cục. Tuy nhiên nhiều bài toán có đầu ra mang cấu trúc như toạ độ, lực, mặt nạ phân đoạn. Khi đó ta không muốn đầu ra bất biến, mà muốn nó biến thiên một cách tương ứng với đầu vào.


Định nghĩa 2.5 (Đẳng biến). Hàm $f : \mathcal{X} \rightarrow \mathcal{Y}$ được gọi là đẳng biến đối với phép biến đổi T nếu tồn tại phép biến đổi tương ứng T' trên không gian đầu ra sao cho^[4]

$$f(T(x)) = T'(f(x)), \quad \forall x \in \mathcal{X}. \quad (2.3)$$

Trong trường hợp đặc biệt thường gặp khi $\mathcal{X}$ và $\mathcal{Y}$ chịu cùng một phép biến đổi $T' = T$, điều kiện trở thành $f(T(x)) = T(f(x))$: biến đổi đầu vào rồi đưa qua mô hình cho cùng kết quả với đưa qua mô hình rồi biến đổi đầu ra.

Ví dụ 2.6 (Nhúng nút trên đồ thị: đẳng biến hoán vị). Xét bài toán học nhúng cho từng nút bằng mạng nơ-ron đồ thị hoặc Transformer: đầu vào là tập đặc trưng nút, đầu ra là tập biểu diễn tương ứng theo cùng thứ tự. Vì thứ tự liệt kê nút là tùy ý nhưng đồ thị không đổi, nếu ta hoán vị đầu vào thì đầu ra phải bị hoán vị y hệt:

$$f(PX) = Pf(X), \quad \forall P \in \mathcal{P}_n. \quad (2.4)$$




Hình 2.3: Đẳng biến hoán vị của GNN.

Ghi chú: Khi hoán vị thứ tự nút ở đầu vào (PX), nhúng đầu ra bị hoán vị theo đúng thứ tự đó (PH), tức $f(PX) = Pf(X)$. Màu sắc theo dõi danh tính nút xuyên suốt.

Ví dụ 2.7 (Dự đoán lực tác dụng lên phân tử: tính đẳng biến). Xét bài toán dự đoán các vector lực tác dụng lên từng nguyên tử của một phân tử hóa học. Nếu ta xoay toàn

bộ cấu trúc phân tử này một góc -90° trong không gian, thì các vector lực tương ứng được biểu diễn bằng các mũi tên màu đỏ cũng phải xoay theo đúng một góc -90° tương ứng. Tính chất này tuân theo hệ thức đẳng biến chuẩn xác: $f(T(x)) = T(f(x))$, giúp mô hình giữ được sự nhất quán vật lý bất kể định hướng của phân tử trong không gian.



Hình 2.4: Đẳng biến $SE(3)$ trong dự đoán lực phân tử.

Ghi chú: Khi quay toàn bộ phân tử bằng phép biến đổi T , các vector lực dự đoán (mũi tên đỏ) cũng quay theo đúng phép biến đổi đó, tức $f(T(x)) = T(f(x))$.

Bất biến là trường hợp đặc biệt của đẳng biến

Cho hàm đẳng biến thỏa mãn phương trình tổng quát:

$$f(T(x)) = T'(f(x)) \quad \forall x \in \mathcal{X} \quad (2.5)$$

Trong đó T' là phép biến đổi tương ứng tác động lên không gian đầu ra.

Nếu ta xét trường hợp đặc biệt khi $T' = \text{Id}$ tức phép đồng nhất, nghĩa là phép biến đổi ở đầu ra là tầm thường và không làm thay đổi bất kỳ phần tử nào:

$$T'(y) = \text{Id}(y) = y \quad \forall y \in \mathcal{Y} \quad (2.6)$$

Khi đó, thay $y = f(x)$ vào biểu thức trên, vế phải của phương trình (2.5) trở thành:

$$T'(f(x)) = \text{Id}(f(x)) = f(x) \quad (2.7)$$

Thế ngược lại vào phương trình (2.5), ta thu được ngay:


$$f(T(x)) = f(x) \quad \forall x \in \mathcal{X} \quad (2.8)$$

Đây chính là định nghĩa của tính bất biến.


Kết luận: Bất biến chính là đẳng biến với phép biến đổi đồng nhất ở đầu ra.

Mối quan hệ giữa biến đổi đầu vào và biến đổi đầu ra được tóm tắt gọn gàng bằng sơ đồ giao hoán ở Hình 2.5. Tính đẳng bất biến tương đương với việc sơ đồ tương ứng giao hoán: mọi đường đi từ góc trên-trái đến góc dưới-phải (hoặc tới $\mathcal{Y}$) đều cho cùng kết quả.

(a) Đẳng biến



(b) Bất biến



Hình 2.5: Sơ đồ giao hoán của bất biến và đẳng biến.

Ghi chú: (a) Đẳng biến: phép biến đổi T trên đầu vào tương ứng với phép biến đổi T' trên đầu ra. (b) Bất biến: đầu ra không đổi dù đầu vào bị biến đổi bởi T .

2.1.3. Vì sao tính đối xứng lại quan trọng?

Việc mã hoá sẵn đối xứng vào mô hình mang lại ba lợi ích đã được chứng thực rộng rãi trong thực nghiệm:

- **Giảm bậc tự do và tăng hiệu quả dữ liệu.** Nếu đã biết hàm cần học có sẵn đối xứng, ta không cần học lại đối xứng đó từ dữ liệu. Trong bài toán dự đoán thể năng liên nguyên tử, các mô hình bất biến/đẳng biến đạt cùng độ chính xác trong khi dùng ít hơn tới ba bậc độ lớn khoảng 10^3 lần dữ liệu huấn luyện so với mô hình không đối xứng^[5].
- **Tăng độ bền vững và tổng quát hoá ngoài phân phối.** Nếu mô hình tôn trọng phép biến đổi, ta biết chính xác nó sẽ ngoại suy thế nào khi dữ liệu bị xoay/tịnh tiến mà không bị ảnh hưởng bởi thay đổi nhỏ. Vô hình chung là hành vi có thể dự đoán được và ổn định hơn.
- **Nền tảng cho mô hình tạo sinh.** Hiểu cơ chế duy trì và phá vỡ đối xứng cung cấp khung lý thuyết để thiết kế mô hình sinh cấu trúc phức tạp như phân tử thuốc, protein.



2.2 Cơ sở lý thuyết nhóm

Các phép biến đổi mà ta quan tâm như phép quay, tịnh tiến, hoán vị không phải là tùy ý: chúng có thể kết hợp với nhau, có thể đảo ngược, và luôn chứa phép không làm gì cả. Cấu trúc đại số nắm bắt chính xác những tính chất này là nhóm.

Định nghĩa 2.8 (Nhóm). Một nhóm là một cặp $(G, \cdot)$ gồm một tập hợp khác rỗng G và một phép toán hai ngôi $\cdot : G \times G \rightarrow G$ gọi là phép hợp thành, thỏa mãn bốn tính chất [2]:

(G1) Tính đóng: với mọi $g, h \in G$ thì $g \cdot h \in G$.

(G2) Tính kết hợp: $(g \cdot h) \cdot \ell = g \cdot (h \cdot \ell)$ với mọi $g, h, \ell \in G$.

(G3) Phần tử đơn vị: tồn tại $e \in G$ sao cho $e \cdot g = g \cdot e = g$ với mọi $g \in G$.


(G4) Phần tử nghịch đảo: với mỗi $g \in G$, tồn tại $g^{-1} \in G$ sao cho $g \cdot g^{-1} = g^{-1} \cdot g = e$.

Để gọn, ta thường viết gh thay cho $g \cdot h$.

Nhận xét 2.9. Định nghĩa nhóm không đòi hỏi tính giao hoán $gh = hg$. Nếu nhóm thỏa thêm tính chất này, ta gọi nó là nhóm giao hoán. Phép quay trong mặt phẳng là giao hoán, nhưng phép quay trong không gian ba chiều và phép hoán vị với $n \geq 3$ thì không.

Ví dụ 2.10 (Một số nhóm tiêu biểu).

- **Nhóm tịnh tiến** $(\mathbb{R}^d, +)$: Đại diện cho phép dịch chuyển vật thể theo một hướng và khoảng cách cố định mà không làm thay đổi hình dáng hay góc độ. Phần tử đơn vị là đứng yên, nghịch đảo của tiến lên là lùi lại.
- **Nhóm xoay tuần hoàn** C_n : Đại diện cho n phép quay quanh một tâm cố định. Ví dụ C_4 là quay vật thể theo từng góc 90° cho đến khi trở về vị trí ban đầu.
- **Nhóm Euclid** $E(d)$ (và $SE(d)$): Đại diện cho các phép dời hình cứng, kết hợp đồng thời cả việc dịch chuyển và xoay vật thể. Đây là nền tảng cốt lõi trong robotics và mô phỏng phân tử 3D.



Hình 2.6: Minh hoạ tác động của ba nhóm tiêu biểu.

Ghi chú: (a) Nhóm tịnh tiến chỉ thay đổi vị trí; (b) nhóm xoay C_4 chỉ thay đổi góc xoay quanh tâm; (c) nhóm Euclid $SE(2)$ thay đổi đồng thời vị trí và góc xoay.

2.2.1. Tác động nhóm và biểu diễn nhóm

Một nhóm trở nên hữu ích khi nó tác động lên dữ liệu: các phần tử của nhóm là những phép biến đổi, nên chúng phải biến đổi một thứ gì đó.

Định nghĩa 2.11 (Tác động nhóm). Một tác động của nhóm G lên tập $\mathcal{X}$ là một ánh xạ $G \times \mathcal{X} \rightarrow \mathcal{X}$, $(g, x) \mapsto g \cdot x$, thỏa mãn^[2]:

$$e \cdot x = x \quad \text{và} \quad (gh) \cdot x = g \cdot (h \cdot x), \quad \forall g, h \in G, \forall x \in \mathcal{X}. \quad (2.9)$$

Tức là phần tử đơn vị không làm gì, và tác động liên tiếp tương thích với phép hợp thành trong nhóm.

Ví dụ 2.12. Hoán vị $\sigma \in S_n$ tác động lên tập chỉ số $\{1, \dots, n\}$ theo $\sigma \cdot i = \sigma(i)$. Ma trận khả nghịch $A \in GL(n)$ tác động lên $\mathbb{R}^n$ bằng phép nhân ma trận $A \cdot x = Ax$.


Trong các trường hợp ta quan tâm, tác động nhóm có thể được tuyến tính hoá: mỗi phần tử nhóm được biểu diễn bằng một ma trận. Đây là chiếc cầu nối giữa lý thuyết nhóm trừu tượng và đại số tuyến tính của mạng nơ-ron.

Định nghĩa 2.13 (Biểu diễn nhóm). Một biểu diễn của nhóm G trên không gian vector V là một ánh xạ $\rho : G \rightarrow GL(V)$ tương thích với phép hợp thành^[2]:

$$\rho(gh) = \rho(g) \rho(h), \quad \forall g, h \in G, \quad (2.10)$$

khi đó tác động được viết dưới dạng nhân ma trận $g \cdot x = \rho(g)x$.

Ví dụ 2.14. Hoán vị σ tác động lên vector qua ma trận hoán vị $\sigma \cdot x = P_\sigma x$. Phép quay tác động qua ma trận quay $g \cdot x = Rx = \rho(g)x$. Hình 2.7 minh hoạ tác động của một hoán vị lên một mảng năm phần tử.



Hình 2.7: Tác động hoán vị lên một mảng.


Ghi chú: Hoán vị $\sigma \in S_5$ tráo đổi thứ tự các phần tử của mảng đầu vào x , biểu diễn bằng phép nhân với ma trận hoán vị P_σ .

2.2.2. Quỹ đạo

Định nghĩa 2.15 (Quỹ đạo). Quỹ đạo của một điểm $x \in \mathcal{X}$ dưới tác động của nhóm G là tập hợp tất cả các điểm có thể đạt tới từ x bằng các phép biến đổi trong G ^[1]:

$$\text{Orb}_G(x) = \{g \cdot x \mid g \in G\}. \quad (2.11)$$

Ví dụ 2.16. Với nhóm C_4 các phép quay 90° tác động lên một điểm trong mặt phẳng, quỹ đạo gồm đúng bốn điểm là bốn vị trí quay của điểm đó (Hình 2.8). Với nhóm tịnh tiến tác động lên một ảnh, quỹ đạo của ảnh là tập tất cả các phiên bản dịch chuyển của nó.



Hình 2.8: Quỹ đạo của một điểm dưới nhóm C_4 .

Ghi chú: Dưới tác động của nhóm xoay tuần hoàn C_4 (phép quay 90°), quỹ đạo của điểm x gồm bốn vị trí quay liên tiếp.

Liên hệ khái niệm quỹ đạo với tính bất biến

Một hàm f là bất biến G khi và chỉ khi nó nhận giá trị hằng trên mỗi quỹ đạo: f không phân biệt được hai điểm thuộc cùng một $\text{Orb}_G(x)$. Quan sát đơn giản này là chìa khoá cho hai họ phương pháp ở chương 3: canonicalization chọn một đại diện cố định cho mỗi quỹ đạo, hay group/frame averaging trung bình hoá giá trị trên toàn bộ quỹ đạo để ép buộc tính bất biến.

2.2.3. Phát biểu hình thức của bất biến và đẳng biến

Với ngôn ngữ tác động nhóm, hai khái niệm ở mục 2.1 được phát biểu lại một cách chính xác và tổng quát.


Định nghĩa 2.17 (Bất biến và đẳng biến theo nhóm). Cho nhóm G tác động lên không gian đầu vào $\mathcal{X}$ và đầu ra $\mathcal{Y}$. Hàm $f : \mathcal{X} \rightarrow \mathcal{Y}$ được gọi là:

- G -invariant nếu $f(g \cdot x) = f(x)$ với mọi $g \in G$;
- G -equivariant nếu $f(g \cdot x) = g \cdot f(x)$ với mọi $g \in G$, hay tổng quát hơn $f(\rho_1(g)x) = \rho_2(g)f(x)$ khi tác động trên đầu vào và đầu ra dùng hai biểu diễn ρ_1, ρ_2 khác nhau.


Bảng 2.1: So sánh hai loại đối xứng cơ bản.

	Bất biến	Đẳng biến
Điều kiện	$f(g \cdot x) = f(x)$	$f(g \cdot x) = g \cdot f(x)$
Đầu ra điển hình	Vô hướng	Vector / có cấu trúc
Ví dụ	Phân loại ảnh/đồ thị	Nhúng nút, dự đoán lực, xác định khung bao
Quan hệ	Bất biến là trường hợp riêng của đẳng biến	

(a) Bất biến (phân loại): $f(g \cdot x) = f(x)$



(b) Đẳng biến (định vị): $f(g \cdot x) = g \cdot f(x)$



Hình 2.9: Trực quan hoá bất biến và đẳng biến.

Ghi chú: (a) Bất biến: tác động g lên con mèo trong khung hình không làm thay đổi nhãn đầu ra, $f(g \cdot x) = f(x)$. (b) Đẳng biến: khung bao đầu ra biến đổi tương ứng, $f(g \cdot x) = g \cdot f(x)$.



Chương 3

Các phương pháp xây dựng mô hình bảo toàn tính đối xứng

3.1 Hướng 1: Can thiệp dữ liệu trên các mô hình có sẵn

Trước khi đi vào các phương pháp xây dựng kiến trúc hoàn toàn mới, một hướng tiếp cận tự nhiên hơn là tận dụng lại những mô hình học máy đã được huấn luyện tốt (thứ mà cộng đồng nghiên cứu đã đổ rất nhiều công sức phát triển) rồi can thiệp vào phía dữ liệu để ép mô hình phải tôn trọng tính đối xứng. Hướng này được gọi là hướng can thiệp dữ liệu, hay cách tiếp cận với mô hình hộp đen.

Ưu điểm cốt lõi của hướng này là mô hình cơ sở (Transformer, CNN hay bất kỳ kiến trúc nào khác) được giữ nguyên hoàn toàn, kéo theo toàn bộ sức mạnh biểu diễn, kỹ thuật tối ưu, và quy trình huấn luyện của nó vẫn còn hiệu lực. Điều đó có nghĩa là người dùng không cần thiết kế lại bất cứ điều gì từ đầu. Ngoài ra, nếu mô hình cơ sở đã có sẵn một số tính chất đối xứng nhất định, việc kết hợp thêm các nhóm đối xứng khác thông qua can thiệp dữ liệu là hoàn toàn khả thi mà không gây mâu thuẫn.

Trong hướng này có ba kỹ thuật chính: tăng cường dữ liệu, chuẩn hóa, và lấy trung bình nhóm/khung. Ba kỹ thuật này nằm trên một phổ liên tục: từ một phép biến đổi duy nhất ở một đầu, đến lấy trung bình trên toàn bộ nhóm G ở đầu kia, với lấy trung bình khung nằm ở giữa như một điểm cân bằng giữa chi phí tính toán và chất lượng đảm bảo tính đối xứng.

3.1.1. Tăng cường dữ liệu

Ý tưởng cơ bản

Tăng cường dữ liệu là kỹ thuật đơn giản và phổ biến nhất để đưa tính đối xứng vào mô hình. Với mỗi điểm dữ liệu x trong tập huấn luyện, ta sinh thêm các biến thể $g \cdot x$ cho nhiều phần tử $g \in G$ khác nhau và đưa chúng vào tập huấn luyện cùng nhãn gốc. Khi tập huấn luyện bao phủ đủ nhiều biến thể của quỹ đạo $\text{Orb}_G(x)$, mô



hình sẽ học được rằng phép biến đổi g không làm thay đổi nhãn, tức là dần hình thành tính bất biến.

Kỹ thuật này rất linh hoạt vì có thể áp dụng cho cả học có giám sát lẫn học tự giám sát. Trong học tương phản, người ta thường tạo cặp dữ liệu $(x, g \cdot x)$ và đặt chúng ở vị trí cặp dương, buộc mô hình phải đặt cả hai vào cùng một vùng trong không gian ẩn. Qua đó, toàn bộ quỹ đạo của x dưới tác động của G sẽ được ánh xạ về một biểu diễn duy nhất.

Chỉ đảm bảo tính đối xứng xấp xỉ

Dù đơn giản và hiệu quả trong thực tế, tăng cường dữ liệu mang một hạn chế quan trọng về mặt lý thuyết: nó không đảm bảo tính invariance ở mọi điểm. Sau khi huấn luyện, không có gì chắc chắn rằng với một điểm dữ liệu mới x' chưa từng thấy, mô hình sẽ cho ra cùng một kết quả cho x' và $g \cdot x'$.


Biểu hiện thực tiễn là mô hình thường hoạt động tốt trên tập test cùng phân phối, nhưng rất dễ bị đánh lừa khi gặp đầu vào bị biến đổi ở góc độ chưa từng xuất hiện. Mô hình chỉ học xấp xỉ tính invariance trong vùng lân cận của dữ liệu đã có, chứ không hình thành một bảo đảm khái quát hóa ra ngoài phân phối.

Học biểu diễn equivariant

Một bước phát triển thú vị từ tăng cường dữ liệu là học biểu diễn equivariant thay vì chỉ invariant. Đôi khi ta không muốn hoàn toàn triệt tiêu thông tin về phép biến đổi mà dữ liệu đã trải qua, mà muốn latent space ghi nhớ lại sự biến đổi đó theo một cách có cấu trúc. Cụ thể, nếu a là một phép tăng cường và f là encoder, thì mục tiêu là:

$$f(a(x)) = T_a \cdot f(x), \quad (3.1)$$

trong đó T_a là một phép biến đổi tác động lên không gian ẩn, tương ứng với phép tăng cường a . Sơ đồ Hình 3.1 minh họa trực quan cho ý tưởng này.



Hình 3.1: Sơ đồ giao hoán của học biểu diễn equivariant.

Ghi chú: Áp dụng phép tăng cường a rồi mã hóa, hoặc mã hóa rồi tác động T_a trong không gian ẩn, đều cho cùng kết quả.

Một cách tiếp cận trực tiếp là dùng một mạng neural nhỏ (gọi là MLP) để cố gắng đoán xem điểm dữ liệu trong không gian ẩn sẽ nằm ở đâu sau khi bị biến đổi. Cụ thể, ta yêu cầu $\text{MLP}(a, f(x))$ phải dự đoán ra đúng giá trị của $f(a(x))$, dẫn đến hàm mất mát:

$$\mathcal{L} = \|f(a(x)) - \text{MLP}(a, f(x))\|. \quad (3.2)$$

Tuy nhiên, cách này gặp phải một nhược điểm rất lớn. Giả sử ta xoay một bức ảnh 90° (gọi là phép biến đổi a_1), rồi xoay tiếp 90° nữa (gọi là a_2). Logic thông thường đòi hỏi kết quả trong không gian ẩn phải y hệt như khi bạn xoay một phát 180° . Nhưng vì mạng MLP chỉ đoán mò dựa trên dữ liệu, nó hoàn toàn có thể cho ra hai kết quả khác nhau (trong toán học gọi là hiện tượng không thỏa mãn *phép kết hợp nhóm*: $T_{a_2 \circ a_1} \neq T_{a_2} \circ T_{a_1}$).

Phiên bản tuyến tính: ràng buộc bảo toàn tích vô hướng.

Để ép không gian ẩn phải thực sự hiểu tính logic của các phép biến đổi, các nghiên cứu sau này (tiêu biểu như Shakerinava et al. 2022 và Gupta et al. 2023) đã sử dụng một thủ thuật hình học thông minh.

Họ đưa ra giả định rằng phép biến đổi T_a tác động lên không gian ẩn thực chất nên là một *phép quay*. Đặc điểm bất di bất dịch của một phép quay chính là nó *luôn bảo toàn góc và độ dài* của mọi vật thể. Chẳng hạn, nếu ta xoay cả hai vector đi 30° cùng lúc, thì khoảng cách và góc nhìn tương đối giữa chúng vẫn y nguyên như lúc chưa xoay. Trong đại số tuyến tính, góc và độ dài được tóm gọn hoàn hảo trong một phép toán duy nhất: *tích vô hướng*.

Do đó thay vì phải dạy mạng MLP cách xoay từng chút một, ta chỉ cần ép mô hình tuân thủ một luật duy nhất: *Tích vô hướng giữa hai điểm dữ liệu bất kì trước khi bị biến đổi ($f(x')^\top f(x)$) phải bằng đúng tích vô hướng của chúng sau khi bị biến đổi*



$(f(a(x'))^\top f(a(x)))$. Hàm mất mát lúc này trở thành:

$$\mathbb{E}_{a,x,x'} [f(a(x'))^\top f(a(x)) - f(x')^\top f(x)]^2 = 0. \quad (3.3)$$

Khi hàm mất mát này hội tụ về 0, mỗi $T_a = R_a$ là một phép quay trong không gian ẩn và tự động tương thích với phép kết hợp nhóm, tức là $\{T_a\}_{a \in G}$ tạo thành một biểu diễn nhóm của G . Hướng tiếp cận này chứng minh rằng phép tăng cường a tác động lên đầu vào không nhất thiết phải là một phép quay và đã được phát triển bởi Shakerinava et al. (2022) và Gupta et al. (2023).

Từ đối xứng xấp xỉ đến đối xứng tuyệt đối.

Như đã phân tích ở trên, hạn chế lớn nhất của việc tăng cường dữ liệu truyền thống là mô hình chỉ học được tính bất biến ở mức độ xấp xỉ. Để hình dung, nếu ta muốn mạng neural nhận diện một con mèo dù nó bị xoay ở bất kỳ góc nào, việc chỉ cung cấp cho mô hình vài bức ảnh mèo bị xoay sẽ không đảm bảo rằng mô hình nhận diện đúng con mèo khi nó bị xoay ở một góc hoàn toàn mới chưa từng có trong tập huấn luyện. Nếu muốn mô hình đạt được tính đối xứng tuyệt đối, ta buộc phải sinh thêm dữ liệu cho *toàn bộ* các phép biến đổi trong nhóm G , dẫn đến độ phức tạp bùng nổ $\mathcal{O}(n|G|)$. Điều này là hoàn toàn bất khả thi với các nhóm lớn, ví dụ như nhóm hoán vị d phần tử có kích thước lên tới $|G| = d!$.

Để khắc phục hạn chế trên, Soleymani et al. (2025) đã giới thiệu một hướng tiếp cận mới trong nghiên cứu *Learning with Exact Invariances in Polynomial Time*^[6]. Thay vì tạo ra tất cả các biến thể của dữ liệu để huấn luyện mô hình, các tác giả đề xuất kỹ thuật *Lấy trung bình phổ* (*Spectral Averaging*). Phương pháp này giải quyết bài toán thông qua góc độ hình học bằng cách phân rã không gian dữ liệu thành các thành phần tần số, khá giống với cách biến đổi Fourier phân tích một tín hiệu âm thanh thành các dải tần riêng biệt.

Ví dụ: Khai thác tập sinh của nhóm hoán vị

Sự đột phá nằm ở chỗ rằng thay vì phải ép mô hình tuân theo hàng triệu ràng buộc tương ứng với hàng triệu phép biến đổi, ta chỉ cần ép mô hình tuân theo các phép biến đổi gốc (gọi là tập sinh - generators của nhóm). Hãy lấy ví dụ về nhóm hoán vị của 10 phần tử ($10! \approx 3.6$ triệu phép hoán vị). Thay vì phải kiểm tra 3.6 triệu trường hợp, toán học nhóm chỉ ra rằng mọi hoán vị đều có thể được tạo ra chỉ từ 2 thao tác cơ bản: (1) hoán đổi 2 phần tử đầu tiên, và (2) đẩy tất cả phần tử sang phải một bước. Nghĩa là, nếu một hàm số không thay đổi kết quả khi bị tác động



bởi 2 thao tác cơ bản này, nó cũng sẽ tự động không thay đổi với toàn bộ 3.6 triệu hoán vị còn lại!

Nhờ nguyên lý này, số lượng phép thử (hay số ràng buộc) được giảm mạnh từ $|G|$ xuống chỉ còn khoảng $\log(|G|)$ (rất nhỏ). Nhờ đó, phương pháp Spectral Averaging có thể tạo ra một bộ ước lượng có tính đối xứng tuyệt đối chỉ trong thời gian đa thức, đồng thời vẫn giữ được khả năng dự đoán chính xác hệt như khi không có ràng buộc đối xứng. Kết quả này chứng minh về mặt lý thuyết rằng ta hoàn toàn có thể đạt được tính đối xứng tuyệt đối đi kèm với hiệu suất tính toán cao, qua đó khắc phục được rào cản lớn nhất của kỹ thuật tăng cường dữ liệu.

3.1.2. Chuẩn hóa


Ý tưởng cơ bản

Kỹ thuật chuẩn hóa theo đuổi một chiến lược khác biệt: thay vì làm phong phú tập dữ liệu bằng nhiều biến thể, ta chuyển mỗi điểm dữ liệu x về một dạng chuẩn duy nhất trước khi đưa vào mô hình. Miễn là hàm chuẩn hóa $c(\cdot)$ ánh xạ mọi phần tử trong cùng một quỹ đạo về cùng một điểm duy nhất, thì mô hình sẽ tự động đạt được tính invariance:

$$c(g \cdot x) = c(x) \quad \forall g \in G. \quad (3.4)$$

Ví dụ điển hình nhất là phép sắp xếp cho bài toán invariant với hoán vị: với bất kỳ chuỗi nào, ta sắp xếp nó theo thứ tự tăng dần trước khi đưa vào mô hình. Vì mọi hoán vị của cùng một chuỗi đều cho ra cùng một dạng đã sắp xếp, mô hình luôn nhận cùng một đầu vào và cho ra cùng một kết quả.

Để đạt equivariance thay vì chỉ invariance, ta thực hiện thêm một bước ở cuối: sau khi mô hình xử lý dạng chuẩn, ta áp dụng phép biến đổi ngược để khôi phục thứ tự ban đầu. Hình 3.2 minh họa toàn bộ quy trình này.



Hình 3.2: Pipeline chuẩn hóa.


Ghi chú: Đầu vào x được ánh xạ về dạng chuẩn $c(x)$, xử lý bằng mô hình f , sau đó áp dụng phép biến đổi ngược c^{-1} để đạt equivariance. Nếu chỉ cần invariance thì có thể bỏ qua bước cuối.

Trong ví dụ sắp xếp, nếu dãy $[5, 3, 4]$ được chuẩn hóa thành $[3, 4, 5]$, mô hình sẽ xử lý và cho ra kết quả dựa trên dạng chuẩn đó. Cuối cùng, ta hoán vị ngược lại để đầu ra khớp với thứ tự ban đầu của đầu vào. Hàm chuẩn hóa $c(\cdot)$ không nhất thiết phải được thiết kế thủ công, mà có thể được học từ dữ liệu thông qua một mạng neural phụ trợ^[7].

Các thách thức của phương pháp chuẩn hóa

- 1. Khó khăn trong việc xác định dạng chuẩn:** Đối với chuỗi số, sắp xếp là một lựa chọn tự nhiên và đơn giản. Nhưng không phải mọi loại dữ liệu đều có một dạng chuẩn rõ ràng. Ta lấy ví dụ với đồ thị: một đồ thị n nút có thể được mô tả bởi $n!$ ma trận kề khác nhau, tương ứng với $n!$ cách đánh số các nút. Tìm một biểu diễn chuẩn chung cho tất cả các cách đánh số đó về cơ bản tương đương với việc giải bài toán graph isomorphism, một bài toán đã được nghiên cứu trong nhiều thập kỷ nhưng vẫn chưa có thuật toán đa thức được chứng minh. Tương tự với đám mây điểm trong không gian 3D kết hợp đối xứng quay và hoán vị, việc chuẩn hóa trở nên rất phức tạp.
- 2. Vấn đề tính liên tục:** Đây là hạn chế lý thuyết nghiêm trọng nhất của kỹ thuật chuẩn hóa. Tính liên tục yêu cầu nếu hai đầu vào gần nhau thì dạng chuẩn của chúng cũng phải gần nhau. Định lý của Dym et al. (2024) (3.1) chứng minh rằng không tồn tại hàm chuẩn hóa liên tục cho nhóm hoán vị S_n hoặc các nhóm liên tục như $SO(2)$ trong trường hợp tổng quát.

Hãy xem xét một ví dụ minh họa cực kỳ trực quan để thấy tại sao tính liên tục lại bị phá vỡ. Đầu tiên, nếu ta chỉ có một mảng 1 chiều (1D array), việc chuẩn hóa bằng cách sắp xếp là hoàn toàn liên tục. Ví dụ, mảng $A = [5, 3, 3]$ sau khi sắp xếp sẽ thành $[3, 3, 5]$. Nếu ta nhiễu loạn nhẹ mảng A thành $A' = [5, 3.01, 3]$, mảng này sau khi sắp xếp sẽ thành $[3, 3.01, 5]$. Hai kết quả này vẫn rất gần nhau, tính liên tục được bảo toàn (xem Hình 3.3).



Example adapted from Dym et al 2024


Hình 3.3: Chuẩn hóa mảng 1 chiều bảo toàn tính liên tục.

Ghi chú: Hai mảng đầu vào gần nhau sau khi sắp xếp (chuẩn hóa) vẫn cho ra hai kết quả gần nhau. Nguồn:^[1], trang 20.

Tuy nhiên, câu chuyện hoàn toàn thay đổi đối với dữ liệu nhiều chiều (chẳng hạn ma trận 2×3). Giả sử ta có hai ma trận M và M' cực kỳ gần nhau, trong đó hàng thứ nhất là ví dụ mảng 1 chiều ở trên, và hàng thứ hai là $[1, 7, 8]$. Khi tiến hành chuẩn hóa ma trận bằng cách sắp xếp các cột theo thứ tự tăng dần dựa trên giá trị của hàng đầu tiên, ta sẽ gặp rắc rối lớn.

Đối với ma trận M , vì hai phần tử ở hàng đầu là 3 và 3 (bằng nhau), thứ tự của hai cột cuối cùng được giữ nguyên (hoặc quyết định bởi hàng thứ hai), kéo theo phần tử 7 đi kèm với số 3 đầu tiên, và 8 đi kèm với số 3 thứ hai. Tuy nhiên, ở ma trận M' , giá trị 3.01 lớn hơn 3, khiến cột chứa 3.01 buộc phải nhảy ra phía sau cột chứa 3. Sự hoán đổi vị trí của hàng trên kéo theo toàn bộ các phần tử ở hàng dưới (7 và 8) cũng bị hoán đổi theo!

Kết quả là, ma trận M và M' ban đầu cực kỳ gần nhau (chỉ lệch 0.01 ở một vị trí), nhưng sau khi chuẩn hóa lại bị biến thành hai dạng chuẩn *cách rất xa nhau* (vì số 7 và 8 bị tráo đổi hoàn toàn). Đây chính là định nghĩa toán học của sự gián đoạn (xem Hình 3.4).



Example adapted from Dym et al 2024

Hình 3.4: Minh họa sự phá vỡ tính liên tục trong chuẩn hóa nhiều chiều.

Ghi chú: Ma trận thứ hai chỉ thay đổi rất nhỏ (3.01 thay vì 3), nhưng khiến thứ tự các cột bị đảo lộn hoàn toàn khi sắp xếp, làm cho hai dạng chuẩn đầu ra cách xa nhau.

Nguồn:^[1], trang 21.



Kết quả lý thuyết của Dym et al. (2024) và Zhang et al. (2020) chỉ ra rằng đây không phải vấn đề của riêng một cách sắp xếp cụ thể nào, mà là một giới hạn căn bản không thể tránh được đối với dữ liệu phức tạp.

Sự bất khả thi của chuẩn hóa liên tục.

Công trình *Equivariant frames and the impossibility of continuous canonicalization* của Dym et al. (2024)^[8] đã phân tích chặt chẽ nền tảng toán học của kỹ thuật chuẩn hóa, từ đó chứng minh giới hạn: Việc xây dựng một hàm chuẩn hóa liên tục là điều không thể thực hiện được đối với phần lớn các nhóm đối xứng thông dụng.

Định lý 3.1 (Sự bất khả thi của chuẩn hóa liên tục, Dym et al. 2024). *Không tồn tại hàm chuẩn hóa liên tục nào cho nhóm hoán vị S_n tác động lên $\mathbb{R}^{d \times n}$ với $n, d > 1$. Tương tự, không tồn tại chuẩn hóa liên tục cho nhóm quay $SO(d)$ khi $n \geq d \geq 2$, và nhóm trực giao $O(d)$ khi $n > d \geq 1$.*

Ví dụ: Chuẩn hóa hướng của hình elip

Để thực sự hiểu tại sao tính liên tục lại bị phá vỡ, hãy cùng xem xét một ví dụ rất trực quan. Hãy tưởng tượng bạn có nhiệm vụ phải chuẩn hóa hướng của một hình elip bằng cách luôn xoay nó sao cho trục dài nhất nằm ngang. Nếu hình elip rất dài và dẹt, nhiệm vụ này rất dễ dàng vì trục dài nhất hiện ra cực kỳ rõ ràng. Tuy nhiên, điều gì sẽ xảy ra nếu hình elip đó ngày càng tròn hơn, cho đến khi nó trở thành một hình tròn hoàn hảo? Một hình tròn hoàn hảo tự mang tính đối xứng ở mọi góc độ (trong toán học gọi là có *nhóm ổn định không tầm thường - non-trivial stabilizers*). Lúc này, mọi trục đều dài bằng nhau, và hàm chuẩn hóa sẽ bị bối rối và sẽ buộc phải chọn đại một hướng ngẫu nhiên làm chuẩn. Hậu quả nghiêm trọng xảy ra khi hình tròn này bị nhiễu động một chút xíu (ví dụ bị bóp méo nhẹ 0.001 cm ở một góc 45°). Ngay lập tức, hàm chuẩn hóa sẽ phát hiện ra trục dài mới này và đột ngột xoay toàn bộ hình đi 45°. Một sự thay đổi cực nhỏ ở đầu vào lại dẫn đến một cú nhảy vọt khổng lồ ở đầu ra, chính là định nghĩa của *sự gián đoạn*.

Giải pháp: Weighted Frames và Robust Frames.

Để cứu vãn tính liên tục mà không làm mất đi sự gọn nhẹ của phương pháp chuẩn hóa, Dym et al. (2024) đề xuất việc nâng cấp chuẩn hóa thành các *weighted frames*. Nếu chuẩn hóa truyền thống là hành động cực đoan: gán 100% niềm tin vào một góc xoay duy nhất, thì khung có trọng số cho phép phân bổ niềm tin (trọng số xác suất) cho nhiều góc xoay khác nhau.

Dựa trên ý tưởng đó, bài báo giới thiệu *Robust Frames* - những khung được thiết kế



đặc biệt để triệt tiêu sự gián đoạn. Quay lại ví dụ hình elip biến thành hình tròn: Khi hình elip ngày càng tròn, độ dài hai trục dần bằng nhau. Thay vì cứ cố chấp chọn một trục duy nhất một cách cực đoan, một khung bền vững sẽ bắt đầu chia sẻ trọng số dần dần cho cả hai trục. Khi nó biến thành một hình tròn hoàn hảo, trọng số sẽ được chia đều 50/50 cho cả hai hướng không thể phân biệt. Khi hình tròn bị bóp méo nhẹ trở lại thành elip, trọng số sẽ thay đổi rất mượt mà (ví dụ thành 51/49), hoàn toàn không xảy ra bất kỳ cú nhảy vọt nào.

Sự chuyển đổi mượt mà này chính là chìa khóa đảm bảo tính liên tục cho mô hình học máy. Kết quả thực nghiệm của bài báo đã chứng minh sức mạnh của ý tưởng này: việc sử dụng các khung bền vững cho bài toán phân loại điểm đám mây 2D giúp tăng độ chính xác đáng kể (từ 85.6% lên đến 88.7%), đồng thời khắc phục triệt để sự thiếu ổn định mà các mạng neural gặp phải khi cố gắng học các hàm chuẩn hóa gián đoạn thông qua các thuật toán như trực giao hóa Gram-Schmidt.

Tổng kết:

Nhìn chung thì chuẩn hóa là kỹ thuật vô cùng hiệu quả và cực kì rẻ về tính toán, đặc biệt là so với việc phải tăng cường dữ liệu hay lấy trung bình nhóm trên các nhóm G khổng lồ. Tuy nhiên, qua sự phân tích của Dym et al., kỹ thuật này vấp phải một rào cản chí mạng về tính liên tục, làm giảm sự ổn định của mô hình. Đây cũng chính là động lực lớn nhất để các nhà nghiên cứu chuyển hướng sang các kỹ thuật dung hòa hơn nhưng vẫn mạnh mẽ về lý thuyết, tiêu biểu là phương pháp lấy trung bình nhóm và lấy trung bình khung, sẽ được trình bày chi tiết ở mục tiếp theo.

3.1.3. Lấy trung bình nhóm

Lấy trung bình nhóm

Một trong những phương pháp nền tảng và có cơ sở toán học vững chắc nhất để xây dựng mô hình invariant hoặc equivariant là sử dụng toán tử Reynolds, hay còn gọi là lấy trung bình nhóm. Cụ thể, cho mạng neural cơ sở ϕ và Φ , ta định nghĩa các hàm invariant $\langle \phi \rangle_G$ và equivariant $\langle \Phi \rangle_G$ bằng cách tính trung bình đầu ra trên toàn bộ các phép biến đổi g thuộc nhóm đối xứng G :

$$\langle \phi \rangle_G(X) = \frac{1}{|G|} \sum_{g \in G} \phi(\rho_1(g)^{-1}X) \quad (3.5)$$

$$\langle \Phi \rangle_G(X) = \frac{1}{|G|} \sum_{g \in G} \rho_2(g) \Phi(\rho_1(g)^{-1}X) \quad (3.6)$$



trong đó ρ_1 và ρ_2 là các biểu diễn nhóm tác động lên không gian đầu vào V và không gian đầu ra W .

Ưu điểm lớn nhất của phương pháp này là nó đảm bảo tính đối xứng một cách chính xác và bảo toàn hoàn toàn khả năng biểu diễn của mô hình cơ sở. Nếu mô hình cơ sở có khả năng xấp xỉ phổ quát, thì mô hình sau khi lấy trung bình cũng sẽ là một hàm phổ quát trên không gian các hàm đối xứng.

Dù vậy thì khi áp dụng vào thực tế phương pháp này vấp phải một rào cản cực lớn về độ phức tạp tính toán. Khi nhóm G quá lớn (ví dụ nhóm hoán vị S_n với kích thước $n!$) hoặc liên tục vô hạn (như nhóm quay $SO(3)$), việc tính toán chính xác tổng hoặc tích phân trên toàn bộ nhóm là bất khả thi. Việc tính xấp xỉ bằng Monte Carlo thường được sử dụng để giảm tải, nhưng điều này lại làm mất đi sự đảm bảo chắc chắn về mặt toán học của tính đối xứng.

Ứng dụng và xấp xỉ cho nhóm hoán vị: Janossy Pooling.

Một minh chứng tiêu biểu cho phương pháp lấy trung bình nhóm khi áp dụng cho nhóm hoán vị S_n chính là *Janossy Pooling*, được giới thiệu bởi Murphy et al. (2019) trong bài báo *Janossy Pooling: Learning Deep Permutation-Invariant Functions for Variable-Size Inputs*^[9]. Ý tưởng cơ bản rất đơn giản: nếu bạn có một chuỗi dữ liệu (ví dụ 10 từ) và muốn mô hình xử lý nó mà không quan tâm đến thứ tự từ, bạn cứ hoán vị chuỗi đó thành tất cả các cách có thể ($10! \approx 3.6$ triệu cách), đưa tất cả qua một hàm học (như mạng LSTM), rồi lấy trung bình cộng tất cả các kết quả lại. Về mặt toán học, đây chính là việc áp dụng toán tử Reynolds hoàn hảo cho nhóm S_n .

Tất nhiên, do kích thước nhóm $|S_n| = n!$ tăng lên theo hàm giai thừa, việc tính toán chính xác biểu thức Janossy Pooling là bất khả thi với các đầu vào lớn (ví dụ như số lượng nốt trong một đồ thị). Do đó, để đưa phương pháp này vào ứng dụng thực tiễn, bài báo đã đề xuất ba chiến lược xấp xỉ nhằm đạt được sự khả thi về mặt tính toán (tractability):

- **Xếp thứ tự theo chuẩn (Canonical orderings):** Thay vì thử mọi hoán vị, ta sắp xếp dữ liệu theo một luật cố định (ví dụ: sắp xếp giảm dần) rồi mới đưa vào mô hình. Cách này loại bỏ hoàn toàn việc phải tính tổng khổng lồ kia, biến độ phức tạp về 1.
- **Phụ thuộc bậc k (k-ary dependencies):** Thay vì hàm cơ sở phụ thuộc vào toàn bộ n phần tử, ta giả định nó chỉ xem xét k phần tử đầu tiên. Điều này giúp giảm số lượng hoán vị cần đánh giá từ $n!$ xuống chỉ còn $\frac{n!}{(n-k)!}$, rất hiệu quả khi k nhỏ. Kiến trúc nổi tiếng DeepSets^[10] thực chất chính là một trường hợp đặc biệt của Janossy



pooling với $k = 1$.

- **Lấy mẫu hoán vị ngẫu nhiên (π -SGD):** Trong quá trình huấn luyện, thay vì tính tổng trên toàn bộ hoán vị, ta chỉ lấy mẫu một hoặc vài hoán vị ngẫu nhiên của chuỗi và sử dụng Stochastic Gradient Descent (được gọi là π -SGD) để tối ưu hóa. Bằng cách kết hợp với các mô hình biểu diễn chuỗi mạnh mẽ như LSTM hay GRU, thuật toán này giúp mô hình bắt được các tương quan phức tạp trong chuỗi mà vẫn duy trì được hiệu suất tính toán cực cao.

Thông qua các chiến lược xấp xỉ này, Janossy Pooling không chỉ cung cấp một khuôn khổ lý thuyết thống nhất bao trùm nhiều kiến trúc bất biến hoán vị, mà còn chỉ ra một hướng đi thực tiễn để cân bằng giữa sức mạnh biểu diễn và chi phí tính toán khi làm việc với phương pháp lấy trung bình nhóm khổng lồ.

3.1.4. Lấy trung bình khung

Từ lấy trung bình nhóm đến lấy trung bình khung.

Để giải quyết triệt để rào cản tính toán của phương pháp lấy trung bình nhóm mà không phải đánh đổi tính liên tục hay làm mất đi sự đảm bảo đối xứng tuyệt đối (như khi xấp xỉ bằng Monte Carlo hay lấy mẫu), Puny et al. (2022) đã đề xuất lý thuyết *Frame Averaging* trong bài báo *Frame Averaging for Invariant and Equivariant Network Design*^[11]. Nhận định cốt lõi của công trình này là: thay vì tính trung bình trên toàn bộ nhóm G , ta hoàn toàn có thể chỉ thực hiện lấy trung bình trên một tập hợp con rất nhỏ $\mathcal{F}(X) \subset G$ được gọi là *khung* (*frame*).

Ví dụ cho khái niệm về khung

Để dễ hình dung, giả sử ta muốn đo nhiệt độ trung bình của một hành tinh hình cầu hoàn hảo. Việc lấy trung bình nhóm tương đương với việc ta phải đi đo nhiệt độ ở vô hạn điểm trên bề mặt hành tinh. Tuy nhiên, vì hành tinh có tính đối xứng tuyệt đối, bạn thực ra chỉ cần chọn một khung gồm đúng 6 điểm đại diện (ví dụ: 2 điểm ở cực và 4 điểm quanh xích đạo). Miễn là cái khung 6 điểm này luôn xoay theo đúng cách mà hành tinh xoay, thì giá trị trung bình của 6 điểm này sẽ chính xác tuyệt đối bằng trung bình của toàn bộ vô hạn điểm trên hành tinh.

Trong toán học, việc khung phải xoay theo dữ liệu được gọi là điều kiện *tương biến tập hợp*:


$$\mathcal{F}(\rho_1(g)X) = g\mathcal{F}(X) \quad \forall X \in V, g \in G. \quad (3.7)$$

Nói cách khác, khi điểm dữ liệu đầu vào X bị biến đổi bởi phần tử g , thì toàn bộ tập hợp các phép biến đổi trong khung cũng bị dịch chuyển một lượng tương ứng bởi g . Khi điều kiện nghiêm ngặt này được thỏa mãn, toán tử lấy trung bình nhóm ở các công thức (3.5) và (3.6) có thể được thay thế hoàn toàn bằng việc lấy trung bình trên khung $\mathcal{F}(X)$:

$$\langle \phi \rangle_{\mathcal{F}}(X) = \frac{1}{|\mathcal{F}(X)|} \sum_{g \in \mathcal{F}(X)} \phi(\rho_1(g)^{-1}X) \quad (3.8)$$

$$\langle \Phi \rangle_{\mathcal{F}}(X) = \frac{1}{|\mathcal{F}(X)|} \sum_{g \in \mathcal{F}(X)} \rho_2(g)\Phi(\rho_1(g)^{-1}X). \quad (3.9)$$

Puny et al. (2022) đã chứng minh mạnh mẽ rằng kỹ thuật lấy trung bình khung cung cấp sự đảm bảo tính bất biến và tương biến hoàn hảo y hệt như lấy trung bình toàn nhóm, đồng thời bảo toàn sức mạnh biểu diễn tối đa của mạng neural cơ sở^[11]. Khung có thể được xem như một giải pháp dung hòa tuyệt vời giữa chuẩn hóa (chỉ chọn 1 phần tử) và lấy trung bình nhóm (chọn tất cả phần tử), tận dụng được ưu điểm của cả hai. Hình 3.5 minh họa một cách trực quan cơ chế hoạt động của một hàm khung.



Hình 3.5: Minh họa tính chất equivariance của hàm khung.

Ghi chú: Khối cầu bên trái là không gian nhóm G , hình chữ nhật bên phải là không gian dữ liệu V . Ánh xạ khung $\mathcal{F}$ gán một tập con các phép biến đổi trong G cho mỗi điểm dữ liệu trong V . Khi điểm X bị biến đổi thành $\rho_1(g)X$, tập hợp khung cũng bị dịch chuyển một lượng g tương ứng. Vẽ lại dựa trên biểu đồ từ bài báo^[11], trang 3.

Ứng dụng thực tiễn cho Point Clouds.

Ví dụ: Trích xuất khung cho point clouds

Một ví dụ cho phương pháp này là việc tạo ra các mạng bất biến xoay 3D ($E(3)$). Tưởng tượng bạn có một point cloud biểu diễn một chiếc máy bay. Thay vì phải



lấy trung bình qua mọi góc xoay 360° có thể có trong không gian 3 chiều (điều này đòi hỏi tính toán trên vô hạn góc), ta dùng thuật toán *Phân tích thành phần chính (PCA)* để tìm ra 3 trục đối xứng chính của chiếc máy bay (trục dọc thân, trục dọc cánh, và trục thẳng đứng).

Vì mỗi trục có hai hướng (chiều dương và chiều âm), ta có chính xác $2 \times 2 \times 2 = 8$ hệ trục tọa độ khác nhau. Tập hợp 8 hệ trục tọa độ này chính là khung của chiếc máy bay. Lúc này, mô hình chỉ cần tính toán và lấy trung bình trên đúng 8 hệ trục này, thay vì vô hạn góc xoay. Sự sụt giảm khối lượng tính toán từ ∞ xuống còn 8 là một bước nhảy vọt khổng lồ, mà lại mang đến cho ta mô hình có tính equivariance tuyệt đối một cách hoàn hảo.


Phương pháp	Chi phí tính toán	Tính liên tục	Tính phổ quát
Canonicalization	Rất thấp	Không	Không
Frame averaging	Thấp	Có	Có
Group averaging	Cực cao / Không khả thi	Có	Có

Bảng 3.1: So sánh ba phương pháp can thiệp dữ liệu để đưa tính đối xứng vào mạng neural. Lấy trung bình khung nổi lên như một điểm cân bằng hoàn hảo giữa chi phí triển khai thực tế và sức mạnh lý thuyết toán học.

Qua bảng phân tích, frame averaging vượt trội vì khắc phục được nhược điểm thiếu liên tục của chuẩn hóa, đồng thời giải quyết bài toán độ phức tạp của lấy trung bình nhóm, biến nó thành công cụ mạnh mẽ hàng đầu cho các tác vụ như phân tích đồ thị cấu trúc nguyên tử hay mô phỏng vật lý đa hạt.

3.2 Hướng 2: Xây dựng kiến trúc tương biến từ đầu

Nếu Hướng 1 xem mô hình học máy như một hộp đen và truyền đạt tính đối xứng từ bên ngoài thông qua thao tác dữ liệu, thì Hướng 2 lựa chọn con đường triệt để hơn: mã hóa cứng tính đối xứng vào chính kiến trúc của mạng. Mô hình tương biến được xây dựng theo cấu trúc tổng quát sau.



Hình 3.6: Cấu trúc tổng quát của mô hình tương biến: xen kẽ các lớp tuyến tính tương biến với hàm kích hoạt phi tuyến σ , kết thúc bằng một lớp gộp bất biến toàn cục.

Ưu điểm cốt lõi của hướng này:

- Tính đối xứng được đảm bảo tuyệt đối tại mọi điểm dữ liệu, kể cả những điểm chưa thấy trong quá trình huấn luyện.
- Số tham số giảm mạnh do cơ chế chia sẻ, dẫn đến hiệu quả dữ liệu cao hơn.
- Đặc biệt phù hợp khi tính đối xứng là điều chắc chắn về mặt vật lý hoặc toán học (phân tử, robot, đồ thị).

3.2.1. Lớp tuyến tính tương biến và cơ chế chia sẻ tham số


Nguyên lý xây dựng. Một lớp tuyến tính $\mathbf{W} \in \mathbb{R}^{n \times n}$ đảm bảo tính tương biến với nhóm G khi và chỉ khi nó thỏa mãn ràng buộc sau với mọi phần tử $\tau \in G$:

$$P_{\tau} \mathbf{W} P_{\tau}^{\top} = \mathbf{W} \quad (3.10)$$

Ràng buộc này kéo theo một hệ quả quan trọng: nếu tồn tại phép biến đổi $\tau \in G$ ánh xạ cặp chỉ số (i, j) thành (k, l) , thì bắt buộc $W_{ij} = W_{kl}$. Đây là cơ chế **chia sẻ tham số**: các vị trí cùng quỹ đạo trong G phải mang cùng giá trị, và mỗi quỹ đạo chỉ tương ứng với một tham số tự do duy nhất.

Ví dụ 1: Nhóm dịch chuyển tuần hoàn dẫn đến phép tích chập.

Xét tín hiệu một chiều với nhóm dịch chuyển $G = C_n = \{t_0, t_1, \dots, t_{n-1}\}$, trong đó $t_i(j) = i + j \pmod{n}$.




Ma trận $\mathbf{W}$ sau khi áp ràng buộc: chỉ $n = 5$ tham số

Hình 3.7: Ma trận trọng số $\mathbf{W}$ sau khi áp ràng buộc tương biến với nhóm dịch chuyển tuần hoàn C_5 . Các ô cùng màu chia sẻ cùng một giá trị tham số. Cấu trúc này chính xác là ma trận circulant của phép tích chập.

- Số tham số giảm từ n^2 xuống còn n , tiết kiệm n lần.
- Cấu trúc lặp lại theo đường chéo này chính là định nghĩa của phép **tích chập** (convolution).
- *Kết luận*: mạng tích chập không phải là thiết kế tùy hứng mà là hệ quả tất yếu của việc áp đặt tính tương biến với nhóm dịch chuyển.

Ví dụ 2: Nhóm hoán vị toàn phần dẫn đến kiến trúc DeepSets.

Xét đầu vào là tập hợp n vector $\{x_1, \dots, x_n\} \subset \mathbb{R}^d$ và ta muốn mô hình bất biến với mọi phép hoán vị phần tử, tức $G = S_n$.



Ma trận $\mathbf{W}$ với $G = S_5$: chỉ **2** tham số

Hình 3.8: Ma trận trọng số $\mathbf{W}$ sau khi áp ràng buộc tương biến với nhóm hoán vị S_n . Toàn bộ ma trận $n \times n$ chỉ còn 2 giá trị: α_1 trên đường chéo và α_2 ở tất cả vị trí còn lại.

Kết quả là lớp tuyến tính tương biến có dạng cực kỳ đơn giản:

$$[\mathbf{F}(\mathbf{X})]_i = \alpha_1 x_i + \alpha_2 \sum_{j \neq i} x_j \quad (3.11)$$

- Số tham số giảm từ n^2 xuống còn **2**, bất kể kích thước n .



- Mỗi điểm được biến đổi kết hợp giữa chính nó và tổng tất cả điểm còn lại.
- Đây chính xác là kiến trúc **DeepSets** và **PointNet**.
- Mở rộng: với tensor bậc cao hơn hoặc các nhóm phức tạp hơn (ví dụ hoán vị ma trận kề của đồ thị), số phần tử cơ sở tăng lên nhưng vẫn ít hơn rất nhiều so với n^2 . Với hoán vị đồng thời hàng và cột của ma trận kề, số cơ sở chỉ là 15.

3.2.2. Tích chập nhóm

Từ tích chập thông thường đến tích chập nhóm.

Tích chập thông thường trên lưới $\mathbb{Z}^2$ thực hiện phép trượt bộ lọc ψ qua toàn bộ các phép tịnh tiến:

$$(f \star \psi)(x) := \sum_{y \in \mathbb{Z}^2} f(y) \psi(y - x) \quad (3.12)$$

Quan sát rằng phép trừ $y - x$ chính là tác động của phép tịnh tiến ngược. Điều này gợi ý cách tổng quát hóa tự nhiên: thay toàn bộ phép tịnh tiến bằng một nhóm đối xứng bất kỳ G .

CNN thông thường

Bộ lọc trượt theo
phép **tịnh tiến**
Tương biến tịnh tiến

$\Rightarrow$
tổng quát hóa

Tích chập nhóm

Bộ lọc trượt theo
mọi phần tử của G
Tương biến với G

Hình 3.9: So sánh tích chập thông thường và tích chập nhóm. Tích chập nhóm là sự tổng quát hóa trực tiếp: thay vì chỉ trượt theo phép tịnh tiến, bộ lọc được trượt qua toàn bộ các phần tử của nhóm G .

- Nếu G là nhóm tịnh tiến trên $\mathbb{Z}^2$, tích chập nhóm hoàn toàn trùng với CNN thông thường.
- Nếu G bổ sung thêm các phép xoay 90 và phản chiếu, bộ lọc sẽ tự động bất biến với 8 phép đối xứng của hình vuông (nhóm dihedral D_4).
- Tích chập nhóm là nền tảng của **mạng tích chập tương biến nhóm**, mở rộng CNN sang các nhóm đối xứng tùy ý.


3.2.3. Lý thuyết bất biến và tham số hóa qua đại lượng bất biến

Ý tưởng cốt lõi. Thay vì thiết kế lại toàn bộ kiến trúc, ta có thể tham số hóa trực tiếp các hàm bất biến thông qua một tập hợp nhỏ các đại lượng vô hướng bất biến đơn giản.

Định lý 3.2 (Định lý cơ bản cho nhóm $O(d)$). Mọi hàm $f : (\mathbb{R}^d)^n \rightarrow \mathbb{R}$ bất biến với nhóm xoay và phản chiếu $O(d)$ đều có thể biểu diễn dưới dạng:

$$f(v_1, \dots, v_n) = h\left(\{v_i^\top v_j\}_{i,j=1}^n\right) \quad (3.13)$$

trong đó h là một hàm bất kỳ tác động lên ma trận Gram của các tích vô hướng.



Hình 3.10: Minh họa định lý cơ bản: mọi hàm bất biến với $O(d)$ đều có thể được tính từ ma trận Gram của các tích vô hướng, bất kể số chiều d hay số điểm n .

- **Tại sao đúng:** phép xoay và phản chiếu bảo toàn góc và khoảng cách, tức là bảo toàn chính xác các tích vô hướng $v_i^\top v_j$.
- **Tại sao mạnh:** định lý đảm bảo tính phổ quát, không có thông tin bất biến nào bị bỏ sót.
- **Với hàm tương biến $O(d)$:** mở rộng thêm tổng tuyến tính của các vector:

$$f(v_1, \dots, v_n) = h(\{v_i^\top v_j\}) \cdot \sum_t v_t.$$
- **Với tính bất biến tịnh tiến:** chỉ cần chuyển sang hệ tọa độ tương đối:

$$f(v_1, \dots, v_n) = h(v_2 - v_1, v_3 - v_1, \dots, v_n - v_1).$$
- **Thực tiễn:** hàm h được tham số hóa bởi một mạng nơ-ron thông thường đặt trên đầu các đặc trưng bất biến đã tính sẵn.

3.2.4. Phương pháp tensor và giới hạn của bổ đề Schur

Vấn đề: tại sao lớp tuyến tính tương biến đơn thuần không đủ?


- Mạng nhiều lớp tuyến tính tương biến xen kẽ hàm kích hoạt đặt ra câu hỏi: liệu có đủ sức biểu diễn để xấp xỉ mọi hàm tương biến liên tục không?
- **Bổ đề Schur** từ lý thuyết biểu diễn nhóm chỉ ra: với một số nhóm liên tục, các ánh xạ tuyến tính tương biến bị hạn chế nghiêm trọng.

Ví dụ 3.3. Với nhóm xoay $SO(2)$ tác động trên $\mathbb{R}^2$, ánh xạ tuyến tính tương biến duy nhất là bội của ma trận đơn vị: $L(x) = \lambda x$, $\lambda \in \mathbb{R}$. Lớp tuyến tính tương biến không thể tạo ra bất kỳ biểu diễn phong phú nào.

Giải pháp: nâng đầu vào lên không gian tensor.

Thay vì làm việc trực tiếp với $x \in \mathbb{R}^d$, ta dùng lũy thừa tensor bậc k :

$$x^{\otimes k} = \underbrace{x \otimes x \otimes \cdots \otimes x}_{k \text{ lần}} \in (\mathbb{R}^d)^{\otimes k} \quad (3.14)$$




Hình 3.11: Phương pháp tensor: nâng đầu vào lên không gian tensor bậc k để vượt qua giới hạn của bổ đề Schur và đạt được tính phổ quát.

- Không gian tensor $(\mathbb{R}^d)^{\otimes k}$ có cấu trúc biểu diễn nhóm vô cùng phong phú, vượt qua giới hạn của bổ đề Schur.
- Xây dựng MLP tương biến trên $x^{\otimes k}$ đạt được tính phổ quát khi k đủ lớn.
- **Thách thức kỹ thuật:** phân rã biểu diễn nhóm trên $(\mathbb{R}^d)^{\otimes k}$ đòi hỏi tính toán hệ số Clebsch-Gordan.
 - Với nhóm xoay $SO(d)$ và phản chiếu $O(d)$: giải được hiệu quả.
 - Với các nhóm hữu hạn tổng quát: là bài toán khó nổi tiếng trong lý thuyết biểu diễn.

3.2.5. Ứng dụng: mạng đồ thị tương biến và bài toán hệ nguyên tử

Bài toán và cấu trúc dữ liệu.

- Một hệ nguyên tử gồm N nguyên tử được biểu diễn dưới dạng một đồ thị có định hướng.
- Mỗi nút i mang: đặc trưng loại nguyên tử $h_i \in \mathbb{R}^c$ (vô hướng) và tọa độ không gian $\mathbf{r}_i \in \mathbb{R}^3$ (vector).
- Bài toán yêu cầu dự đoán năng lượng toàn phần E của hệ, vốn là một hàm bất biến với nhóm Euclide $E(3)$ gồm phép xoay, phản chiếu và tịnh tiến, đồng thời bất biến với mọi phép hoán vị nguyên tử cùng loại.




Hình 3.12: Minh họa bài toán hệ nguyên tử: phân tử H_2O được biểu diễn dưới dạng đồ thị. Mỗi nút mang đặc trưng vô hướng h_i (loại nguyên tử) và tọa độ vector $\mathbf{r}_i$. Mô hình cần dự đoán năng lượng E bất biến với mọi phép biến đổi $E(3)$.

Cơ chế truyền thông tin tương biến.

Mạng nơ-ron tương biến cập nhật lặp lại cả đặc trưng ẩn $h_i^{(\ell)}$ lẫn tọa độ $\mathbf{x}_i^{(\ell)}$ tại mỗi lớp ℓ , đảm bảo toàn bộ quá trình tương biến với $E(3)$:

$$\mathbf{x}_i^{(\ell+1)} = \mathbf{x}_i^{(\ell)} + C \sum_{j \neq i} \left(\mathbf{x}_i^{(\ell)} - \mathbf{x}_j^{(\ell)} \right) \cdot \varphi \left(h_i^{(\ell)}, h_j^{(\ell)}, \left\| \mathbf{x}_i^{(\ell)} - \mathbf{x}_j^{(\ell)} \right\|^2, a_{ij} \right) \quad (3.15)$$

trong đó φ là một mạng nơ-ron nhỏ và a_{ij} là đặc trưng cạnh bổ sung.




Hình 3.13: Cơ chế cập nhật tương biến: hàm message φ chỉ nhận khoảng cách bình phương $\|x_i - x_j\|^2$ (một đại lượng bất biến) thay vì tọa độ tuyệt đối, đảm bảo kết quả tương biến với nhóm $E(3)$.

- Hàm φ chỉ nhận **khoảng cách bình phương** $\|x_i - x_j\|^2$, một đại lượng bất biến với $E(3)$, thay vì tọa độ tuyệt đối.
- Cập nhật tọa độ theo hướng $(x_i - x_j)$ đảm bảo đầu ra tương biến: xoay đầu vào thì đầu ra cũng xoay theo đúng cách đó.
- Đặc trưng vô hướng h_i và tọa độ vector x_i được cập nhật đồng thời qua nhiều lớp, làm giàu dần biểu diễn.

Lợi ích đặc biệt: tính toán lực miễn phí qua vi phân tự động.

Sau khi mô hình dự đoán được năng lượng E , lực tác dụng lên từng nguyên tử thu được hoàn toàn miễn phí:

$$\mathbf{F}_i = -\frac{\partial E}{\partial \mathbf{r}_i} \quad (3.16)$$



Hình 3.14: Sơ đồ tính lực qua vi phân tự động: mô hình chỉ được huấn luyện dự đoán năng lượng E (vô hướng), nhưng đồng thời cung cấp $3N$ thành phần lực vector nhất quán và đảm bảo tính đối xứng.

- Mô hình chỉ cần học dự đoán một đại lượng vô hướng (năng lượng), nhưng đồng thời cung cấp dự đoán cho $3N$ thành phần lực vector.
- Các lực này **nhất quán** với nhau và với năng lượng theo định luật bảo toàn, vì chúng đến từ cùng một hàm thế năng.



- Đây là lợi thế quyết định so với các mô hình dự đoán lực trực tiếp, vốn không đảm bảo tính nhất quán.

Ứng dụng mở rộng. Nguyên lý tương biến $E(3)$ trong mạng đồ thị không chỉ giới hạn ở hệ nguyên tử, mà còn được áp dụng rộng rãi trong:

- **Sinh protein:** các mô hình Chroma và RFDiffusion dùng GNN tương biến kết hợp với hệ tọa độ địa phương để tạo sinh cấu trúc protein.
- **Dự đoán liên kết phân tử:** tương biến $SE(3)$ cho phép mô hình nắm bắt hướng và hình dạng của túi liên kết kháng nguyên-kháng thể.
- **Điều khiển robot:** tương biến $SO(2)/SE(3)$ trong học tăng cường cho phép chính sách tối ưu tự động điều chỉnh khi robot bị xoay hoặc dịch chuyển trong không gian (được trình bày chi tiết ở Mục 3.5).

3.3 NequIP: Mạng nơ-ron đồ thị tương biến cho thể năng nguyên tử

Để cụ thể hóa những nền tảng lý thuyết trừu tượng về mạng đồ thị tương biến và phương pháp tensor, bài hướng dẫn tại hội nghị NeurIPS 2025 đã phân tích chuyên sâu một công trình nghiên cứu mang tính bước ngoặt trong lĩnh vực hóa học tính toán của Batzner và cộng sự công bố năm 2022^[5]. Việc lựa chọn công trình này nhằm minh họa cách các phương trình hình học phức tạp được thiết lập trực tiếp vào lõi kiến trúc mạng, đồng thời làm nổi bật hệ quả quan trọng của các thiết kế tương biến trong việc nâng cao hiệu suất sử dụng dữ liệu.


3.3.1. Bài toán và động lực nghiên cứu

Nghiên cứu này xuất phát từ một nút thắt cổ chai trong khoa học vật liệu và hóa học tính toán. Các phương pháp tính toán lượng tử từ đầu như DFT cho độ chính xác rất cao nhưng chi phí tính toán tăng theo cấp số nhân với kích thước hệ thống, khiến các mô phỏng quy mô lớn gặp nhiều rào cản. Các mạng nơ-ron thể hệ trước có khả năng học lại các quy luật này với tốc độ suy luận nhanh hơn, nhưng lại đòi hỏi hàng nghìn đến hàng triệu cấu trúc để huấn luyện. Trong khi đó, việc thu thập dữ liệu bằng cơ học lượng tử lại tiêu tốn chi phí rất lớn^[5].

Hạn chế cốt lõi của các mô hình bất biến truyền thống là chúng chỉ nhìn nhận cấu trúc nguyên tử qua khoảng cách vô hướng. Việc này làm mất đi thông tin về phương hướng trong không gian ba chiều. Hệ quả kéo theo là đường cong học tập của các mô hình này tuân theo một quy luật lũy thừa cố định, trong đó các cải tiến kiến trúc thường chỉ làm giảm hệ số sai số nền chứ không thể thay đổi độ dốc của đường cong. Kiến trúc NequIP ra đời hướng tới việc phá vỡ giới hạn này bằng cách duy trì trọn vẹn thông tin hướng không gian thông qua các tensor hình học đa bậc, cho phép mô hình huấn luyện hiệu quả trên các tập dữ liệu tham chiếu có kích thước nhỏ nhưng đạt độ chính xác cao như cấu hình CCSD(T).

3.3.2. Kiến trúc NequIP và cơ chế tương biến

Cấu trúc của mạng NequIP được chia thành ba khối xử lý nối tiếp nhau bao gồm khối nhúng, khối tương tác và khối đầu ra.



Hình 3.15: Luồng dữ liệu qua ba khối chính của mô hình NequIP.

Tại khối nhúng, đặc trưng ban đầu của mỗi nguyên tử được khởi tạo dựa trên số hiệu nguyên tử. Ở bước này, tất cả các đặc trưng đều được biểu diễn dưới dạng đại lượng vô hướng. Tiếp theo là khối tương tác, nơi quá trình xử lý tương biến chính thức diễn ra. Đặc trưng nguyên tử được mở rộng thành các tensor hình học ở nhiều bậc khác nhau. Mỗi lớp cập nhật đồng thời các tensor này bằng cách sử dụng cấu trúc tương tự mạng ResNet để ổn định quá trình huấn luyện, kết hợp cùng hàm kích hoạt tương biến SiLU. Khối đầu ra làm nhiệm vụ loại bỏ các phần tử tensor có hướng, chỉ giữ lại thành phần vô hướng và đưa qua các lớp tự tương tác để tổng hợp thành một giá trị duy nhất đại diện cho thế năng của toàn hệ thống^[5].

Về cơ chế xử lý cốt lõi, việc truyền thông điệp giữa các nút trong đồ thị được thực hiện thông qua phép tích chập tương biến E(3). Để làm được điều này, hệ thống thay thế các bộ lọc tích chập thông thường bằng sự kết hợp giữa một mạng nơ-ron học tham số từ khoảng cách vô hướng và các hàm điều hòa cầu. Mạng nơ-ron xử lý khoảng cách đảm bảo tính bất biến với tịnh tiến và phản xạ. Cùng lúc đó, các hàm điều hòa cầu mã hóa hướng của vectơ nối giữa hai nguyên tử, giúp kết quả tính toán luôn duy trì sự tương biến với


phép xoay trong không gian ba chiều.

$$W_{ij}^{(l,m)} = R(r_{ij}) \cdot Y_m^{(l)}(\hat{r}_{ij}) \quad (3.17)$$

Khi tiến hành kết hợp đặc trưng của nguyên tử và bộ lọc, phép nhân ma trận thông thường sẽ làm vỡ cấu trúc đối xứng. Để khắc phục, mô hình vận hành phép tích tensor thông qua hệ số Clebsch-Gordan [5]. Cơ chế này đóng vai trò như một bộ quy tắc chọn lọc khắt khe giúp các đặc trưng không gian được kết hợp chuẩn xác, đảm bảo kết quả được đưa vào đúng không gian biểu diễn của bậc mới.

$$(f^{(l_1)} \otimes_{\text{CG}} W^{(l_2)})_m^{(l)} = \sum_{m_1, m_2} C_{m_1 m_2}^{(l_1 l_2) l m} f_{m_1}^{(l_1)} W_{m_2}^{(l_2)} \quad (3.18)$$

Sau khi khởi đầu ra dự đoán được giá trị thế năng vô hướng, lực tác dụng lên từng nguyên tử được suy ra thông qua cơ chế vi phân tự động. Hệ thống tính đạo hàm của thế năng theo tọa độ không gian, cung cấp đồng thời các thành phần lực vector mà không cần bổ sung tham số huấn luyện. Phương pháp tính toán này tuân thủ định luật bảo toàn năng lượng, giúp các mô phỏng động lực học phân tử duy trì sự ổn định bền vững trong thời gian dài mà không bị cộng dồn sai số vật lý.




Hình 3.16: Quy trình tính lực qua vi phân tự động trong NequIP.

3.3.3. Kết quả thực nghiệm và hiệu quả dữ liệu

Về mặt thực nghiệm, kiến trúc này thể hiện năng lực dự đoán trên nhiều hệ vật lý phức tạp. Đối với phân tử hữu cơ nhỏ trong tập dữ liệu MD-17 và rMD-17, mô hình đánh bại các mạng nơ-ron và phương pháp kernel tốt nhất hiện có về cả sai số năng lượng lẫn lực [5]. Ứng dụng trên các hệ thống xúc tác dị thể phức tạp kết hợp nhiều loại liên kết hóa học hay mô phỏng sự hình thành thủy tinh, mạng đều cho thấy khả năng tái tạo chính xác các chỉ số như RDF và ADF.

Đóng góp mang tính đột phá của NequIP nằm ở hiệu suất sử dụng dữ liệu. Trong bài toán mô phỏng nước lỏng và băng, kiến trúc đề xuất chỉ cần hơn một trăm cấu trúc huấn

luyện để vượt qua hiệu suất của các mô hình thể hệ trước vốn được huấn luyện trên hàng trăm nghìn cấu trúc. Mức cải thiện hiệu quả dữ liệu này đạt tới ba bậc độ lớn.



Hình 3.17: Minh họa đường cong học tập của NequIP so với các mô hình tiêu biểu trên bài toán mô phỏng nước.

Về động lực học tập, việc đưa các tensor hình học vào mạng làm tăng độ dốc của đường cong học tập trong không gian logarit. Sự thay đổi về chất này minh chứng cho quan điểm cốt lõi của học máy hình học: khi hệ thống được cung cấp một nền tảng toán học phù hợp với quy luật tự nhiên, mỗi điểm dữ liệu mới thu thập được sẽ mang lại lượng thông tin lớn hơn rất nhiều so với trước đây^[5].

Bên cạnh những ưu điểm, kiến trúc này vẫn tồn tại một số giới hạn thực tiễn. Việc tính toán tích tensor qua hệ số Clebsch-Gordan đòi hỏi chi phí tính toán lớn, làm tăng thời gian huấn luyện và suy luận khi xử lý các hệ thống có quy mô hàng nghìn nguyên tử. Khoảng cách hiệu suất so với các mô hình bất biến cũng có xu hướng thu hẹp lại khi lượng dữ liệu trở nên dồi dào. Thêm vào đó, mô hình giả định tính đối xứng không gian một cách nghiêm ngặt, điều này có thể trở thành một ràng buộc cản trở đối với các hệ thống có tính đối xứng bị phá vỡ một phần. Cuối cùng, do chỉ xét các tương tác trong một bán kính ngắt cố định, các tương tác tầm xa cần được xử lý riêng biệt vì chúng không được mã hóa tự nhiên trong kiến trúc hiện tại^[5].



3.4 PointNet: Học sâu trên tập hợp điểm cho bài toán ba chiều

Bên cạnh các kiến trúc tiên tiến giải quyết bài toán tương biến $E(3)$ như NequIP, bài hướng dẫn tại NeurIPS 2025 cũng nhìn lại những nền tảng sơ khai nhất để minh họa cho cơ chế chia sẻ tham số. Cụ thể, khi thảo luận về tính bất biến hoán vị trên các tập dữ liệu không có thứ tự, diễn giả đã trích dẫn PointNet như một công trình tiên phong. Việc giới thiệu bài báo này nhằm làm rõ cách một ràng buộc toán học cực kỳ tinh gọn có thể giải quyết triệt để thách thức của dữ liệu đám mây điểm ba chiều, tạo ra một bộ khung chuẩn mực cho hàng loạt nghiên cứu về thị giác máy tính sau này. Dưới đây là các phân tích chi tiết về kiến trúc đột phá này.

- **Bài báo:** PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation.
- **Tác giả:** Charles R. Qi, Hao Su, Kaichun Mo, Leonidas J. Guibas thuộc Đại học Stanford.
- **Nơi xuất bản:** Hội nghị CVPR, 2017.
- **Liên kết bài báo:** <https://arxiv.org/abs/1612.00593>
- **Liên kết mã nguồn:** <https://github.com/charlesq34/pointnet>

3.4.1. Bài toán và động lực nghiên cứu

Dữ liệu hình học ba chiều, cụ thể là đám mây điểm mang cấu trúc bất quy tắc. Để đưa vào mạng nơ-ron học sâu, các nghiên cứu trước đó thường phải biến đổi chúng theo các cách như sau:

- **Mạng voxel:** Chuyển đám mây điểm thành các lưới thể tích ba chiều, tương tự như điểm ảnh nhưng trong không gian ba chiều. Cách này làm dữ liệu trở nên cồng kềnh không cần thiết và gây mất mát chi tiết do hiệu ứng lượng tử hóa.
- **Mạng đa góc nhìn:** Chiếu không gian ba chiều thành nhiều ảnh hai chiều rồi dùng mạng chập xử lý. Tuy nhiên, phương pháp này gặp khó khăn trong các bài toán cần phân tích từng điểm cụ thể như bài toán phân đoạn điểm.

Động lực thiết kế: PointNet ra đời với mục tiêu lấy trực tiếp đám mây điểm thô làm đầu vào. Quá trình này không cần qua bất kỳ phép biến đổi nào như voxel hóa hay kết xuất hình ảnh. Giải pháp này giúp tiết kiệm bộ nhớ và giữ nguyên bản chất hình học của vật thể.


3.4.2. Ba đặc tính cốt lõi của dữ liệu đám mây điểm

Một đám mây điểm được biểu diễn là tập hợp $\{P_i | i = 1, \dots, n\}$, với mỗi điểm có tọa độ (x, y, z) . Để xử lý dữ liệu này, mô hình phải giải quyết ba tính chất:

- Đám mây điểm chỉ là một tập hợp. Khi thay đổi thứ tự đọc các điểm, hình dáng vật thể không thay đổi. Do đó, mạng phải duy trì tính bất biến với $N!$ phép hoán vị của tập hợp điểm đầu vào.
- Các điểm nằm trong một không gian có thang đo khoảng cách nhất định, từ đó tạo thành các cấu trúc cục bộ có ý nghĩa.
- Việc xoay hoặc tịnh tiến đám mây điểm không được làm thay đổi nhãn phân loại hay kết quả phân đoạn của toàn bộ vật thể.

3.4.3. Kiến trúc PointNet và cơ chế hoạt động

Để giải quyết các đặc tính trên, PointNet sử dụng ba khối kỹ thuật mới:



Hình 3.18: Luồng trích xuất đặc trưng toàn cục của PointNet.

Hàm đối xứng: Thay vì sắp xếp dữ liệu hay dùng mạng tuần tự, PointNet xấp xỉ một hàm chung cho tập hợp thông qua phương trình xấp xỉ. Phương trình được thể hiện qua công thức: $f(\{x_1, \dots, x_n\}) \approx g(h(x_1), \dots, h(x_n))$. Trong đó, hàm h là mạng perceptron đa tầng giúp trích xuất đặc trưng độc lập cho từng điểm. Hàm g là hàm gộp cực đại đóng vai trò là một hàm đối xứng. Kết quả trả về là một vector duy nhất không phụ thuộc vào thứ tự điểm đầu vào.


Mạng căn chỉnh tự động:

- PointNet tích hợp một mạng con gọi là mạng T-Net để dự đoán ma trận biến đổi afin. Ma trận này được nhân trực tiếp vào tọa độ điểm đầu vào nhằm căn chỉnh chúng về một không gian chuẩn.
- Khi áp dụng trên không gian đặc trưng, mạng thêm một hàm mất mát chính quy hóa để ép ma trận căn chỉnh gần với ma trận trực giao. Công thức tính hàm mất mát được định nghĩa là: $L_{reg} = ||I - AA^T||_F^2$.

Kết hợp đặc trưng cục bộ và toàn cục:

- Đối với bài toán phân đoạn điểm, mô hình sẽ ghép nối vector đặc trưng toàn cục của vật thể với vector đặc trưng của từng điểm.
- Kỹ thuật này giúp mỗi điểm vừa có thông tin hình học của riêng nó, vừa nhận thức được bức tranh tổng thể của toàn bộ vật thể.

3.4.4. Khung xương vật thể và tính bền vững



Hình 3.19: Mô phỏng nguyên lý của mạng lưới.

Nguyên lý của hàm gộp cực đại:

- PointNet học cách tóm tắt hình dạng bằng một tập hợp thưa thớt các điểm quan trọng, được gọi chung là điểm tới hạn. Nhờ nguyên lý này, mạng lưới trở nên cực kỳ bền vững trước các dữ liệu nhiễu.
- Khi bị xóa ngẫu nhiên đến 50% số điểm của vật thể, độ chính xác của mạng chỉ sụt giảm rất nhẹ từ 2.4% đến 3.8%. Mạng vẫn hoạt động ổn định với độ chính xác trên 80% ngay cả khi đầu vào bị trộn lẫn 20% các điểm nhiễu ngoại lai.


3.4.5. Đánh giá hiệu năng và độ phức tạp tính toán

- Việc từ bỏ biểu diễn bằng điểm ảnh thể tích hay hình ảnh đã mang lại cho PointNet lợi thế về mặt thuật toán hệ thống.

- **Thời gian và không gian:** Độ phức tạp về không gian và thời gian của mô hình chỉ là $O(N)$, nghĩa là tăng tuyến tính theo số lượng điểm đầu vào N .
- **Hiệu suất cao:** PointNet tốn ít chi phí tính toán hơn 141 lần so với mạng đa góc nhìn, nhưng vẫn giữ được hiệu năng dẫn đầu trên các bài toán phân đoạn và phân loại.
- **Dung lượng nhẹ:** Mạng lưới chỉ có khoảng 3.5 triệu tham số, ít hơn 17 lần so với các kiến trúc mạng đa góc nhìn thông thường.
- **Tính ứng dụng:** Nhờ vào dung lượng nhẹ và tốc độ xử lý nhanh, mô hình này rất phù hợp cho các ứng dụng thực tế đòi hỏi phản hồi theo thời gian thực.

3.5 Ứng dụng: Equivariance trong Robotics

Trong robotics, equivariance xuất hiện rất tự nhiên vì nhiều hành động của robot phải thay đổi nhất quán theo hình học của môi trường. Nếu camera quan sát một vật thể trên bàn và toàn bộ cảnh được xoay một góc, chiến lược điều khiển hợp lý không nên học lại từ đầu như một trường hợp mới. Thay vào đó, action tương ứng cũng cần được xoay theo cùng phép biến đổi. Trực giác này đặc biệt rõ trong các bài toán manipulation, nơi robot phải chọn vị trí gấp, hướng gripper, hoặc quỹ đạo tiếp cận dựa trên hình dạng và tư thế của vật thể. Khi vật thể bị rotate hoặc translate, action tối ưu thường cũng rotate hoặc translate theo cùng cấu trúc hình học.



Hình 3.20: Tính nhất quán hình học giữa state và action trong robot manipulation.

Ghi chú. Sơ đồ mô tả trường hợp một phép biến đổi hình học g tác động lên state. Nếu policy học được đúng cấu trúc equivariance, action đầu ra cũng biến đổi theo cùng g , thay vì sinh ra một action không nhất quán với hình học của cảnh.



Một cách mô hình hóa phổ biến cho bài toán ra quyết định của robot là Markov decision process $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{T}, \mathcal{R}, \gamma)$, trong đó $\mathcal{S}$ là state space, $\mathcal{A}$ là action space, $\mathcal{T}$ là transition function, $\mathcal{R}$ là reward function và γ là discount factor. Giả sử có một group G tác động lên cả state và action. Với mỗi $g \in G$, ta ký hiệu state sau biến đổi là $g \cdot s$ và action sau biến đổi là $g \cdot a$.

Định lý cốt lõi về optimal policy đẳng biến

Xét một MDP có đối xứng theo group G . Nếu reward function và transition function tương thích với tác động của group, nghĩa là

$$\mathcal{R}(g \cdot s, g \cdot a) = \mathcal{R}(s, a), \quad (3.19)$$

$$\mathcal{T}(g \cdot s' \mid g \cdot s, g \cdot a) = \mathcal{T}(s' \mid s, a), \quad (3.20)$$

thì optimal value function và optimal action-value function thỏa mãn

$$V^*(g \cdot s) = V^*(s), \quad Q^*(g \cdot s, g \cdot a) = Q^*(s, a). \quad (3.21)$$

Từ đó, nếu optimal action là duy nhất hoặc cơ chế chọn action được ràng buộc nhất quán theo group, optimal policy có dạng equivariant:

$$\pi^*(g \cdot s) = g \cdot \pi^*(s), \quad \forall g \in G. \quad (3.22)$$

Ý nghĩa của kết quả (3.22) là: nếu một scene được rotate, action tối ưu của robot cũng phải rotate theo cùng phép biến đổi. Chẳng hạn, nếu robot học được cách gấp một khối hộp tại một hướng nhất định, thì khi khối hộp bị xoay đi, vị trí và hướng gấp hợp lý cũng phải xoay theo. Trong bối cảnh này, equivariance không chỉ là một thuộc tính hình học đẹp về mặt lý thuyết, mà còn là một inductive bias trực tiếp giúp mô hình tránh học lặp lại nhiều tình huống vốn là cùng một bài toán sau phép biến đổi.

Phác thảo lập luận từ Bellman optimality


Bellman optimality equation cho optimal action-value function có dạng

$$Q^*(s, a) = \mathcal{R}(s, a) + \gamma \mathbb{E}_{s' \sim \mathcal{T}(\cdot \mid s, a)} [V^*(s')]. \quad (3.23)$$

Khi thay (s, a) bằng $(g \cdot s, g \cdot a)$, reward function không đổi theo (3.19) và phân phối

transition chỉ được biến đổi theo cùng g theo (3.20). Vì vậy, giá trị kỳ vọng của future return được bảo toàn dưới tác động của group, dẫn đến $Q^*(g \cdot s, g \cdot a) = Q^*(s, a)$. Khi action tối ưu được lấy từ $\arg \max_{a \in \mathcal{A}} Q^*(s, a)$, tập action tối ưu tại $g \cdot s$ chính là ảnh qua g của tập action tối ưu tại s .

Trong robotics, G có thể là $SO(2)$ khi chỉ xét phép xoay trên mặt phẳng, $SE(2)$ khi xét cả tịnh tiến và xoay trên mặt phẳng, hoặc $SE(3)$ khi xét chuyển động rigid body trong không gian ba chiều. Sự lựa chọn group phụ thuộc vào bậc tự do của bài toán cụ thể.



Hình 3.21: Phân loại symmetry group theo bậc tự do của bài toán robot manipulation.

Ghi chú. Mỗi group biểu diễn tập hợp các phép biến đổi mà robot có thể gặp lặp lại trong môi trường nhưng về bản chất không làm thay đổi mục tiêu thao tác.

Trong các bài toán tabletop manipulation, $SO(2)$ thường được dùng để mô hình hóa phép xoay quanh trục vuông góc với mặt bàn. Khi action bao gồm cả vị trí trên ảnh hoặc trên mặt phẳng thao tác, $SE(2)$ phù hợp hơn vì nó biểu diễn đồng thời translation và rotation. Với các bài toán 6-DoF grasping, object rearrangement hoặc thao tác trong không gian ba chiều, $SE(3)$ là lựa chọn tự nhiên hơn vì nó mô tả pose đầy đủ của rigid body. Điểm chung của các nhóm này là chúng biểu diễn những biến đổi mà robot có thể gặp nhiều lần trong môi trường, nhưng về bản chất không làm thay đổi mục tiêu thao tác.

Các công trình gần đây trong robot learning khai thác trực tiếp cấu trúc này. Trong *Equivariant Q Learning in Spatial Action Spaces*, Wang et al. xây dựng Q -learning cho visual state space và spatial action space, trong đó action của robot nằm trong không gian liên hệ với $SE(2)$; đóng góp quan trọng của công trình này là chỉ ra điều kiện để Q^* mang tính equivariant và thiết kế Q -network phản ánh cấu trúc đó^[12]. Tiếp theo, *SO(2)-Equivariant Reinforcement Learning* mở rộng ý tưởng trên sang cả DQN và SAC, cho thấy các đặc trưng equivariant và invariant của Q^* cũng như optimal policy có thể được mã



hóa vào kiến trúc mạng để cải thiện hiệu quả học trong manipulation^[13]. Trong *On-Robot Learning With Equivariant Models*, Wang et al. đưa hướng tiếp cận này vào thiết lập học trực tiếp trên robot thật, nơi dữ liệu thu thập thường đắt và thời gian thử nghiệm bị giới hạn^[14]. Riêng với grasp learning, *On Robot Grasp Learning Using Equivariant Models* của Zhu et al. xem planar grasp function như một hàm $SE(2)$ -equivariant, từ đó ràng buộc mô hình học grasp theo đúng cấu trúc hình học của bài toán^[15]. Với grasp detection trong không gian ba chiều, *OrbitGrasp* mở rộng trực giác tương tự sang $SE(3)$ bằng cách học grasp quality function từ point cloud dưới ràng buộc equivariance^[16].

Lưu ý về điều kiện áp dụng

Tính equivariance của optimal policy phụ thuộc vào cách định nghĩa state, action, reward và transition. Nếu camera bị che khuất, gripper có giới hạn cơ học không đối xứng, hoặc reward phụ thuộc vào một hướng cố định trong môi trường, giả thiết đối xứng có thể chỉ đúng một phần. Trong các trường hợp đó, mô hình partially equivariant thường phù hợp hơn mô hình ép toàn bộ kiến trúc phải equivariant theo mọi biến đổi của group.

Lợi ích chính của equivariance trong robotics là sample-efficient learning. Một mạng nơ-ron thông thường có thể phải quan sát nhiều phiên bản xoay khác nhau của cùng một tình huống để học rằng chúng có chung cấu trúc quyết định. Ngược lại, một equivariant model mã hóa quan hệ này ngay trong kiến trúc, nên kinh nghiệm học được ở một pose có thể được tái sử dụng cho các pose liên hệ với nó qua group action. Điều này đặc biệt quan trọng với robot thật, vì mỗi grasp attempt, mỗi lần thất bại, hoặc mỗi lần reset môi trường đều tiêu tốn thời gian và có thể gây hao mòn phần cứng.

Hiệu quả trên có thể được hiểu theo nghĩa kích thước hypothesis space hiệu dụng. Một mạng không ràng buộc phải tìm kiếm mapping $\pi : \mathcal{S} \rightarrow \mathcal{A}$ trên toàn bộ không gian hàm. Khi áp đặt ràng buộc equivariance (3.22), tập hàm tìm kiếm bị thu nhỏ xuống tập con các hàm thỏa mãn đối xứng group. Về mặt lý thuyết, điều này tương đương với một prior mạnh trên kiến trúc, từ đó giảm lượng dữ liệu cần thiết để hội tụ đến optimal policy. Trong thực nghiệm, các công trình kể trên báo cáo tốc độ học nhanh hơn đáng kể so với baseline không có inductive bias hình học tương ứng^[12;13;15].

Tóm lại, equivariance cung cấp một cầu nối rõ ràng giữa hình học và decision making trong robotics. Thay vì xem các scene sau rotate hoặc translate là những dữ liệu độc lập, mô hình tận dụng group symmetry để ràng buộc output policy biến đổi nhất quán với input state. Nhờ đó, các hệ thống grasp learning và manipulation có thể học ổn định hơn, tổng quát hóa tốt hơn giữa các pose, và giảm đáng kể lượng dữ liệu cần thu thập từ robot



thật.

3.6 Giới hạn: Vấn đề phá vỡ tính đối xứng

Mặc dù các kiến trúc tương biến mang lại nhiều lợi ích về hiệu quả học tập và khả năng khái quát hóa, chúng mang một hạn chế toán học chặt chẽ. Hạn chế này thường được biết đến với tên gọi là vấn đề phá vỡ tính đối xứng.

Định lý về nhóm đẳng hướng

Xét một hàm tương biến f đối với nhóm G , thỏa mãn tính chất $f(g \cdot x) = g \cdot f(x)$ với mọi $g \in G$.

Với một điểm dữ liệu x , ta định nghĩa nhóm đẳng hướng G_x là tập hợp tất cả các phép biến đổi thuộc G mà khi tác động lên x thì không làm thay đổi x :

$$G_x = \{g \in G \mid g \cdot x = x\} \quad (3.24)$$

Tương tự, gọi $y = f(x)$ là đầu ra của mô hình, và G_y là nhóm đẳng hướng của y . Nếu ta lấy một phép biến đổi g bất kỳ thuộc G_x và tác động lên y , ta có sự liên hệ sau:

$$g \cdot y = g \cdot f(x) = f(g \cdot x) = f(x) = y \quad (3.25)$$

Phương trình này chứng minh rằng g cũng giữ nguyên y , nghĩa là $g \in G_y$. Từ đó suy ra $G_x \subseteq G_y$ [cite: 1012, 1014, 1015, 1016].


Hệ quả trực tiếp của định lý trên là đầu ra của một kiến trúc tương biến luôn có mức độ đối xứng bằng hoặc cao hơn so với đầu vào của nó [cite: 1012]. Đặc tính này trở thành một rào cản kỹ thuật nghiêm trọng đối với các mô hình tạo sinh, nơi nhiệm vụ của mạng nơ-ron là biến đổi một phân phối nhiễu cơ bản thành một cấu trúc dữ liệu phức tạp.

Ví dụ về sự cố trong mô hình tạo sinh

Giả sử ta muốn sử dụng một mô hình khuếch tán tương biến để tạo sinh ra cấu trúc 3D của một chiếc ghế. Đầu vào ban đầu của mô hình là một đám mây điểm nhiễu có phân phối dạng hình cầu. Hình cầu là một vật thể có tính đối xứng cực kỳ cao, nó không thay đổi dưới bất kỳ góc quay nào trong không gian.

Do mô hình mang tính tương biến, định lý trên ép buộc đầu ra của nó cũng phải duy trì sự bất biến dưới mọi góc quay đó. Kết quả là mạng nơ-ron không thể phá

vỡ hình dáng đối xứng ban đầu để tạo ra các chi tiết góc cạnh của chiếc ghế. Nó bị kẹt trong việc chỉ có thể sinh ra các vật thể hình cầu hoặc các cấu trúc có tính đối xứng tương đương[cite: 386, 387, 1012].



Hình 3.22: Minh họa sự cản trở của vấn đề phá vỡ đối xứng.

Để giải quyết hạn chế này, các nghiên cứu gần đây buộc phải tìm cách phá vỡ tính đối xứng một cách có chủ đích. Các kỹ thuật can thiệp bao gồm việc thêm nhiễu ngẫu nhiên vào trọng số của mạng trong quá trình học, thao tác trên không gian gradient thay vì dự đoán trực tiếp giá trị, hoặc chuyển đổi kiến trúc để dự đoán một tập hợp các trạng thái thay vì một đầu ra duy nhất[cite: 1013, 1016]. Những phương pháp này nói lỏng sự kìm kẹp của nhóm đẳng hướng, cung cấp cho mô hình đủ sự linh hoạt để hình thành các cấu trúc bất đối xứng cần thiết.

3.7 So sánh hai hướng tiếp cận

Sau khi phân tích chi tiết nền tảng lý thuyết và các kiến trúc tiêu biểu, ta có thể hệ thống hóa sự khác biệt giữa hai trường phái thiết kế mạng nơ-ron nhận thức hình học thông qua Bảng 3.2.



Tiêu chí	Hướng 1: Can thiệp dữ liệu	Hướng 2: Xây dựng kiến trúc
Độ linh hoạt	Rất cao. Có thể kết hợp với bất kỳ mô hình cơ sở nào đang có sẵn (Transformer, CNN) mà không cần lập trình lại lõi mạng.	Thấp. Đòi hỏi thiết kế lại toán học của từng lớp mạng từ đầu, khó tích hợp chéo với các kiến trúc bên ngoài.
Bảo đảm đối xứng	Tùy kỹ thuật. Chỉ đạt mức xấp xỉ nếu dùng tăng cường dữ liệu. Đạt mức chính xác nếu dùng chuẩn hóa hoặc lấy trung bình.	Chính xác tại mọi điểm. Ràng buộc đối xứng được mã hóa cứng vào trọng số nên không thể bị vi phạm.
Sức mạnh biểu diễn	Kế thừa trọn vẹn năng lực của mô hình cơ sở.	Phụ thuộc vào thiết kế. Dễ gặp giới hạn biểu diễn do bổ đề Schur nếu không sử dụng phương pháp tensor.
Chi phí tính toán	Có thể rất đắt đỏ (với lấy trung bình nhóm) hoặc gây mất ổn định (với chuẩn hóa). Kỹ thuật lấy trung bình khung giải quyết được đa số nhược điểm.	Tối ưu cao. Số lượng tham số giảm mạnh do cơ chế chia sẻ, thời gian suy luận nhanh ở các kiến trúc cơ bản.
Sự phụ thuộc dữ liệu	Cần dữ liệu lớn để mô hình có thể tự nhận ra các quy luật đối xứng qua quá trình tối ưu hóa.	Hiệu quả dữ liệu vượt trội. Mô hình có thể hội tụ nhanh chóng chỉ với một lượng mẫu huấn luyện rất nhỏ.

Bảng 3.2: Bảng tổng hợp đối chiếu ưu nhược điểm giữa phương pháp hộp đen (Hướng 1) và phương pháp xây dựng từ lõi (Hướng 2).

Việc lựa chọn giữa hai hướng tiếp cận không tuân theo một quy tắc cứng nhắc mà phụ thuộc sâu sắc vào bản chất của bài toán thực tế.

Hướng can thiệp dữ liệu thể hiện sự ưu việt khi ta đang làm việc với các hệ thống trí tuệ nhân tạo quy mô lớn mang tính nền tảng. Chẳng hạn, trong lĩnh vực xử lý ngôn ngữ tự nhiên hoặc thị giác máy tính, việc tự xây dựng một mô hình tương biến khổng lồ từ đầu là không khả thi về mặt tài chính và thời gian. Hơn nữa, các đối xứng trong dữ liệu tự nhiên thường không hoàn hảo hoặc phụ thuộc ngữ cảnh[cite: 1020, 1021]. Trong bối cảnh đó, việc tái sử dụng các mô hình mạnh mẽ hiện có và tinh chỉnh chúng qua dữ liệu là phương án kinh tế và linh hoạt nhất.



Ngược lại, hướng xây dựng kiến trúc từ đầu là sự lựa chọn duy nhất đúng đắn cho các bài toán khoa học tự nhiên. Trong hóa học lượng tử, mô phỏng vật lý đa hạt hay điều khiển tay máy robot, dữ liệu thu thập vô cùng đắt đỏ và các định luật bảo toàn không gian là những tiên đề bất di bất dịch[cite: 977, 1069]. Việc sử dụng kiến trúc mã hóa cứng như NequIP hay Mạng đồ thị tương biến giúp loại bỏ mọi rủi ro về sai số vật lý, tận dụng tối đa giá trị của từng điểm dữ liệu nhỏ giọt để đạt được độ chính xác mà các phương pháp truyền thống không thể chạm tới.



Chương
4

Lý thuyết nâng cao và các hướng nghiên cứu mới

Chương trước đã cho thấy bằng các ví dụ cụ thể rằng việc nhúng tính đối xứng vào kiến trúc mang lại lợi ích thực nghiệm rõ rệt, từ NequIP cho thể năng nguyên tử, PointNet trên đám mây điểm, cho tới các mạng tích chập nhóm. Tuy nhiên, một bức tranh chỉ dừng ở mức quan sát thực nghiệm là chưa đủ. Vì sao đối xứng lại giúp ích, mức lợi ích chính xác là bao nhiêu, cái giá tính toán phải trả ra sao, và liệu giả định về đối xứng có thực sự đúng với dữ liệu hay không, đó là những câu hỏi mà chương này tập trung trả lời.

4.1 Lợi ích về độ phức tạp mẫu

Lý thuyết học máy hiện đại đang hướng tới việc giải thích một cách định lượng vì sao các tiên nghiệm hình học, đặc biệt là tính bất biến theo nhóm, có thể giúp mô hình học hiệu quả hơn. Một đóng góp nền tảng theo hướng này là công trình *The Exact Sample Complexity Gain from Invariances for Kernel Regression* của Behrooz Tahmasebi và Stefanie Jegelka^[17], trong đó lợi ích về độ phức tạp mẫu của tính bất biến được đặc trưng chính xác trong khung hồi quy kernel trên đa tập.

4.1.1. Động lực: một lý thuyết cần đủ tổng quát

Các kết quả lý thuyết trước đó về lợi ích của tính bất biến thường ràng buộc rất chặt vào tình huống cụ thể. Tiêu biểu là kết quả của Bietti, Venturi và Bruna^[18], vốn chỉ áp dụng cho nhóm hữu hạn, tác động đẳng cự và dữ liệu nằm trên mặt cầu đơn vị $\{x \in \mathbb{R}^d : \|x\|_2 = 1\}$. Giả thiết mặt cầu là quá hạn chế đối với nhiều bài toán thực tế. Hãy xét một ví dụ rất phổ biến: dữ liệu là các tập hợp ba điểm trong không gian ba chiều, được xét dưới phép tịnh tiến và phép đổi hệ tọa độ. Miền dữ liệu khi đó không còn là mặt cầu, và nhóm tác động cũng không thuộc dạng chuẩn tắc mà lý thuyết cũ giả định.

Một lý thuyết thực sự hữu ích phải làm việc được trong hai điều kiện tổng quát sau:

1. Miền dữ liệu là một đa tập compact bất kỳ, không nhất thiết là mặt cầu, chẳng hạn đa tập Stiefel xuất hiện trong dữ liệu phổ.



2. Nhóm tác động là một continuous group bất kỳ, bao gồm cả các nhóm Lie có số chiều dương, chứ không chỉ các nhóm hữu hạn.

Đóng góp cốt lõi của bài báo là mở rộng kết quả từ mặt cầu lên mọi đa tạp compact, và từ nhóm hữu hạn lên mọi smooth compact Lie group, kể cả nhóm vô hạn. Chính việc cho phép nhóm có số chiều dương đã làm lộ ra một trục giảm độ phức tạp mẫu hoàn toàn mới, điều mà các giả thiết cũ không thể nhìn thấy.

4.1.2. Thiết lập bài toán: hồi quy Sobolev bất biến

Xét một đa tạp Riemann compact, liên thông, không biên (M, g) với số chiều $\dim(M)$, và một compact Lie group G tác động trơn lên M . Không mất tính tổng quát, ta có thể giả định G tác động đẳng cự, vì luôn có thể biến đổi metric ban đầu thành một metric mới mà dưới đó tác động trở thành đẳng cự. Tập dữ liệu gồm n mẫu độc lập cùng phân phối $x_1, x_2, \dots, x_n$ lấy đều trên M , với nhãn quan sát

$$y_i = f_\star(x_i) + \epsilon_i, \quad \mathbb{E}[\epsilon_i | x_i] = 0, \quad \mathbb{E}[\epsilon_i^2 | x_i] \leq \sigma^2. \quad (4.1)$$

Hàm mục tiêu $f_\star$ được giả định là G -invariant, tức $f_\star(\tau(x)) = f_\star(x)$ với mọi $\tau \in G$, và nằm trong không gian Sobolev bất biến $H_{\text{inv}}^s(M)$, gồm các hàm bất biến có đạo hàm khả tích bình phương đến bậc s . Bộ ước lượng được dùng là KRR với một kernel G -invariant K :

$$\hat{f} := \arg \min_{f \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2 + \eta \|f\|_{\mathcal{H}}^2, \quad (4.2)$$

trong đó $\mathcal{H}$ là không gian Hilbert tái sinh của kernel Sobolev và η là tham số điều chuẩn. Theo representer theorem, nghiệm tối ưu có dạng tổ hợp tuyến tính của các giá trị kernel tại các điểm dữ liệu, nên KRR có nghiệm đóng.

4.1.3. Kết quả chính: hai trục giảm độ phức tạp mẫu

Định lý trung tâm khẳng định một cận trên cho sai số tổng quát hóa của KRR khi hàm mục tiêu bất biến. Cụ thể, với kernel Sobolev, sai số kỳ vọng thỏa mãn

$$\mathbb{E}[\|\hat{f} - f_\star\|_2^2] \lesssim \left(\frac{C_{d'} \sigma^2 \text{vol}(M/G)}{n} \right)^{\frac{s}{s+d'}}, \quad (4.3)$$

trong đó $C_{d'}$ là hằng số phụ thuộc số chiều hiệu dụng, $d' = \dim(M) - \dim(G)$ là số chiều của quotient space, và s là bậc Sobolev. Quan trọng hơn, tốc độ này được chứng minh là



minimax optimal, nghĩa là không có bộ ước lượng nào có thể làm tốt hơn về mặt bậc, kể cả ở hệ số đứng trước. Vì vậy đây là mức lợi ích chính xác chứ không chỉ là một cận lỏng.

Đặt G là nhóm tầm thường sẽ thu lại đúng cận tổng quát hóa cổ điển khi không có đối xứng, lúc đó d' trở thành $\dim(M)$ và $\text{vol}(M/G)$ trở thành $\text{vol}(M)$. So sánh hai trường hợp cho thấy tính bất biến mang lại lợi ích theo hai cơ chế khác nhau về bản chất:

- **Multiplicative gain:** Thể tích quotient $\text{vol}(M/G)$ luôn nhỏ hơn $\text{vol}(M)$. Với nhóm hữu hạn tác động hiệu quả, $\text{vol}(M/G) = \text{vol}(M)/|G|$, nên về thực chất mỗi mẫu dữ liệu mang lượng thông tin tương đương $|G|$ mẫu. Hiệu ứng giống như tăng kích thước tập huấn luyện lên $n \times |G|$ lần.
- **Exponential gain:** Số mũ chứa $d' = \dim(M) - \dim(G)$ thay vì $\dim(M)$. Khi nhóm có số chiều dương, số chiều hiệu dụng giảm đi $\dim(G)$ đơn vị, kéo theo tốc độ hội tụ cải thiện theo hàm mũ. Đây chính là trực lợi ích mới mà các lý thuyết giới hạn ở nhóm hữu hạn không thể phát hiện, bởi với nhóm hữu hạn thì $\dim(G) = 0$.

Bảng 4.1: Hai cơ chế giảm độ phức tạp mẫu theo loại nhóm tác động.

Ghi chú: Bảng do nhóm lập dựa trên Định lý 4.1 trong^[17].

Tiêu chí	Nhóm hữu hạn	Nhóm Lie số chiều dương
$\dim(G)$	0	> 0
Số chiều hiệu dụng d'	$\dim(M)$	$\dim(M) - \dim(G)$
Lợi ích nhân	$\text{vol}(M)/ G $	Co thể tích theo quotient
Lợi ích mũ	Không có	Có, giảm số chiều
Diễn giải trực quan	Hiệu quả như $n \times G $ mẫu	Vừa thêm mẫu, vừa giảm chiều


Nhận xét: Bảng 4.1 cho thấy ranh giới định tính giữa nhóm hữu hạn và nhóm Lie số chiều dương. Với nhóm hữu hạn, $\dim(G) = 0$ nên lợi ích chỉ là hệ số nhân, tương đương khuếch đại mỗi mẫu thành $|G|$ mẫu. Với nhóm liên tục, ngoài lợi ích nhân còn có lợi ích mũ vì số chiều hiệu dụng giảm từ $\dim(M)$ xuống $\dim(M) - \dim(G)$. Do đó giá trị lớn nhất của đối xứng liên tục không chỉ là thêm dữ liệu, mà là thu nhỏ chính số chiều của bài toán cần học, đặc biệt quan trọng khi dữ liệu khan hiếm.

4.1.4. Trực giác hình học: phép phản xạ trên vòng tròn

Để thấy rõ vì sao tính bất biến lại làm giảm độ phức tạp mẫu, ta xét ví dụ đơn giản nhất là vòng tròn đơn vị, tham số hóa bởi góc $\theta \in [0, 2\pi)$. Các eigenfunction của

Laplace-Beltrami operator trên vòng tròn là hàm hằng cùng với $\sin(k\theta)$ và $\cos(k\theta)$, ứng với eigenvalue $\lambda = k^2$. Mỗi eigenvalue khác không có bội hai, đây chính là toàn bộ các Fourier modes.

Bây giờ áp đặt tính đối xứng bằng nhóm phản xạ G qua trục tung, tức yêu cầu $f_*(\pi - \theta) = f_*(\theta)$. Khi đó chỉ một nửa số Fourier modes sống sót, cụ thể là các hàm $\sin((2k+1)\theta)$ và $\cos(2k\theta)$, vì $|G| = 2$. Quotient space ở đây là một nửa vòng tròn, và do đó $\text{vol}(M/G) = \frac{1}{2}\text{vol}(M)$. Độ thưa của khai triển Fourier chính là cơ chế trực tiếp dẫn tới lợi ích về độ phức tạp mẫu: không gian hàm cần học bị thu nhỏ đúng một nửa, nên cần ít dữ liệu hơn để xác định hàm mục tiêu.



Hình 4.1: Phản xạ qua trục tung gập vòng tròn thành nửa vòng tròn, chỉ một nửa số Fourier modes còn lại nên $\text{vol}(M/G) = \frac{1}{2}\text{vol}(M)$.

Ghi chú: Hình do nhóm tự vẽ dựa trên ví dụ vòng tròn trong^[17]; hai điểm $(0, \pm 1)$ là các điểm cố định, nơi xuất hiện biên của quotient space.

4.1.5. Ý tưởng chứng minh: định luật Weyl mở rộng

Phần khó nhất của bài báo nằm ở chứng minh, và đây cũng là nơi cách tiếp cận hình học vi phân thể hiện sức mạnh. Ý tưởng là xem không gian hàm bất biến trên M như không gian hàm trên quotient space M/G , rồi đo độ phức tạp của không gian đó qua phân bố eigenvalue của Laplace-Beltrami operator. Ta định nghĩa $N(\lambda; G)$ là số eigenfunction bất biến có eigenvalue không vượt quá λ . Định lý đếm chiều khẳng định đáng diệu tiệm cận của đại lượng này, chính là một dạng mở rộng của định luật Weyl:

$$N(\lambda; G) \approx \frac{\omega_{d'}}{(2\pi)^{d'}} \text{vol}(M/G) \lambda^{d'/2}, \quad (4.4)$$



trong đó ω_d là thể tích hình cầu đơn vị trong $\mathbb{R}^d$. Công thức này nói rằng số hàm bất biến tăng theo thể tích quotient và theo số chiều hiệu dụng, qua đó liên kết trực tiếp với hai trục lợi ích đã nêu.

Tuy nhiên, áp dụng định luật Weyl cho M/G không hề tầm thường, vì quotient space gặp hai trở ngại sau:

1. Quotient space nói chung không phải là một đa tạp, nên ngay cả khái niệm số chiều và thể tích cũng cần được định nghĩa lại một cách cẩn thận thông qua phần chính của nó.
2. Ngay cả khi giới hạn ở phần là đa tạp, quotient vẫn có thể xuất hiện biên dù không gian gốc không có biên. Ví dụ vòng tròn ở trên cho quotient là nửa vòng tròn với hai điểm biên, sinh ra từ các điểm cố định của tác động nhóm.

Nhận xét: Khi đã có biên thì một kết quả đếm chiều kiểu Weyl chỉ đúng nếu đi kèm điều kiện biên phù hợp, và các điều kiện biên khác nhau dẫn tới những không gian hàm hoàn toàn khác nhau. Đóng góp của chứng minh là chỉ ra rằng các hàm bất biến chiếu xuống quotient luôn thỏa mãn điều kiện biên Neumann, tức đạo hàm pháp tuyến triệt tiêu trên biên, chứ không phải điều kiện Dirichlet. Chính việc xác định đúng điều kiện biên này đã đặc trưng hóa chính xác không gian hàm bất biến. Cách lập luận bằng hình học vi phân và Laplace-Beltrami operator này tổng quát hơn hẳn chiến lược cổ điển dùng đa thức bất biến, vốn chỉ hoạt động trên mặt cầu^[18].

4.1.6. Mở rộng và liên hệ với các kết quả khác

Khung lý thuyết trên không dừng lại ở hồi quy. Cùng nhóm tác giả đã mở rộng ý tưởng sang bài toán ước lượng các probability divergence dưới đối xứng^[19], bao gồm cả optimal transport. Một quan sát thú vị là với kernel maximum mean discrepancy, mức lợi ích không còn chỉ phụ thuộc vào thể tích quotient mà còn phụ thuộc vào những tính chất hình học tinh tế hơn của đa tạp, chẳng hạn hàm zeta của nó. Kết quả tương tự về độ phức tạp mẫu của divergence dưới đối xứng nhóm cũng được Chen và cộng sự thiết lập một cách độc lập^[20].

Trong bức tranh rộng hơn, đây là một mắt xích trong dòng nghiên cứu định lượng lợi ích của tính bất biến và đẳng biến. Elesedy chứng minh lợi ích tổng quát hóa nghiêm ngặt cho các phương pháp kernel bất biến^[21], còn Mei, Misiakiewicz và Montanari phân tích trường hợp random features và kernel models trong một chế độ scaling khác^[22]. So với các công trình này, đóng góp riêng của Tahmasebi và Jegelka là một kết quả minimax


optimal đúng cho mọi đa tập compact và mọi tác động nhóm Lie trơn, qua đó hợp nhất nhiều trường hợp riêng lẻ dưới một lý thuyết chung.

Bảng 4.2: Ánh xạ một số mô hình bất biến quen thuộc vào khung lý thuyết đa tập và nhóm tác động.

Ghi chú: Bảng do nhóm tổng hợp từ phần ứng dụng kernel hóa trong^[17].

Mô hình	Nhóm tác động G	Nguồn lợi ích chủ đạo
DeepSets	Hoán vị S_n hữu hạn	Lợi ích nhân theo $ G = n!$
GNN	Hoán vị trên đỉnh đồ thị	Lợi ích nhân theo cỡ nhóm
PointNet	Hoán vị, tịnh tiến, quay	Cả lợi ích nhân và lợi ích mũ
SignNet	Đối xứng dấu của vector riêng	Lợi ích nhân theo nhóm dấu

Hình 4.2 tổng kết bằng trực giác cuối cùng: ở cùng một mức sai số mục tiêu, mô hình bất biến cần ít mẫu hơn đáng kể, và khoảng cách này càng rõ khi nhóm đối xứng càng lớn. Đúng như lý thuyết dự đoán, lợi ích thể hiện mạnh nhất ở chế độ dữ liệu ít; khi dữ liệu trở nên dồi dào, khoảng cách giữa mô hình bất biến và mô hình thông thường thu hẹp dần.



Hình 4.2: Cùng một mức sai số mục tiêu, mô hình bất biến đạt được với số mẫu nhỏ hơn, và nhóm đối xứng càng lớn thì đường cong càng dốc.

Ghi chú: Hình do nhóm tự vẽ mang tính minh họa định tính cho Định lý 4.1 trong^[17], không phải kết quả thực nghiệm.



4.2 Giải quyết chi phí tính toán bằng Expanders

Các phương pháp khai thác tính đối xứng như *group averaging* và *data augmentation* có thể cải thiện khả năng tổng quát hóa của mô hình bằng cách buộc mô hình tôn trọng các phép biến đổi không làm thay đổi bản chất dữ liệu. Tuy nhiên, khi nhóm biến đổi có kích thước lớn, việc xét toàn bộ các phần tử của nhóm trở nên không khả thi về mặt tính toán. Một ví dụ điển hình là nhóm hoán vị S_{50} , có kích thước

$$|S_{50}| = 50! \approx 3 \times 10^{64}. \quad (4.5)$$

Đây là một con số vượt xa khả năng duyệt vét cạn trong mọi thiết lập thực nghiệm thông thường. Do đó, một câu hỏi quan trọng được đặt ra là liệu có thể thu được lợi ích của đối xứng mà không cần thao tác trực tiếp trên toàn bộ nhóm G hay không.

Một hướng tiếp cận hiện đại là khai thác tập sinh và đồ thị Cayley ngẫu nhiên. Thay vì duyệt qua tất cả phần tử của G , ta chỉ làm việc với một tập con nhỏ $\mathcal{S} \subseteq G$ nhưng vẫn giữ được thông tin quan trọng về cấu trúc nhóm. Khi đồ thị Cayley sinh bởi $\mathcal{S}$ có tính chất expander, thông tin có thể lan truyền hiệu quả trên toàn bộ nhóm, dù số cạnh của đồ thị tương đối nhỏ.

4.2.1. Tập sinh và tiết kiệm theo hàm mũ

Cho một nhóm hữu hạn G , một tập con $\mathcal{S} \subseteq G$ được gọi là tập sinh nếu mọi phần tử $g \in G$ đều có thể được biểu diễn dưới dạng tích hữu hạn của các phần tử trong $\mathcal{S}$:

$$g = s_1 s_2 \cdots s_k, \quad s_i \in \mathcal{S}. \quad (4.6)$$

Khi đó, thay vì kiểm tra tính bất biến trên toàn bộ nhóm G , ta có thể kiểm tra trên tập sinh $\mathcal{S}$. Cụ thể, nếu hàm mục tiêu $f_\star$ thỏa mãn

$$f_\star(s \cdot x) = f_\star(x), \quad \forall s \in \mathcal{S}, \quad (4.7)$$



thì với mọi phần tử $g \in G$ có biểu diễn như trong phương trình (4.6), ta suy ra

$$\begin{aligned} f_*(g \cdot x) &= f_*(s_1 s_2 \cdots s_k \cdot x) \\ &= f_*(s_2 \cdots s_k \cdot x) \\ &\dots \\ &= f_*(x). \end{aligned} \tag{4.8}$$

Do đó, tính bất biến trên tập sinh là điều kiện đủ để suy ra tính bất biến trên toàn bộ nhóm.

Lợi ích tính toán của quan sát này đến từ việc tập sinh có thể nhỏ hơn rất nhiều so với toàn bộ nhóm. Với một nhóm hữu hạn G , luôn tồn tại một tập sinh có kích thước không vượt quá logarithm cơ số hai của kích thước nhóm:

$$|\mathcal{S}| \leq \log_2 |G|. \tag{4.9}$$

Cận này cho thấy số phần tử cần kiểm soát có thể giảm từ $|G|$ xuống mức logarithmic theo $|G|$, tạo ra sự tiết kiệm theo hàm mũ. Tuy nhiên, bài toán tìm tập sinh có kích thước nhỏ nhất trong các thiết lập tổng quát là một bài toán khó về mặt tính toán, do đó cần các phương pháp xấp xỉ hoặc ngẫu nhiên hóa thay vì tìm kiếm tối ưu trực tiếp.

4.2.2. Đồ thị Cayley ngẫu nhiên và expander

Từ một tập con $\mathcal{S} \subseteq G$, đồ thị Cayley $\text{Cay}(G, \mathcal{S})$ được xây dựng bằng cách lấy mỗi phần tử của nhóm G làm một đỉnh. Hai đỉnh g và g' được nối với nhau nếu

$$g^{-1}g' \in \mathcal{S}. \tag{4.10}$$


Nếu $\mathcal{S}$ là tập sinh của G , đồ thị Cayley tương ứng là liên thông. Khi đồ thị này đồng thời có tính chất expander, nó là một đồ thị thưa nhưng có khả năng kết nối mạnh, nhờ đó các phép biến đổi trong nhóm có thể được bao phủ hiệu quả thông qua một số bước nhỏ.

Các kết quả về đồ thị Cayley ngẫu nhiên cho thấy việc lấy mẫu một tập con ngẫu nhiên $\mathcal{S}$ với kích thước tỉ lệ với $\log |G|$ thường đủ để sinh ra toàn bộ nhóm với xác suất cao. Trong một số thiết lập, kích thước cỡ

$$|\mathcal{S}| \approx 2.67 \log |G| \tag{4.11}$$

có thể đủ để $\mathcal{S}$ trở thành tập sinh với xác suất cao. Ý nghĩa của kết quả này là ta không

cần thiết kể thủ công tập sinh tối ưu; thay vào đó, lấy mẫu ngẫu nhiên một số lượng phần tử tỉ lệ logarithmic theo kích thước nhóm đã có thể tạo ra một cấu trúc đủ tốt cho nhiều thuật toán học có đối xứng.



S nhỏ nhưng tạo liên thông trên toàn bộ cấu trúc nhóm

Hình 4.3: Minh họa đồ thị Cayley sinh bởi một tập con S .

Ghi chú: Khi S là tập sinh, các cạnh tương ứng với phép nhân bởi phần tử sinh giúp kết nối toàn bộ các phần tử của nhóm. Hình chỉ mang tính minh họa định tính.

4.2.3. Ứng dụng trong học máy hình học

Việc sử dụng expander và đồ thị Cayley ngẫu nhiên dẫn đến ba ứng dụng quan trọng trong học máy hình học.

Thứ nhất, trong bài toán học các hàm bất biến chính xác, cấu trúc tập sinh cho phép thay thế việc kiểm tra toàn bộ nhóm bằng việc kiểm tra một số phần tử đại diện. Các kết quả gần đây cho thấy trong một số thiết lập, bài toán học exact invariance có thể được giải với độ phức tạp theo dạng đa thức của $\log |G|$, chẳng hạn

$$\mathcal{O}_{n,d}((\log |G|)^3), \quad (4.12)$$

thay vì phụ thuộc trực tiếp vào $|G|$ [23]. Đây là sự giảm chi phí đáng kể đối với các nhóm tổ hợp lớn như nhóm hoán vị.

Thứ hai, trong *data augmentation*, mục tiêu không nhất thiết là duyệt toàn bộ nhóm, mà là thu được lợi ích thống kê từ các phép biến đổi đại diện. Với các giả định phù hợp về phân phối dữ liệu và lớp hàm học, việc lấy mẫu ngẫu nhiên

$$|\mathcal{S}| = \mathcal{O}(\log |G|) \quad (4.13)$$



phần tử từ nhóm có thể đủ để đạt được lợi ích thống kê tương đương về bậc với việc sử dụng toàn bộ nhóm^[24]. Điều này cung cấp cơ sở lý thuyết cho thực hành phổ biến trong học sâu, nơi chỉ một số phép biến đổi được lấy mẫu ngẫu nhiên trong quá trình huấn luyện.

Thứ ba, trong bài toán xấp xỉ *group averaging*, ta thay trung bình đầy đủ trên nhóm

$$A_G f(x) = \frac{1}{|G|} \sum_{g \in G} f(g \cdot x) \quad (4.14)$$

bằng trung bình trên một tập con ngẫu nhiên $\mathcal{S}$:

$$A_{\mathcal{S}} f(x) = \frac{1}{|\mathcal{S}|} \sum_{s \in \mathcal{S}} f(s \cdot x). \quad (4.15)$$

Với một lớp hàm phù hợp và các giả định chặn chuẩn cần thiết, sai số xấp xỉ có thể được khống chế theo dạng

$$\sup_{f \in \mathcal{F}} |A_G f(x) - A_{\mathcal{S}} f(x)| \leq \mathcal{O} \left(\sqrt{\frac{\log |G|}{|\mathcal{S}|}} \right), \quad (4.16)$$

trong đó $\mathcal{F}$ là lớp hàm đang xét. Cách viết này nhấn mạnh rằng cận sai số phụ thuộc vào giả định của định lý, thay vì đúng cho mọi hàm không bị ràng buộc.

4.2.4. Phân biệt giữa bất biến chính xác và bất biến xấp xỉ

Các kết quả trên cho thấy cần phân biệt rõ giữa ba mục tiêu khác nhau. Nếu mục tiêu là xây dựng tính bất biến chính xác bằng *group averaging* đầy đủ, chi phí vẫn có thể rất lớn vì trung bình đầy đủ yêu cầu thao tác trên toàn bộ nhóm. Nếu mục tiêu là xấp xỉ tính bất biến, việc lấy mẫu một tập con có kích thước logarithmic có thể đủ để kiểm soát sai số. Nếu mục tiêu là đạt được lợi ích thống kê trong *data augmentation*, số phép biến đổi cần lấy mẫu cũng có thể chỉ tăng theo $\mathcal{O}(\log |G|)$ trong các thiết lập phù hợp.

Do đó, expander cung cấp một sự phân tách quan trọng về mặt tính toán. Tính bất biến chính xác thông qua trung bình đầy đủ vẫn là một bài toán khó khi nhóm có kích thước lớn. Ngược lại, bất biến xấp xỉ và lợi ích thống kê của đối xứng có thể đạt được bằng một số lượng phần tử nhỏ hơn rất nhiều. Với những nhóm có kích thước thiên văn như S_{50} , sự phân tách này biến một bài toán không khả thi thành một chiến lược có thể triển khai trong thực nghiệm.

4.3 Kiểm định tính đối xứng trong dữ liệu

Các mô hình học máy hình học thường được xây dựng dựa trên một giả định tiên nghiệm: phân bố dữ liệu tuân theo một nhóm đối xứng nhất định. Giả định này cho phép mã hóa trực tiếp tính bất biến hoặc tính tương biến vào kiến trúc mô hình, qua đó cải thiện hiệu quả dữ liệu và khả năng tổng quát hóa. Tuy nhiên, trong các bài toán thực tế, đối xứng của dữ liệu không phải lúc nào cũng hiển nhiên hoặc đúng tuyệt đối. Chẳng hạn, ảnh MRI có thực sự bất biến với mọi phép quay hay không còn phụ thuộc vào quy ước thu nhận ảnh, tư thế bệnh nhân và cấu trúc giải phẫu đang được khảo sát. Tương tự, một hệ phân tử có thể bất biến với phép tịnh tiến và phép quay toàn cục, nhưng không nhất thiết bất biến với mọi phép biến đổi rộng hơn nếu dữ liệu chứa ràng buộc môi trường hoặc điều kiện biên cụ thể.

Vì vậy, trước khi mã hóa một đối xứng vào mô hình, cần có một cơ chế kiểm định xem phân bố dữ liệu có thực sự tôn trọng đối xứng đó hay không. Vấn đề này được nghiên cứu có hệ thống trong bài báo về *Symmetry Testing* của Soleymani và cộng sự. Trọng tâm của hướng nghiên cứu này là chuyển câu hỏi “dữ liệu có đối xứng hay không” thành một bài toán kiểm định giả thuyết thống kê có thể phân tích được về mặt lý thuyết và triển khai được về mặt thuật toán.

4.3.1. Phát biểu bài toán kiểm định

Cho một phân bố dữ liệu μ trên không gian đầu vào $\mathcal{X}$ và một nhóm G tác động lên $\mathcal{X}$. Với mỗi phần tử $g \in G$, ký hiệu $g \cdot \mu$ là phân bố thu được sau khi tác động phép biến đổi g lên các mẫu được sinh từ μ . Khi đó, bài toán kiểm định tính đối xứng được phát biểu dưới dạng hai giả thuyết:


$$H_0 : \mu \equiv g \cdot \mu, \quad \forall g \in G, \quad (4.17)$$

$$H_1 : \sup_{g \in G} D(g \cdot \mu, \mu) \geq \varepsilon. \quad (4.18)$$

Trong đó, $D(\cdot, \cdot)$ là một độ đo khoảng cách giữa hai phân bố và $\varepsilon > 0$ là ngưỡng sai khác có ý nghĩa thống kê. Giả thuyết H_0 phát biểu rằng phân bố dữ liệu bất biến với toàn bộ nhóm G , trong khi H_1 phát biểu rằng tồn tại ít nhất một phép biến đổi trong G làm thay đổi phân bố dữ liệu vượt quá ngưỡng ε .

Về mặt thực nghiệm, D có thể được chọn là *maximum mean discrepancy*, *total variation*, hoặc một độ đo xác suất khác tùy thuộc vào loại dữ liệu và giả định phân tích. Cách

phát biểu này có ý nghĩa quan trọng vì nó không kiểm tra đối xứng trên từng mẫu riêng lẻ, mà kiểm tra đối xứng ở cấp độ phân bố dữ liệu.



Hình 4.4: Quy trình kiểm định tính đối xứng ở cấp độ phân bố.

Ghi chú: Dữ liệu ban đầu được so sánh với dữ liệu sau khi tác động bởi phần tử nhóm để đánh giá mức độ vi phạm tính bất biến.

4.3.2. Độ khó tính toán

Một cách trực tiếp để kiểm định H_1 là tìm phần tử nhóm gây vi phạm lớn nhất:

$$g^* \in \arg \sup_{g \in G} D(g \cdot \mu, \mu). \quad (4.19)$$

Tuy nhiên, bài toán này thường không khả thi trong các nhóm có cấu trúc tổ hợp lớn. Trong trường hợp tổng quát, việc tìm phần tử tối ưu g^* là một bài toán khó về mặt tính toán và có thể quy về các bài toán tối ưu tổ hợp như *Travelling Salesman Problem*. Do đó, nếu kiểm định tính đối xứng được triển khai bằng cách duyệt toàn bộ nhóm hoặc tìm chính xác phần tử vi phạm lớn nhất, chi phí tính toán sẽ trở thành trở ngại chính.

Khó khăn này đặc biệt rõ trong các nhóm hoán vị, nhóm quay rời rạc kích thước lớn, hoặc các nhóm biến đổi tổ hợp phát sinh trong dữ liệu đồ thị. Khi đó, số lượng phần tử của G tăng rất nhanh theo kích thước đầu vào, khiến cách tiếp cận vét cạn không phù hợp với các hệ thống học máy hiện đại.

4.3.3. Giải pháp ngẫu nhiên hóa

Thay vì tìm trực tiếp phần tử vi phạm lớn nhất, Soleymani và cộng sự cho thấy có thể sử dụng một chiến lược ngẫu nhiên hóa dựa trên việc lấy mẫu phần tử g từ nhóm G .



Trong thiết lập lý thuyết của bài báo, kỳ vọng của độ lệch ngẫu nhiên có thể được dùng để khống chế đại lượng vi phạm cực đại:

$$\mathbb{E}_{g \sim \text{Unif}(G)} [D(g \cdot \mu, \mu)] \leq \sup_{g \in G} D(g \cdot \mu, \mu) \leq 2\mathbb{E}_{g \sim \text{Unif}(G)} [D(g \cdot \mu, \mu)]. \quad (4.20)$$

Bất đẳng thức này cho thấy độ lệch trung bình dưới phép lấy mẫu ngẫu nhiên không chỉ là một đại lượng phụ trợ, mà còn có thể đóng vai trò như một chứng nhận thống kê cho mức độ vi phạm tính đối xứng. Nếu kỳ vọng trong phương trình (4.20) nhỏ, thì độ lệch cực đại cũng bị khống chế trong cùng bậc sai khác. Ngược lại, nếu các mẫu ngẫu nhiên thường xuyên tạo ra độ lệch lớn, điều đó cung cấp bằng chứng thực nghiệm chống lại giả thuyết bất biến.

Về mặt thuật toán, cách tiếp cận này thay thế bài toán tối ưu khó trên toàn nhóm bằng bài toán lấy mẫu và ước lượng kỳ vọng. Điều này đặc biệt quan trọng khi nhóm G có kích thước lớn nhưng việc sinh ngẫu nhiên một phần tử $g \in G$ lại tương đối đơn giản.

4.3.4. Thuật toán tắt định khai thác cấu trúc nhóm

Bên cạnh giải pháp ngẫu nhiên hóa, cấu trúc đại số của nhóm còn cho phép xây dựng các thuật toán tắt định hiệu quả hơn so với phương pháp phủ tập thông thường. Điểm then chốt là độ lệch theo tác động nhóm thỏa mãn một dạng bất đẳng thức tam giác:

$$D(g_1(g_2 \cdot \mu), \mu) \leq D(g_1 \cdot \mu, \mu) + D(g_2 \cdot \mu, \mu). \quad (4.21)$$

Bất đẳng thức (4.21) cho phép truyền sai số qua phép hợp thành nhóm. Nếu một phần tử phức tạp g có thể được biểu diễn thông qua các phần tử đơn giản hơn, thì độ lệch của g có thể được khống chế bằng tổng độ lệch của các thành phần cấu thành. Nhờ vậy, thay vì phải xây dựng một covering set dày đặc trên toàn bộ không gian nhóm, ta có thể khai thác cấu trúc sinh của nhóm để giảm mạnh số phần tử cần kiểm tra.

Theo kết quả của Soleymani và cộng sự, với một số nhóm biến đổi quan trọng trong học máy hình học, kích thước covering set có thể được giảm xuống còn


$$\mathcal{O}\left(\frac{d^2}{\varepsilon}\right), \quad (4.22)$$

thay vì kích thước dạng

$$\mathcal{O}\left(\varepsilon^{-d^2}\right) \quad (4.23)$$

của cách phủ tập không khai thác cấu trúc nhóm. Sự cải thiện này chuyển chi phí từ phụ

thuộc hàm mũ theo số chiều sang phụ thuộc đa thức theo d và $1/\varepsilon$, qua đó làm cho kiểm định tính đối xứng trở nên khả thi hơn trong các bài toán có chiều cao.



Hình 4.5: Minh họa lợi ích của việc khai thác cấu trúc nhóm trong kiểm định tính đối xứng.

Ghi chú: Thay vì phủ trực tiếp toàn bộ không gian biến đổi, thuật toán sử dụng quan hệ hợp thành nhóm để giảm kích thước tập kiểm định.

4.3.5. Ý nghĩa đối với học máy hình học

Symmetry Testing cung cấp một lớp công cụ quan trọng cho học máy hình học vì nó kiểm tra tính đúng đắn của giả định đối xứng trước khi giả định đó được mã hóa vào mô hình. Nếu dữ liệu thực sự bất biến với nhóm G , việc sử dụng mô hình bất biến hoặc tương biến có thể giúp giảm độ phức tạp mẫu và cải thiện khả năng tổng quát hóa. Ngược lại, nếu dữ liệu chỉ xấp xỉ bất biến hoặc vi phạm đối xứng ở một số hướng nhất định, việc áp đặt đối xứng cứng có thể làm mất thông tin dự đoán quan trọng.

Do đó, kiểm định tính đối xứng đóng vai trò như một bước trung gian giữa phân tích dữ liệu và thiết kế kiến trúc. Thay vì chọn nhóm đối xứng hoàn toàn dựa trên trực giác miền ứng dụng, nhà nghiên cứu có thể sử dụng kiểm định thống kê để đánh giá mức độ phù hợp của nhóm đó với phân bố dữ liệu quan sát được. Đây là một hướng nghiên cứu quan trọng vì nó làm cho quá trình thiết kế mô hình hình học trở nên có căn cứ hơn, đặc biệt trong các miền dữ liệu phức tạp như ảnh y sinh, phân tử, đồ thị xã hội và hệ thống vật lý nhiều hạt.

4.4 Tính đối xứng tham số mạng nơ-ron

Góc nhìn của Geometric Machine Learning không chỉ dừng lại ở dữ liệu đầu vào mà còn được mở rộng vào sâu bên trong không gian tham số của chính mạng nơ-ron. Xét một mạng nơ-ron f_θ với tập tham số θ . Ta nói θ và θ' là tương đương về mặt hàm nếu $f_\theta \equiv f_{\theta'}$, tức hai bộ tham số khác nhau xác định cùng một ánh xạ đầu vào-đầu ra. Tập hợp tất cả các phép biến đổi g trên không gian tham số thỏa mãn $f_\theta = f_{g \cdot \theta}$ tạo thành một nhóm, gọi là nhóm đối xứng tham số của mạng.



4.4.1. Các dạng đối xứng tham số phổ biến

Bản thân cấu trúc trọng số của các mạng học sâu chứa đựng nhiều dạng đối xứng nội tại:

- *Permutation invariance*: Hoán đổi hai nơ-ron ẩn trong cùng một lớp, kèm theo hoán vị tương ứng các hàng của ma trận trọng số lớp trên và các cột của ma trận lớp dưới, không thay đổi hàm tính toán. Với hàm kích hoạt theo điểm, đẳng thức tường minh là:

$$W_2 \sigma(W_1 x) = W_2 P^\top \sigma(P W_1 x) \quad (4.24)$$

với mọi ma trận hoán vị P .

- *Scale invariance*: Với hàm kích hoạt thuần nhất như ReLU thỏa mãn $\sigma(\alpha z) = \alpha \sigma(z)$ với $\alpha > 0$, nhân lớp trước với α và chia lớp sau cho α cho cùng kết quả:

$$W_2 \sigma(W_1 x) = \frac{1}{\alpha} W_2 \sigma(\alpha W_1 x). \quad (4.25)$$

- *GL(r)-invariance trong Attention và LoRA*: Trong các phân rã hạng thấp dạng $UV^\top$, bất kỳ ma trận khả nghịch $R \in GL(r)$ nào cũng cho cùng tích:

$$UV^\top = (UR)(R^{-1}V^\top). \quad (4.26)$$

Tương tự, trong cơ chế attention nhiều đầu, việc hoán vị các đầu attention không thay đổi đầu ra sau phép chiếu kết hợp.

Công trình của Theus và cộng sự^[25] đã hệ thống hóa đầy đủ các đối xứng tham số của Transformer, bao gồm đối xứng của các lớp MLP, hoán vị đầu attention, nhóm trục giao xuất hiện trong RMSNorm, cũng như đối xứng $GL(r)$ trong các tham số LoRA và attention.

4.4.2. Hệ quả thực tiễn

Nhận thức về đối xứng tham số có hệ quả quan trọng cho nhiều tác vụ: so sánh hai mô hình đã huấn luyện đòi hỏi phải căn chỉnh chúng về cùng một orbit trước khi tính khoảng cách; việc hợp nhất nhiều checkpoint không thể thực hiện trực tiếp bằng cách lấy trung bình số học mà phải căn chỉnh orbit trước; và các phương pháp tối ưu hóa nhận thức được đối xứng, chẳng hạn Path-SGD, có thể khai thác cấu trúc này để tăng tốc hội tụ.



4.5 Tổng quan hàm mất mát và gộp mô hình

Đối xứng tham số không chỉ làm xuất hiện nhiều biểu diễn tham số khác nhau cho cùng một hàm dự đoán, mà còn quyết định trực tiếp hình học của *loss landscape*. Giả sử Θ là không gian tham số, $\mathcal{L} : \Theta \rightarrow \mathbb{R}$ là hàm mất mát và G là nhóm đối xứng tác động lên tham số. Nếu tác động của G không làm thay đổi hàm được biểu diễn bởi mạng nơ-ron, thì hàm mất mát thỏa mãn

$$\mathcal{L}(g \cdot \theta) = \mathcal{L}(\theta), \quad \forall g \in G, \forall \theta \in \Theta. \quad (4.27)$$

Từ đó, nếu θ^* là một local minimum của $\mathcal{L}$, thì mọi điểm trên orbit

$$\text{Orb}_G(\theta^*) = \{g \cdot \theta^* \mid g \in G\} \quad (4.28)$$

cũng là local minimum với cùng giá trị hàm mất mát. Nói cách khác, một nghiệm tối ưu không tồn tại đơn lẻ trong không gian tham số, mà thường đi kèm với nhiều nghiệm tương đương do đối xứng sinh ra. Đây là nguyên nhân làm cho *loss landscape* của mạng nơ-ron có cấu trúc suy biến và chứa nhiều nghiệm biểu diễn cùng một hàm.

4.5.1. Mode connectivity và đối xứng liên tục

Trường hợp đầu tiên là các đối xứng liên tục, thường được mô hình hóa bởi Lie groups. Khi G là một nhóm liên tục, orbit của một local minimum dưới tác động của G tạo thành một đa tạp liên tục trong không gian tham số. Với một đường liên tục $g(t) \in G$, $t \in [0, 1]$, ta thu được một đường cong trong không gian tham số:

$$\gamma(t) = g(t) \cdot \theta^*. \quad (4.29)$$

Do tính bất biến của hàm mất mát theo phương trình (4.27), ta có

$$\mathcal{L}(\gamma(t)) = \mathcal{L}(g(t) \cdot \theta^*) = \mathcal{L}(\theta^*), \quad \forall t \in [0, 1]. \quad (4.30)$$

Điều này cung cấp một cơ chế hình học để lý giải hiện tượng *mode connectivity*: các nghiệm có mất mát thấp có thể được nối với nhau bằng những đường cong trong không gian tham số mà trên đó giá trị mất mát vẫn duy trì thấp. Các quan sát thực nghiệm của Garipov và cộng sự^[26] cũng như Draxler và cộng sự^[27] cho thấy nhiều nghiệm độc lập của mạng nơ-ron có thể được nối bằng các đường cong mất mát thấp. Đối xứng liên tục cung

cấp một trong những cơ chế lý thuyết giải thích vì sao hiện tượng này có thể xuất hiện.

4.5.2. Đối xứng rời rạc và các bản sao cực tiểu

Khác với đối xứng liên tục, đối xứng rời rạc thường tạo ra các bản sao cực tiểu tách rời trong không gian tham số. Ví dụ điển hình là đối xứng hoán vị nơ-ron trong các lớp ẩn. Nếu ta hoán vị thứ tự các nơ-ron trong một lớp và đồng thời hoán vị tương ứng các trọng số ở lớp kế tiếp, hàm được biểu diễn bởi mạng không thay đổi, nhưng vector tham số thu được có thể nằm ở một vị trí rất khác trong không gian tham số.

Khi đó, hai mô hình θ_A và θ_B được huấn luyện độc lập có thể biểu diễn các hàm tương tự nhau nhưng nằm trên hai orbit hoán vị khác nhau. Nếu lấy trung bình tuyến tính trực tiếp:


$$\theta_{\text{avg}} = \frac{1}{2}(\theta_A + \theta_B), \quad (4.31)$$

mô hình thu được có thể có mất mát cao, vì đoạn thẳng nối θ_A và θ_B đi qua vùng tham số không tương ứng với một mô hình tốt. Đây là lý do việc trung bình trọng số trực tiếp giữa các mô hình được huấn luyện độc lập thường không ổn định.

Hiện tượng này cũng giải thích vai trò của *linear mode connectivity*. Nếu hai nghiệm đã được căn chỉnh vào cùng một orbit hoặc cùng một basin phù hợp, đoạn thẳng nội suy giữa chúng có thể duy trì mất mát thấp:

$$\theta(t) = (1 - t)\theta_A + t\theta_B, \quad t \in [0, 1]. \quad (4.32)$$

Trong trường hợp chưa căn chỉnh, đường nội suy tuyến tính có thể đi qua vùng mất mát cao; sau căn chỉnh, đường nội suy có thể trở thành một đường nối mất mát thấp.



Hình 4.6: Minh họa ảnh hưởng của đối xứng hoán vị đối với gộp mô hình.

Ghi chú: Khi hai nghiệm chưa được căn chỉnh, đoạn nối giữa chúng có thể đi qua vùng mất mát cao. Sau khi căn chỉnh orbit, nội suy tuyến tính giữa hai nghiệm có thể duy trì mất mát thấp.

4.5.3. Gộp mô hình thông qua căn chỉnh orbit

Từ phân tích trên, yêu cầu cốt lõi của *model merging* là phải căn chỉnh các nghiệm trước khi lấy trung bình. Với đối xứng hoán vị, điều này tương ứng với việc tìm một phép hoán vị P^* sao cho θ_A và $P^* \cdot \theta_B$ nằm trong cùng một basin hoặc có đường nối mất mát thấp. Khi đó, mô hình gộp được xác định bởi

$$\theta_{\text{merged}} = \frac{1}{2} (\theta_A + P^* \cdot \theta_B). \quad (4.33)$$

Phương pháp *Git Re-Basin* của Ainsworth và cộng sự^[28] đi theo hướng này: trước tiên căn chỉnh các nơ-ron giữa hai mạng thông qua đối xứng hoán vị, sau đó mới thực hiện trung bình trọng số. Cách tiếp cận này cho thấy nhiều mô hình tưởng như nằm ở các basin khác nhau thực chất có thể được đưa về cùng một cấu hình tương thích thông qua phép tái căn chỉnh tham số.

Về mặt thực tiễn, điều này giải thích vì sao việc gộp mô hình không thể chỉ được xem như một phép trung bình số học đơn giản. Khi các mô hình có đối xứng tham số, trung bình trọng số chỉ có ý nghĩa sau khi các thành phần tương ứng giữa hai mạng đã được căn chỉnh. Nếu bỏ qua bước này, phép gộp có thể phá vỡ cấu trúc đặc trưng đã học và làm tăng mất mát.



4.5.4. Ứng dụng trong tối ưu hóa và suy luận

Đối xứng tham số và hình học của *loss landscape* có nhiều hệ quả quan trọng ngoài bài toán gộp mô hình. Trong tối ưu hóa, nhận thức rằng nhiều nghiệm khác nhau có thể biểu diễn cùng một hàm giúp thiết kế các thuật toán bất biến với phép tái tham số hóa. Một ví dụ là *Path-SGD*, trong đó bước cập nhật được xây dựng dựa trên chuẩn theo đường đi trong mạng nhằm giảm phụ thuộc vào cách tham số hóa cụ thể của mô hình^[29]. Cách tiếp cận này phù hợp với quan điểm rằng thuật toán tối ưu không nên bị chi phối bởi những thay đổi tham số không làm thay đổi hàm dự đoán.

Trong suy luận Bayesian, đối xứng tham số tạo ra nhiều mode tương đương trong phân bố hậu nghiệm. Nếu không xét đến các mode tương đương này, việc xấp xỉ hậu nghiệm có thể đánh giá sai độ bất định hoặc bỏ sót các vùng xác suất cao. Do đó, hiểu cấu trúc đối xứng của không gian tham số giúp diễn giải tốt hơn bản chất đa mode của hậu nghiệm trong mạng nơ-ron.

Trong *model merging* và *ensembling*, đối xứng tham số cho thấy việc kết hợp nhiều mô hình cần được thực hiện ở cấp độ đã căn chỉnh. Đối với *ensembling*, ta có thể kết hợp dự đoán ở không gian đầu ra mà không cần căn chỉnh tham số. Ngược lại, đối với *model merging*, vì phép kết hợp diễn ra trực tiếp trong không gian tham số, bước căn chỉnh orbit là điều kiện quan trọng để tránh đi qua các vùng có mất mát cao.


Tóm lại, đối xứng tham số cung cấp một lăng kính hình học để hiểu vì sao *loss landscape* của mạng nơ-ron chứa nhiều nghiệm tương đương, vì sao các đường nối mất mát thấp có thể xuất hiện, và vì sao gộp mô hình cần đi kèm với căn chỉnh. Những kết quả này tạo nền tảng cho các hướng nghiên cứu hiện đại về tối ưu hóa bất biến, suy luận Bayesian trong không gian tham số và kết hợp mô hình sau huấn luyện.

4.6 Học trên không gian trọng số

4.6.1. Động lực: kho mô hình như dữ liệu

Học trên không gian trọng số là một hướng nghiên cứu mới trong bối cảnh các Foundation Models và kho mô hình mã nguồn mở phát triển mạnh. Thay vì chỉ xem dữ liệu huấn luyện là ảnh, văn bản, đồ thị hoặc phân tử, hướng nghiên cứu này xem chính bộ tham số của các mạng nơ-ron như một dạng dữ liệu có cấu trúc. Quan điểm này trở nên đặc biệt quan trọng khi số lượng mô hình được công bố công khai ngày càng lớn, đồng thời các biểu diễn ngầm định như implicit neural representations và NeRF cũng mã hóa đối tượng hoặc cảnh vật bằng chính tham số của một mạng nơ-ron.

Câu hỏi trung tâm của hướng nghiên cứu này là liệu có thể xây dựng một mô hình học máy nhận đầu vào là trọng số của một mô hình khác, sau đó phân tích, dự đoán hoặc chỉnh sửa mô hình đó hay không. Nói cách khác, nếu trong học máy truyền thống ta học từ dữ liệu để thu được mô hình, thì trong học trên không gian trọng số, chính các mô hình đã huấn luyện trở thành đối tượng dữ liệu cần được học.



Hình 4.7: Khái quát học trên không gian trọng số.

Ghi chú: Thay vì học trực tiếp từ dữ liệu gốc, một metanetwork nhận tham số của các mạng nơ-ron đã huấn luyện làm đầu vào để thực hiện các tác vụ phân tích hoặc chỉnh sửa.

4.6.2. Các tác vụ trên không gian trọng số

Các tác vụ của học trên không gian trọng số có thể được chia thành ba nhóm chính. Nhóm thứ nhất là dự đoán thuộc tính của mô hình. Thay vì đánh giá một mạng nơ-ron bằng cách chạy inference trên toàn bộ tập kiểm tra, metanetwork có thể dự đoán độ chính xác, khả năng tổng quát hóa hoặc mức độ hội tụ của mô hình trực tiếp từ bộ trọng số. Cách tiếp cận này có tiềm năng giảm đáng kể chi phí đánh giá, đặc biệt khi số lượng mô hình cần so sánh rất lớn.

Nhóm thứ hai là suy diễn thông tin được mã hóa trong tham số. Bộ trọng số của một mạng nơ-ron có thể chứa dấu vết về dữ liệu huấn luyện, quy trình huấn luyện, hoặc các thiên vị mà mô hình đã học. Vì vậy, các mô hình trên không gian trọng số có thể được dùng để kiểm tra bản quyền mô hình, phát hiện nguồn gốc dữ liệu, hoặc ước lượng các dạng thiên vị tiềm ẩn trong mô hình.

Nhóm thứ ba là chỉnh sửa mô hình. Thay vì tinh chỉnh mô hình bằng dữ liệu gốc, một metanetwork có thể dự đoán trực tiếp biến đổi cần áp dụng lên trọng số để thực hiện domain adaptation, pruning, nén mô hình hoặc cập nhật tham số. Đây là một hướng hấp dẫn trong bối cảnh dữ liệu gốc không luôn sẵn có, hoặc chi phí tinh chỉnh đầy đủ quá lớn.



4.6.3. Kiến trúc tương biến cho không gian trọng số

Thách thức cốt lõi của học trên không gian trọng số là không gian tham số của mạng nơ-ron không phải là một không gian Euclid thông thường. Hai bộ trọng số khác nhau có thể biểu diễn cùng một hàm nếu chúng liên hệ với nhau thông qua các đối xứng tham số như hoán vị nơ-ron, tái tỉ lệ trọng số, hoặc các biến đổi liên tục khác. Do đó, nếu chỉ vector hóa toàn bộ trọng số rồi đưa vào một mô hình học máy thông thường, mô hình đó có thể học các đặc trưng phụ thuộc vào cách đánh số nơ-ron hoặc cách tham số hóa, thay vì học các thuộc tính thực sự của hàm được biểu diễn.

Để giải quyết vấn đề này, các kiến trúc metanetwork tương biến được thiết kế sao cho đầu ra biến đổi nhất quán khi trọng số đầu vào chịu tác động của nhóm đối xứng tham số. Nếu θ là bộ tham số của mạng đích và $g \cdot \theta$ là một tham số tương đương dưới tác động của nhóm đối xứng G , một metanetwork Φ cần thỏa mãn quan hệ tương biến:

$$\Phi(g \cdot \theta) = \rho(g)\Phi(\theta), \quad \forall g \in G, \quad (4.34)$$

trong đó $\rho(g)$ là phép biến đổi tương ứng trên không gian đầu ra. Khi đầu ra là một đại lượng vô hướng như độ chính xác dự đoán, điều kiện này trở thành bất biến:

$$\Phi(g \cdot \theta) = \Phi(\theta). \quad (4.35)$$

Một số kiến trúc tiêu biểu đã được đề xuất theo hướng này. Deep Weight Space Networks sử dụng các lớp tuyến tính tương biến được xây dựng từ nhóm đối xứng tham số của mạng đích^[30]. Neural Functional Transformers kết hợp attention với ràng buộc tương biến để xử lý bộ trọng số như một đối tượng có cấu trúc^[31]. Một hướng khác mô hình hóa mạng nơ-ron đích như một đồ thị tham số, trong đó nơ-ron và trọng số được biểu diễn bằng các nút và cạnh, sau đó áp dụng graph neural network lên đồ thị này^[32].

4.6.4. Thách thức về mở rộng và căn chỉnh

Mặc dù học trên không gian trọng số mở ra nhiều ứng dụng mới, hướng này vẫn đối mặt với hai thách thức lớn. Thách thức thứ nhất là khả năng mở rộng. Các mô hình hiện đại có thể chứa hàng triệu đến hàng tỷ tham số, khiến việc đưa toàn bộ trọng số vào một metanetwork trở nên tốn kém về bộ nhớ và tính toán. Do đó, các phương pháp thực tế thường cần biểu diễn nén, chia khối tham số, hoặc chỉ thao tác trên các thành phần thích ứng như LoRA.

Thách thức thứ hai là đối xứng tham số. Trước khi so sánh hoặc kết hợp các bộ trọng



số, cần xét đến khả năng chúng nằm trên các orbit khác nhau nhưng biểu diễn các hàm tương đương. Nếu không căn chỉnh, metanetwork có thể nhầm lẫn giữa khác biệt do đối xứng tham số và khác biệt thực sự về chức năng. Các nghiên cứu trường hợp với LoRA metanetworks cho thấy những phương pháp nhận thức được đối xứng thường ổn định hơn so với các phương pháp bỏ qua cấu trúc đối xứng, đặc biệt khi số lượng mô hình huấn luyện có sẵn còn hạn chế.

4.7 Đối xứng linh hoạt và khám phá đối xứng

4.7.1. Hạn chế của việc mã hóa cứng đối xứng

Các kiến trúc tương biến truyền thống thường giả định rằng nhóm đối xứng của dữ liệu đã được biết trước và được mã hóa trực tiếp vào mô hình trước khi huấn luyện. Cách tiếp cận này hiệu quả trong các miền có cấu trúc hình học rõ ràng, chẳng hạn ảnh với phép tịnh tiến, đồ thị với hoán vị đỉnh, hoặc phân tử với phép quay và tịnh tiến trong không gian ba chiều. Tuy nhiên, trong các hệ thống quy mô lớn được huấn luyện trên dữ liệu đa miền, một nhóm đối xứng cố định thường không đủ để mô tả toàn bộ cấu trúc dữ liệu.

Vấn đề này đặc biệt rõ trong bối cảnh Foundation Models. Một mô hình có thể phải xử lý nhiều loại đầu vào khác nhau, mỗi loại chỉ tôn trọng một phần đối xứng nhất định. Nếu áp đặt một đối xứng quá mạnh, mô hình có thể mất thông tin quan trọng. Nếu áp đặt một đối xứng quá yếu, mô hình không tận dụng được cấu trúc hình học của dữ liệu. Do đó, các hướng nghiên cứu mới tập trung vào đối xứng thích nghi theo ngữ cảnh và tự động khám phá đối xứng từ dữ liệu.

4.7.2. Lựa chọn đối xứng theo ngữ cảnh

Hướng thích nghi giả định rằng đối xứng không phải là một thuộc tính cố định toàn cục, mà có thể thay đổi theo từng ngữ cảnh. Contextual World Models đề xuất cơ chế lựa chọn đối xứng trong ngữ cảnh, trong đó mô hình học cách chọn một nhóm con phù hợp của G tùy theo đầu vào hoặc trạng thái môi trường^[33]. Cách tiếp cận này phù hợp với các bài toán trong đó cùng một hệ thống có thể biểu hiện các đối xứng khác nhau ở các tình huống khác nhau.

Một phát biểu hình thức hơn được đưa ra trong khung any-subgroup equivariant networks^[34]. Mô hình nhận đầu vào chính x và một biến ngữ cảnh v . Biến v xác định

nhóm con các phép biến đổi giữ nguyên ngữ cảnh đó. Nếu một phần tử nhóm g thỏa mãn

$$g \cdot v = v, \quad (4.36)$$


thì mô hình cần tương biến với phép biến đổi đó:

$$f(g \cdot x, v) = g \cdot f(x, v). \quad (4.37)$$

Nhóm con

$$G_v = \{g \in G \mid g \cdot v = v\} \quad (4.38)$$

được gọi là nhóm ổn định của v . Như vậy, cùng một kiến trúc có thể hành xử tương biến với các nhóm con khác nhau tùy thuộc vào ngữ cảnh đầu vào.



Hình 4.8: Minh họa đối xứng phụ thuộc ngữ cảnh. Biến ngữ cảnh xác định nhóm con phù hợp, sau đó mô hình chỉ cần tương biến với nhóm con đó thay vì toàn bộ nhóm ban đầu.

4.7.3. Khám phá đối xứng từ dữ liệu

Một hướng bổ sung là không giả định trước nhóm đối xứng, mà học hoặc suy diễn nhóm đó từ dữ liệu. Khám phá đối xứng có thể được triển khai theo ba cấp độ. Ở cấp độ dữ liệu, mô hình học trực tiếp các phép biến đổi hoặc phép tăng cường dữ liệu làm thay đổi biểu diễn nhưng giữ nguyên thuộc tính cần dự đoán. Cách tiếp cận này giúp thay thế việc thiết kế thủ công các phép biến đổi bằng một quy trình học từ dữ liệu.

Ở cấp độ kiến trúc, mô hình có thể học các mẫu chia sẻ tham số. Nếu một số trọng số cần được ràng buộc giống nhau để đạt hiệu quả tổng quát hóa tốt hơn, cấu trúc chia sẻ đó có thể phản ánh một đối xứng tiềm ẩn của bài toán. Khi đó, đối xứng không được áp đặt trước mà được suy ra từ quá trình tối ưu hóa.

Ở cấp độ hậu nghiệm, ta có thể phân tích các mạng đã được huấn luyện để xác định những đối xứng mà mô hình đã học ngầm định. Việc kiểm tra biểu diễn nội bộ, phản ứng của mô hình trước các phép biến đổi đầu vào, hoặc cấu trúc của không gian đặc trưng



có thể cung cấp bằng chứng về các đối xứng tiềm ẩn. Hướng này có vai trò quan trọng trong việc diễn giải mô hình và kiểm chứng xem mạng nơ-ron có thực sự học được cấu trúc hình học mong muốn hay không.

4.8 Mô hình không phụ thuộc số chiều

Một hạn chế thực tiễn của nhiều mạng tương biến là kiến trúc thường được thiết kế cho một kích thước đầu vào cố định. Ví dụ, một mạng tương biến với nhóm hoán vị S_n được xây dựng cho tập hợp gồm n phần tử thường không thể áp dụng trực tiếp cho tập hợp gồm $m \neq n$ phần tử nếu kiến trúc phụ thuộc tường minh vào n . Hướng nghiên cứu mô hình không phụ thuộc số chiều nhằm xây dựng các mô hình có tham số cố định nhưng vẫn hoạt động trên đầu vào có kích thước thay đổi.

4.8.1. Nền tảng lý thuyết

Cơ sở lý thuyết quan trọng của hướng này là Representation Stability [35]. Lý thuyết này nghiên cứu dãy các biểu diễn của nhóm hoán vị S_n khi n thay đổi và đặc trưng hóa các điều kiện để cấu trúc biểu diễn trở nên ổn định khi n tăng. Trong học máy, ý tưởng này cho thấy một số lớp hàm bất biến với hoán vị có thể được tham số hóa bằng số tham số không phụ thuộc vào kích thước đầu vào.

Chẳng hạn, một hàm tuyến tính bất biến với hoán vị từ $\mathbb{R}^n$ sang $\mathbb{R}$ có dạng

$$f(x) = \alpha \sum_{i=1}^n x_i, \quad (4.39)$$

trong đó chỉ cần một tham số α , thay vì cần n tham số độc lập. Với hàm bậc hai bất biến với hoán vị, các đặc trưng cơ bản có thể được viết theo hai dạng tổng:

$$f(x) = \alpha \sum_{i=1}^n x_i^2 + \beta \sum_{i \neq j} x_i x_j. \quad (4.40)$$

Do đó, hàm bậc hai chỉ cần hai tham số chính, bất kể n lớn đến đâu. Tổng quát hơn, các hàm đa thức bậc k bất biến với hoán vị có thể được mô tả bằng số tham số phụ thuộc vào số phân hoạch của k , ký hiệu $p(k)$:

$$\#\text{parameters} = p(k), \quad p(k) \approx \exp(C\sqrt{k}), \quad (4.41)$$



với một hằng số $C > 0$. Điểm quan trọng là số tham số này phụ thuộc vào bậc k nhưng không phụ thuộc vào kích thước đầu vào n .

4.8.2. Ý nghĩa đối với khả năng ngoại suy kích thước

Kết quả trên cung cấp cơ sở lý thuyết cho việc huấn luyện mô hình trên các đối tượng nhỏ và kiểm tra trên các đối tượng lớn hơn. Trong dữ liệu đồ thị, điều này tương ứng với việc huấn luyện trên các đồ thị có ít đỉnh nhưng kiểm tra trên các đồ thị có nhiều đỉnh. Nếu kiến trúc được thiết kế sao cho tham số không phụ thuộc vào n , mô hình có khả năng duy trì cùng quy tắc xử lý khi kích thước đầu vào thay đổi.

Ý tưởng này đặc biệt quan trọng đối với graph neural networks, nơi số lượng nút và cạnh thay đổi tự nhiên giữa các mẫu dữ liệu. Một mô hình không phụ thuộc số chiều không nên học các quy luật gắn chặt với một kích thước cụ thể, mà cần học các phép toán cục bộ hoặc bất biến có thể mở rộng sang kích thước lớn hơn.

4.8.3. Câu hỏi mở

Mặc dù nền tảng lý thuyết đã cung cấp động lực rõ ràng, hướng mô hình không phụ thuộc số chiều vẫn còn nhiều câu hỏi mở. Trước hết, cần xác định điều kiện đủ để các kiến trúc này đạt tính phổ quát trên nhiều kích thước đầu vào khác nhau. Tiếp theo, cần xây dựng phương pháp đánh giá nhất quán khi tập huấn luyện và tập kiểm tra có kích thước khác nhau đáng kể. Cuối cùng, vẫn cần mở rộng các kết quả từ nhóm hoán vị sang những nhóm đối xứng khác, chẳng hạn nhóm quay, nhóm Euclidean hoặc các nhóm gauge trong dữ liệu hình học phức tạp.


4.9 Hình học vượt đối xứng: Topology và Curvature

Các phương pháp học máy hình học đã trình bày ở các phần trước chủ yếu khai thác đối xứng được mô tả bởi nhóm. Tuy nhiên, dữ liệu hình học trong thực tế còn mang nhiều đặc trưng quan trọng không được nắm bắt đầy đủ bởi đối xứng nhóm. Hai lớp cấu trúc tiêu biểu là topo học và độ cong. Topo học mô tả các quan hệ kết nối và tương tác bậc cao không thay đổi dưới biến dạng liên tục, trong khi độ cong mô tả hình học cục bộ của không gian dữ liệu và ảnh hưởng trực tiếp đến độ khó của bài toán học.

4.9.1. Topological Deep Learning

Topological Deep Learning khai thác cấu trúc topo học của dữ liệu như hình dạng ba chiều, phân tử hoặc mạng sinh học. Thay vì chỉ biểu diễn dữ liệu bằng đồ thị gồm nút và cạnh, hướng này sử dụng các phức đơn hình, phức tế bào và phức tổ hợp. Những cấu trúc này cho phép biểu diễn các tương tác bậc cao hơn, chẳng hạn tam giác, tứ diện hoặc các quan hệ nhiều phần tử mà đồ thị thông thường không mô tả trực tiếp.

Cơ chế truyền thông tin trong các cấu trúc topo học được thực hiện qua Higher-Order Message Passing, tổng quát hóa message passing trên đồ thị sang các tế bào bậc cao. Tuy nhiên, các kết quả gần đây cho thấy Higher-Order Message Passing vẫn chưa đủ để nắm bắt một số đặc trưng topo học toàn cục như đường kính của phức hoặc tính định hướng được. Vì vậy, các kiến trúc multi-cellular networks được đề xuất để kết hợp thông tin từ nhiều loại tế bào khác nhau, qua đó cải thiện khả năng biểu diễn các đặc trưng topo học phức tạp.



Hình 4.9: Minh họa cấu trúc topo học bậc cao.

Ghi chú: Ngoài nút và cạnh như trong đồ thị, phức đơn hình hoặc phức tế bào có thể biểu diễn các tương tác nhiều phần tử thông qua tam giác và các tế bào bậc cao.

4.9.2. Lý thuyết học và độ cong

Từ góc độ lý thuyết học, giả thuyết đa tạp cho rằng dữ liệu thực thường nằm gần một đa tạp có số chiều nội tại thấp hơn nhiều so với không gian quan sát. Giả thuyết này giúp lý giải vì sao học sâu có thể hoạt động hiệu quả trên dữ liệu thực tế mặc dù không gian đầu vào có số chiều rất lớn. Tuy nhiên, số chiều nội tại không phải yếu tố duy nhất quyết định độ khó của bài toán học; hình học của đa tạp, đặc biệt là độ cong, cũng đóng vai trò quan trọng.

Đa tạp có Ricci curvature dương thường có các tính chất compact mạnh hơn, giúp kiểm soát tốt hơn sự phân tán của dữ liệu và hỗ trợ xây dựng các cận độ phức tạp mẫu thuận lợi. Ngược lại, các không gian có độ cong bị chặn nhưng thể tích không bị chặn có



thể tạo ra các bài toán học khó, trong đó không tồn tại bảo đảm hội tụ với số mẫu đa thức trong các thiết lập tổng quát.

Dữ liệu thực tế thường nằm trong một chế độ bất đồng nhất, nơi các vùng có độ cong cao xen kẽ với các vùng tương đối phẳng. Điều này cho thấy một giả định hình học duy nhất hiếm khi đủ để mô tả toàn bộ không gian dữ liệu. Vì vậy, các phương pháp học máy hình học hiện đại cần kết hợp nhiều dạng tiên nghiệm hình học khác nhau, bao gồm đối xứng, topo học và độ cong, thay vì chỉ dựa vào một nhóm biến đổi cố định.



Chương 5

Thực nghiệm và kết quả

5.1 Tổng quan thực nghiệm

Các kết quả thực nghiệm được trình bày trong chương này không tập trung vào việc giải quyết một bài toán đơn lẻ hay cạnh tranh điểm số cao nhất trên một bộ dữ liệu cụ thể. Thay vào đó, chuỗi thực nghiệm được thiết kế trải dài trên nhiều khía cạnh khác nhau của lĩnh vực học máy hình học. Mục tiêu cốt lõi là cung cấp các minh chứng thực tiễn cho những đặc tính lý thuyết đã được xây dựng ở các chương trước, bao gồm hiệu quả sử dụng dữ liệu, khả năng xấp xỉ toán học, cấu trúc của tổng quan tối ưu và tính khả thi của việc học trên không gian trọng số.

5.2 Hiệu quả dữ liệu và định luật tỷ lệ


Thực nghiệm đầu tiên được thiết kế nhằm kiểm chứng giả thuyết cho rằng việc tích hợp tính tương biến vào kiến trúc mô hình sẽ giúp tiết kiệm đáng kể lượng dữ liệu huấn luyện và chi phí tính toán.

Bài toán đặt ra là dự đoán các đặc tính vật lý của hệ thống nguyên tử, cụ thể là năng lượng và lực tương tác. Quá trình đánh giá được thực hiện trên các bộ dữ liệu mô phỏng hệ thống phân tử chuẩn mực như tập dữ liệu phân tử nhỏ QM9, tập dữ liệu động lực học phân tử rMD17 và tập dữ liệu chất xúc tác OC20. Kiến trúc được đưa vào thử nghiệm là mạng nơ-ron tương biến NequIP, một mô hình sử dụng cơ chế truyền thông điệp trên đồ thị trong không gian Euclid. Mô hình cơ sở được dùng để đối chiếu là các mạng nơ-ron tiêu chuẩn không tích hợp tính đối xứng.

Về mặt quy trình, thay vì chỉ đo lường hiệu suất tại một mức dữ liệu cố định, thực nghiệm tiến hành thay đổi linh hoạt lượng tài nguyên tính toán huấn luyện và số lượng mẫu để xây dựng đường cong học tập. Kết quả thu được cho thấy sự chênh lệch rất lớn. Để đạt được cùng một mức độ chính xác như nhau, mô hình NequIP cần lượng dữ liệu huấn luyện ít hơn mô hình cơ sở tới ba bậc độ lớn^[5].

Khi phân tích trên biểu đồ so sánh giữa hàm mất mát và số phép toán dấu phẩy động, tại bất kỳ một mức chi phí tính toán nào, kiến trúc tương biến luôn đạt được mức lỗi thấp hơn đáng kể so với kiến trúc thông thường. Điều này xác nhận sức mạnh của việc

sử dụng tiên nghiệm hình học trong việc cải thiện định luật tỷ lệ^[36].



Hình 5.1: Đường cong định luật tỷ lệ so sánh giữa mô hình cơ sở và mô hình tương biến

Ghi chú: Biểu đồ log-log thể hiện sự tương quan giữa Hàm mất mát (Loss) và Chi phí huấn luyện (Training compute). Mô hình Equivariant (đường nét liền đỏ) hội tụ nhanh và đạt mức lỗi thấp hơn nhiều so với Baseline (đường đứt nét xanh). Nguồn: Brehmer et al., 2025.

5.3 Thực nghiệm về xấp xỉ lấy trung bình nhóm

Phương pháp lấy trung bình nhóm thường vấp phải rào cản lớn về mặt tính toán khi kích thước của nhóm đối xứng quá lớn. Một thực nghiệm mô phỏng đã được thiết kế để kiểm chứng xem lý thuyết lấy mẫu ngẫu nhiên dựa trên đồ thị có thể giải quyết được vấn đề này trong thực tế hay không.

Nhiệm vụ của mạng nơ-ron ba lớp sử dụng hàm kích hoạt ReLU là dự đoán giá trị tuyệt đối, một bài toán đòi hỏi hệ thống phải duy trì tính bất biến lật dấu. Mốc so sánh lý tưởng trong trường hợp này là việc tính toán trung bình qua toàn bộ nhóm đối xứng $\mathcal{G}$, vốn có kích thước lên tới một triệu phần tử.



Quy trình thực nghiệm thay đổi chiến lược tính toán bằng cách không duyệt qua toàn bộ không gian biến đổi. Thay vào đó, hệ thống chỉ lấy mẫu ngẫu nhiên một tập con $\mathcal{S}$ gồm 32 phần tử^[24]. Điểm mấu chốt của giao thức này là tập con 32 phần tử chỉ được lấy mẫu đúng một lần duy nhất trước khi bắt đầu và được sử dụng cố định cho tất cả các vòng lặp huấn luyện.

Kết quả ghi nhận trên tập kiểm tra cho thấy chỉ với 32 phần tử, mức cải thiện của hàm mất mát đã đạt trạng thái bão hòa. Hiệu suất thu được tương đương với việc phải thực hiện phép tính cộng kênh trên toàn bộ một triệu phần tử của mô hình cơ sở. Sự hội tụ này diễn ra ổn định qua từng vòng lặp, minh chứng cho khả năng giảm thiểu độ phức tạp tính toán theo cấp số nhân mà không làm suy giảm chất lượng dự đoán.

5.4 Học không gian trọng số thông qua mạng meta

Thực nghiệm này mở rộng ranh giới của học máy truyền thống bằng cách đánh giá hiệu suất của mô hình ngôn ngữ lớn mà không cần chạy suy luận trực tiếp trên văn bản. Thay vào đó, thực nghiệm tiến hành dự đoán dựa trên ma trận trọng số.

Dữ liệu đầu vào là các bản tinh chỉnh trọng số của mô hình ngôn ngữ lớn. Mạng meta được huấn luyện để dự đoán các chỉ số như thành viên dữ liệu, hàm mất mát kiểm định và độ chính xác suy luận logic. Các mô hình ngây thơ được dùng làm cơ sở xử lý ma trận trọng số như các mảng dữ liệu phẳng một chiều, bỏ qua cấu trúc toán học ẩn bên trong. Ngược lại, kiến trúc đề xuất được thiết kế nhằm nhận thức được các đặc tính bất biến của phép nhân ma trận.

Kết quả thu được phản ánh rõ rệt tầm quan trọng của việc duy trì tính đối xứng. Các mô hình cơ sở xử lý dữ liệu phẳng tỏ ra thiếu ổn định, đưa ra dự đoán kém chính xác và đặc biệt thường xuyên gặp lỗi tràn bộ nhớ (Out of Memory - OOM) khi phải xử lý các bộ trọng số khổng lồ. Trong khi đó, các mạng meta nhận thức được đối xứng hoạt động trơn tru mà không tiêu tốn quá nhiều tài nguyên RAM.

Về mặt định lượng, phương pháp mới mang lại hệ số xác định R^2 cao hơn, cung cấp các dự đoán bám sát hiệu suất thực tế. Đáng chú ý nhất, việc dùng mạng meta để đánh giá chất lượng bộ trọng số cho tốc độ phản hồi nhanh hơn từ năm mươi nghìn đến một trăm nghìn lần so với việc khởi chạy toàn bộ mô hình ngôn ngữ lớn ban đầu^[37].



		Qwen2-ARC-LoRA		Llama3.2-ARC-LoRA
LoL Model		Val Loss (R^2)	ARC-C Acc (R^2)	Val Loss (R^2)
Naive	MLP($[U, V]$)	.113 $\pm$.059	.107 $\pm$.035	.091 $\pm$.030
	Transformer($[U, V]$)	.856 $\pm$.061	.630 $\pm$.045	.828 $\pm$.120
	MLP(UV^T)	.987 $\pm$.003	.981 $\pm$.002	OOM
Invariant	MLP(O-Align($[U, V]$))	.821 $\pm$.078	.965 $\pm$.004	.562 $\pm$.103
	MLP($\sigma(UV^T)$)	.999 $\pm$.000	.983 $\pm$.002	.998 $\pm$.000
	GL-net	.998 $\pm$.000	.987 $\pm$.001	.995 $\pm$.000

Bảng 5.1: Hiệu suất dự đoán của mạng meta trên không gian trọng số LoRA. Các mô hình nhận thức đối xứng (Invariant) hoạt động ổn định, trong khi mô hình Naive dễ gặp lỗi OOM.


5.5 Tổng quan hàm mất mát và kỹ thuật gộp mô hình

Việc gộp các mô hình nơ-ron là một thách thức lớn do đặc thù phức tạp của không gian tham số. Thực nghiệm thứ tư được triển khai để khảo sát hành vi của tổng quan hàm mất mát khi kết hợp hai mô hình được huấn luyện hoàn toàn độc lập từ hai điểm khởi tạo ngẫu nhiên khác nhau.

Nếu áp dụng phương pháp nội suy tiêu chuẩn, tức là lấy trung bình trực tiếp các giá trị trọng số của hai mô hình, biểu đồ hàm mất mát trên tập kiểm tra sẽ xuất hiện một rào cản cực kỳ cao ở vùng giữa đường nội suy. Điều này cho thấy hai mô hình đã rơi vào hai cực tiểu cục bộ tách biệt.

Tuy nhiên, quy trình thực nghiệm đề xuất sử dụng đối xứng hoán vị để xử lý vấn đề này. Trước khi thực hiện nội suy, các nơ-ron ẩn của mô hình thứ hai được nhân với một ma trận hoán vị để căn chỉnh thứ tự sao cho khớp với cấu trúc của mô hình thứ nhất, một phương pháp được gọi là Git Re-Basin^[28]. Kết quả của bước căn chỉnh này làm thay đổi hoàn toàn hình dạng của tổng quan tối ưu. Rào cản ở giữa biến mất, thay vào đó là một đường thẳng có mức lỗi thấp kết nối hai điểm cực tiểu. Sự xuất hiện của kết nối cực tiểu tuyến tính này cho phép gộp các trọng số mô hình một cách mượt mà mà không gây

ra bất kỳ sự suy giảm hiệu suất dự đoán nào.



Hình 5.2: Khắc phục rào cản hàm mất mát thông qua căn chỉnh hoán vị Git Re-Basin

Ghi chú: Căn chỉnh hoán vị giúp tạo ra một đường kết nối tuyến tính có mức lỗi thấp (đường đứt nét màu trắng) giữa hai điểm cực tiểu cục bộ Θ_A và Θ_B . Nguồn: Ainsworth et al., 2023.

5.6 Kiểm định tính đối xứng của dữ liệu và quan sát trên tập QM9


Bên cạnh việc thiết kế các kiến trúc mạng nơ-ron phức tạp, một khía cạnh mang tính quyết định nhưng thường bị bỏ qua là việc xác minh xem bản thân phân phối dữ liệu có thực sự mang các đặc tính hình học như kỳ vọng hay không. Theo nghiên cứu của Soleymani và cộng sự (2025)^[38], quy trình *symmetry testing* đóng vai trò như một bước đánh giá nền tảng trước khi áp dụng bất kỳ mô hình học máy hình học nào.

Về mặt phương pháp luận, bài toán này được công thức hóa thông qua khung kiểm định thống kê với hai giả thuyết rõ ràng. Giả thuyết không H_0 định đề rằng phân phối dữ liệu μ là bất biến dưới tác động của toàn bộ nhóm đối xứng G . Trái ngược với điều đó, giả thuyết đối H_1 cho rằng tồn tại ít nhất một phần tử g thuộc nhóm G làm phá vỡ cấu trúc đối xứng của phân phối này.

Việc giải quyết bài toán kiểm định này đối mặt với một rào cản tính toán lớn. Quá trình quét qua toàn bộ không gian nhóm G để tìm kiếm chính xác phần tử g phá vỡ đối

xúng đã được chứng minh là một bài toán NP-hard. Tuy nhiên, các phân tích toán học trong tutorial đã cung cấp một hướng tiếp cận khả thi. Thay vì phải tính toán trên toàn bộ nhóm, việc lấy mẫu ngẫu nhiên một tập con các phép biến đổi là đủ để ước lượng divergence giữa các phân phối. Phương pháp xấp xỉ này cho phép kiểm định tính đối xứng với sai số tiệm cận chỉ chênh lệch một hằng số bằng 2 so với kết quả tính toán đầy đủ.

Chính nhờ nền tảng phương pháp luận kiểm định thống kê này, các nhà nghiên cứu đã tiến hành đánh giá lại các bộ dữ liệu tiêu chuẩn trong lĩnh vực hóa học tính toán. Một quan sát thực địa đáng chú ý đã được Lawrence và cộng sự (2025) báo cáo khi phân tích tập dữ liệu QM9^[39]. Kết quả đánh giá phân bố không gian cho thấy một tỷ trọng lớn các phân tử trong QM9 thực chất đã ở trạng thái canonicalized. Tọa độ không gian ba chiều của các nguyên tử đã được căn chỉnh theo một hệ quy chiếu chung ngay từ khâu xây dựng bộ dữ liệu.



Hình 5.3: Quan sát thực nghiệm cho thấy các phân tử trong tập QM9 và rMD17 phần lớn đã được chuẩn hóa hệ tọa độ ngầm định

Ghi chú: Việc các phân tử được định hướng gọn gàng trong hệ quy chiếu chung ảnh hưởng trực tiếp đến hiệu quả của các mô hình tương biến. Nguồn: Lawrence et al., 2025.

Phát hiện thống kê này mang lại một góc nhìn phản biện đối với xu hướng phát triển mô hình hiện tại. Khi dữ liệu huấn luyện đã được căn chỉnh định hướng từ trước, mạng nơ-ron sẽ hiếm khi quan sát được các phép biến đổi xoay vô hướng đa dạng. Trong điều kiện môi trường dữ liệu như vậy, việc bắt buộc áp dụng các kiến trúc equivariant với chi



phí huấn luyện đắt đỏ có thể không mang lại sự khác biệt đáng kể về hiệu suất so với các mô hình baseline thông thường. Quan sát này tái khẳng định tầm quan trọng của bước symmetry testing, giúp các nhà nghiên cứu đưa ra quyết định kiến trúc phù hợp và tránh lãng phí tài nguyên tính toán.



Chương 6

Đánh giá và kết luận

Trong các chương trước, đề án đã tìm hiểu về lý thuyết nhóm, các cách ép mô hình học máy tuân theo tính invariance và equivariance, cũng như các chứng minh về độ phức tạp mẫu và kết quả chạy thực nghiệm. Việc thêm tính đối xứng vào mạng nơ-ron đem lại nhiều lợi ích. Tuy nhiên, để đánh giá khách quan, ta cần xem xét kỹ hơn: Liệu có phải lúc nào cũng cần dùng geometric machine learning? Phương pháp này có giới hạn gì, và sắp tới lĩnh vực này sẽ phát triển theo hướng nào? Phần cuối của đề án sẽ phân tích các vấn đề này.

6.1 Thảo luận: Có nên luôn dùng mô hình equivariant?


Thấy được thành công của NequIP^[5] khi giảm được rất nhiều dữ liệu cần thiết để dự đoán năng lượng phân tử, hay các chứng minh toán học giúp giảm độ phức tạp mẫu^[17], ta dễ nghĩ rằng cứ dùng đối xứng là mô hình sẽ tốt. Tuy nhiên, theo đánh giá từ tutorial NeurIPS 2025^[1], thực tế không đơn giản như vậy.

6.1.1. Xét về quy mô dữ liệu và scaling laws

Lý do phổ biến nhất để dùng inductive bias là giúp tiết kiệm dữ liệu. Điều này rất quan trọng trong hóa học lượng tử hay thiết kế thuốc, vì tính toán mô phỏng tốn rất nhiều thời gian và tiền bạc. Khi có ít dữ liệu, việc đưa thẳng quy luật không gian vào mô hình giúp nó hội tụ nhanh hơn là để nó tự học từ đầu.

Tuy nhiên, với các foundation models hiện nay được train trên hàng tỷ dữ liệu, nhiều người cho rằng chỉ cần ném dữ liệu vào mạng transformer thì nó sẽ tự học được các tính đối xứng ngầm mà không cần thiết kế kiến trúc phức tạp từ trước.

Dù vậy, các quan sát thực nghiệm trong^[1] cho thấy: ngay cả khi có nhiều dữ liệu và máy mạnh, nếu xét cùng một mức chi phí huấn luyện, mô hình equivariant vẫn có sai số thấp hơn mô hình thường. Nghĩa là việc dùng tính đối xứng giúp cải thiện trực tiếp định luật tỷ lệ, làm quá trình học hiệu quả hơn ở mọi quy mô.



Hình 6.1: Mô hình equivariant thường có hiệu suất tốt hơn mô hình thông thường ở cùng một mức chi phí huấn luyện. (Vẽ lại dựa trên nhận xét từ^[1])

6.1.2. Loại đối xứng trong dữ liệu

Một vấn đề khác là liệu tính đối xứng có thực sự đúng với mọi dữ liệu hay không. Thực tế có hai trường hợp:

- *Đối xứng chính xác*: Đây là các quy luật vật lý bắt buộc. Ví dụ, năng lượng phân tử không đổi khi ta xoay nó đi. Lúc này, dùng invariance là hoàn toàn chính xác.
- *Đối xứng xấp xỉ*: Nhiều dữ liệu chỉ có đối xứng tương đối. Ví dụ trong xử lý ảnh, con mèo ở góc nào thì vẫn là con mèo, nhưng vị trí của nó có thể mang thông tin về bối cảnh ảnh. Nếu ép mô hình phải invariance cứng nhắc với phép tịnh tiến, ta có thể vô tình làm mất thông tin vị trí hữu ích.

Ngoài ra, theo^[1], một số tập dữ liệu phân tử (benchmark) nổi tiếng đã bị tác giả âm thầm canonicalization sẵn trước khi công bố.

Lỗi khi dùng benchmark đã căn lề sẵn

Nếu dữ liệu phân tử đã bị căn lề, các mẫu không còn xoay ngẫu nhiên nữa. Khi đó, dùng mô hình equivariant (vốn cố tình bỏ qua thông tin góc xoay) lại làm mô hình học kém hơn mạng MLP bình thường, vì ta vô tình vứt bỏ đi thông tin góc xoay đã được cố định sẵn. Do đó, cần kiểm tra kỹ tập dữ liệu trước khi chọn kiến trúc.

6.1.3. Tính đa năng so với chuyên môn hóa

Cuối cùng là việc chọn giữa làm một bài toán cụ thể hay làm một mô hình đa năng. Một mô hình equivariant thiết kế cho nhóm xoay $SO(3)$ dự đoán phân tử rất tốt, nhưng



không dùng được cho bài toán khác không có không gian 3D. Ngược lại, các foundation models dù học chậm ban đầu nhưng lại xử lý được nhiều loại đối xứng khác nhau tùy theo ngữ cảnh dữ liệu. Do đó, việc chọn geometric machine learning phụ thuộc vào mục đích làm công cụ chuyên biệt hay làm mô hình nền tảng.

6.2 Tổng hợp ưu điểm và hạn chế

Từ các phần trên, đề án đúc kết lại các ưu nhược điểm của geometric machine learning:

Về ưu điểm: Lợi ích lớn nhất là học nhanh và cần ít dữ liệu hơn (nhờ inductive bias). Thay vì cần hàng ngàn mẫu ảnh để mô hình biết ảnh xoay ngược vẫn là ảnh d", ta cài đặt sẵn quy luật đó vào mạng. Việc này cũng giúp mô hình dự đoán đúng trên các dữ liệu bị biến đổi góc độ chưa từng gặp lúc train.

Bên cạnh đó, nhờ dùng chung trọng số, số tham số cần học ít đi nên giảm được hiện tượng overfitting. Cuối cùng, như đã chỉ ra ở Chương 3, dùng các kỹ thuật như group averaging không làm mất khả năng học được mọi hàm số của mạng gốc.

Về hạn chế: Khó khăn nhất là việc lập trình và thiết kế đòi hỏi kiến thức toán nặng về group theory và representation theory. Hơn nữa, việc tính toán để duy trì tính đối xứng cho các nhóm lớn (như nhóm hoán vị) làm tốn rất nhiều thời gian chạy máy.

Thêm vào đó, mô hình equivariant rất khó áp dụng cho các bài toán sinh dữ liệu, vì nhiệm vụ này yêu cầu phá vỡ tính đối xứng để tạo ra cấu trúc mới từ đầu vào đối xứng. Cuối cùng, nếu đoán sai nhóm đối xứng hoặc dùng dữ liệu đã bị căn lề sẵn như đã nói ở trên, hiệu suất mô hình sẽ giảm mạnh.

Ưu điểm	Hạn chế
Tiết kiệm dữ liệu và học nhanh hơn vì không phải học lại các phép biến đổi không gian.	Lập trình khó, cần nền tảng toán học sâu để thiết kế và sửa lỗi.
Dự đoán ổn định ngay cả khi dữ liệu đầu vào bị biến đổi.	Chi phí tính toán cao khi áp dụng group averaging trên các nhóm lớn.
Giảm lượng tham số nhờ dùng chung trọng số.	Khó làm các bài toán sinh dữ liệu (vì cần phá vỡ tính đối xứng).
Bảo toàn được khả năng xấp xỉ hàm của mô hình nền.	Hiệu quả giảm mạnh nếu đoán sai tính đối xứng hoặc dùng tập dữ liệu đã căn lề sẵn.

Bảng 6.1: Bảng tóm tắt các điểm mạnh và điểm yếu của geometric machine learning



6.3 Các hướng nghiên cứu tương lai

Lĩnh vực geometric machine learning đang phát triển ra nhiều hướng mới. Dựa trên tutorial NeurIPS 2025^[1], cộng đồng đang tập trung vào một số chủ đề sau.

6.3.1. Cởi mở hơn với tính đối xứng

Thay vì gán một loại đối xứng cố định cho toàn bộ mô hình, các nghiên cứu đang tìm cách làm mô hình linh hoạt hơn. Ví dụ, ý tưởng Contextual World Models^[33] thiết kế mô hình tự nhìn vào ngữ cảnh để chọn phép đối xứng cho phù hợp.

Hướng Any-Subgroup^[34] thì đề xuất cố tình bỏ bớt tính đối xứng của toàn hệ thống để đưa bài toán về một nhóm con nhỏ hơn. Điều này giúp giảm tính toán và bắt được các chi tiết cục bộ tốt hơn. Ngoài ra, nhánh Symmetry Discovery đang nghiên cứu thuật toán để mô hình tự tìm ra tính đối xứng trong dữ liệu mà không cần con người phải tự định nghĩa trước.

6.3.2. Mô hình không phụ thuộc số chiều

Các mạng nơ-ron thường yêu cầu đầu vào có kích thước cố định (ví dụ ảnh phải là 224x224, hoặc đồ thị có đúng N node). Dựa vào lý thuyết Representation Stability^[35], các nhà nghiên cứu đang tạo ra các mô hình có tham số cố định nhưng vẫn nhận được đầu vào có kích thước biến thiên tùy ý.

Việc này giúp ta có thể huấn luyện mạng GNN trên các đồ thị nhỏ để tiết kiệm chi phí, sau đó mang mạng đó đi dự đoán thẳng trên các đồ thị rất lớn mà kết quả vẫn đúng theo bảo đảm của lý thuyết.

6.3.3. Kiểm định tính đối xứng

Thường thì khi code, người ta hay đoán dữ liệu có đối xứng rồi tự thiết kế kiến trúc. Nhánh Symmetry Testing^[38] dùng thống kê để kiểm tra xem phân phối dữ liệu có thực sự bảo toàn tính chất sau phép biến đổi hay không. Xu hướng tới là đưa bài kiểm tra này thẳng vào lúc huấn luyện, để mô hình tự động điều chỉnh mức độ áp dụng đối xứng cho khớp với dữ liệu thực tế.

6.3.4. Học trên không gian trọng số


Với việc có hàng triệu mô hình mã nguồn mở trên mạng (như Hugging Face), xuất hiện một hướng nghiên cứu là lấy mạng nơ-ron (chính xác là trọng số của nó) làm dữ liệu đầu vào. Trọng số của các lớp ẩn có nhiều phép đối xứng^[3], ví dụ đổi chỗ các nơ-ron trong mạng MLP thì kết quả dự đoán cuối cùng không hề thay đổi.

Các mạng như Neural Functional Transformers^[31] hay các kiến trúc equivariant cho trọng số^[30] được tạo ra để cho máy tính đọc hiểu, phân loại và gộp (merge) các mô hình lại với nhau nhanh hơn rất nhiều so với cách thông thường.

6.3.5. Topo học và độ cong

Người ta bắt đầu dùng toán học sâu hơn lý thuyết nhóm. Topological Deep Learning^[40] dùng phức đơn hình để nhìn được cấu trúc vĩ mô của đồ thị (số lỗ thủng, số liên thông) mà mạng GNN bình thường hay bỏ sót.

Ngoài ra, việc dùng độ cong không gian (như Ricci curvature) giúp đánh giá xem bài toán học máy dễ hay khó, từ đó tìm ra cách tối ưu mô hình tốt hơn^[1].



Hình 6.2: Các hướng nghiên cứu mới đang được phát triển trong lĩnh vực. Nguồn: Tổng hợp từ^[1]

6.4 Kết luận

Đề án này bắt đầu bằng thắc mắc: Tại sao mạng CNN dùng cho xử lý ảnh, GNN dùng cho đồ thị hay PointNet dùng cho đám mây điểm lại hiệu quả như vậy? Geometric machine learning trả lời rằng: Các kiến trúc này đã được nhúng sẵn tính đối xứng phù



hợp với dữ liệu. Khi mô hình biết hai ảnh thực ra là một do phép biến đổi góc xoay, nó sẽ không lãng phí tài nguyên để học lại bức ảnh đó.

Dù dùng phương pháp can thiệp trên dữ liệu hay xây dựng kiến trúc từ đầu, cách nào cũng có ưu nhược điểm riêng. Data augmentation thì dễ setup và tận dụng được mô hình có sẵn, trong khi các kiến trúc như group convolution thì khó code hơn nhưng lại đảm bảo đúng về mặt toán học.

Những lợi ích này đã được chứng minh rõ qua lý thuyết độ phức tạp mẫu^[17]. Dùng tính đối xứng thật sự làm giảm độ phức tạp của bài toán, giúp mô hình cần ít dữ liệu hơn rất nhiều. Vấn đề tốn thời gian tính toán khi phải trung bình qua nguyên một nhóm lớn (group averaging) cũng đã được giảm bớt nhờ các lý thuyết như đồ thị giãn nở^[23].

Tất nhiên, geometric ML cũng có nhiều lỗi sai hay gặp. Việc phải tốn thời gian lập trình toán học, khó làm các bài toán sinh dữ liệu, hoặc dễ dùng sai kiến trúc trên tập dữ liệu đã bị căn lề sẵn là những lưu ý quan trọng. Nhưng với các hướng đi mới như học trực tiếp trên trọng số hay kết hợp với topo học, lĩnh vực này chắc chắn sẽ còn phát triển mạnh.

Bài học cốt lõi

Việc thêm tính chất không gian của dữ liệu vào mạng nơ-ron giúp chúng ta hiểu rằng: mô hình học máy tốt không chỉ cần biết học được gì từ dữ liệu, mà còn cần biết những thuộc tính gì của dữ liệu luôn luôn được giữ nguyên, bất kể chúng ta có biến đổi nó như thế nào.



Chương 7

Demo minh họa

7.1 Tổng quan thực nghiệm

Chương này trình bày ba demo tương tác được xây dựng để minh chứng thực nghiệm cho các phân tích lý thuyết ở Chương 3. Mỗi demo đại diện cho một kiểu dữ liệu hình học và một cách tiếp cận khác nhau để đưa đối xứng vào mô hình: ảnh hai chiều chịu tác động của phép xoay, đám mây điểm ba chiều chịu tác động của phép hoán vị thứ tự điểm, và phân tử hóa học ba chiều đòi hỏi tính bất biến theo nhóm Euclidean $E(3)$. Mục tiêu chính không chỉ là báo cáo độ chính xác, mà còn là quan sát cách hành vi của mô hình thay đổi khi ta đưa trực tiếp inductive bias hình học vào dữ liệu hoặc kiến trúc.

	Demo Part 1	Demo Part 2	Demo Part 3
Bài toán	Phân loại chữ số viết tay	Phân loại đám mây điểm 3D	Dự đoán năng lượng phân tử
Dữ liệu	MNIST (28×28 , 10 lớp)	5 lớp trích từ ModelNet40, 1024 điểm/mẫu	Tập con QM9 gồm 1000 phân tử
Nhóm đối xứng	$SO(2)$, phép xoay trong mặt phẳng	S_n , phép hoán vị thứ tự điểm	$E(3)$, nhóm Euclidean trong $\mathbb{R}^3$
Số mô hình	3 mô hình CNN	2 biến thể PointNet	2 cấu hình NequIP ($\ell = 0$ và $\ell = 1$)
Phương pháp	Baseline, Data Augmentation, Frame Averaging	Shared MLP, max pooling, T-Net	Equivariant message passing với irrep
Liên kết lý thuyết	Mục 3.1	Mục 3.4	Mục ??

Bảng 7.2: Tổng quan ba demo thực nghiệm và liên kết với các phân tích lý thuyết trong đề án.

Hệ thống demo được triển khai dưới dạng ứng dụng web gồm hai thành phần chính. *Frontend* sử dụng Next.js, TypeScript, Tailwind CSS và Three.js để cung cấp giao diện



vẽ chữ số, thanh trượt góc xoay, bộ chọn lớp vật thể và trình quan sát point cloud 3D. *Backend* sử dụng FastAPI và PyTorch để phục vụ inference cho cả hai bài toán. Các mô hình được nạp một lần khi server khởi động và được giữ trong bộ nhớ trong suốt phiên chạy.

Cấu trúc thư mục thực tế trong repository được sử dụng như sau:

- `frontend/`: mã nguồn giao diện web.
- `backend/services/model_service.py`: logic inference cho demo MNIST xoay.
- `backend/services/pointnet_service.py`: logic inference cho demo PointNet.
- `backend/services/qm9_service.py`: xây dựng đồ thị phân tử đầu vào cho NequIP.
- `backend/core/nequip_wrapper.py`: tải và chạy checkpoint NequIP.
- `backend/api/part3_routes.py`: endpoint `/api/part3/predict-energy`.
- `backend/core/`: định nghĩa kiến trúc SimpleCNN, FrameAveragingCNN, PointNetBasic và PointNetFull.
- `storage/weights/`: các file trọng số cho Part 1 và Part 2.
- `ai_core/outputs/nequip_l1_1000/best.ckpt`: checkpoint NequIP tốt nhất được triển khai trong demo.
- `ai_core/outputs/`: bốn thư mục kết quả huấn luyện: `baseline_l0_100`, `baseline_l0_1000`, `nequip_l1_100` và `nequip_l1_1000`.
- `ai_core/configs/`: bốn file cấu hình Hydra tương ứng với từng thực nghiệm.
- `ai_core/notebooks/`: script phân tích `03_nequip_learning_curve.py` và các notebook huấn luyện.

Các thí nghiệm được thiết kế để có thể chạy trên CPU. Với quy mô demo hiện tại, việc dùng CPU giúp quá trình cài đặt và trình diễn đơn giản hơn, trong khi vẫn đủ để minh họa tác động của đối xứng lên hành vi mô hình. Các thư viện chính gồm PyTorch, torchvision, NumPy, Matplotlib, FastAPI và các thư viện frontend được khai báo trong `backend/requirements.txt` và `frontend/package.json`.



7.2 Demo thực nghiệm Part 1: Nhận diện chữ số viết tay bất biến với phép xoay

Demo đầu tiên hiện thực hóa bài toán phân loại chữ số viết tay trên giao diện web tương tác. Người dùng vẽ một chữ số trên canvas, điều chỉnh góc xoay, sau đó backend trả về đồng thời kết quả của ba mô hình: Baseline CNN, Augmented CNN và Frame Averaging CNN. Thiết kế này cho phép quan sát trực tiếp khác biệt giữa mô hình không có inductive bias hình học, mô hình học tính bất biến bằng data augmentation và mô hình ép tính bất biến bằng cơ chế frame averaging.

7.2.1. Kiến trúc nền chung

Ba mô hình dùng cùng một backbone CNN đơn giản để việc so sánh tập trung vào cách xử lý đối xứng thay vì sức mạnh kiến trúc:

$$\begin{aligned} \text{Conv}(1 \rightarrow 16, k=5) \rightarrow \text{MaxPool}(2) \rightarrow \text{Conv}(16 \rightarrow 32, k=5) \rightarrow \text{MaxPool}(2) \\ \rightarrow \text{FC}(1568 \rightarrow 128) \rightarrow \text{FC}(128 \rightarrow 10). \end{aligned} \quad (7.1)$$

Ảnh đầu vào được chuẩn hóa theo thống kê MNIST với $\mu = 0.1307$ và $\sigma = 0.3081$. Ở bước inference, backend cắt bounding box của nét vẽ, resize cạnh dài về 20 pixel bằng nội suy Lanczos, rồi căn *center of mass* vào tâm ảnh 28×28 . Quy trình này giúp dữ liệu do người dùng vẽ trên web gần hơn với phân phối MNIST gốc.

7.2.2. Baseline CNN

Mô hình Baseline được huấn luyện trên MNIST gốc, không áp dụng phép xoay trong quá trình load batch. Notebook `train_models.ipynb` huấn luyện mô hình này trong 3 epoch, batch size 64. Loss trung bình in ra trong quá trình huấn luyện giảm từ khoảng 0.315 ở các batch đầu của epoch 1 xuống khoảng 0.034 ở cuối epoch 3. Điều này cho thấy mô hình học tốt phân phối MNIST thẳng đứng, nhưng không đồng nghĩa với việc mô hình đã học được tính bất biến với phép xoay.

Khi ảnh đầu vào bị xoay khỏi phân phối gốc, đặc biệt ở các góc lớn như 90° hoặc 180° , dự đoán của Baseline dễ thay đổi mạnh. Đây là biểu hiện của việc mô hình phụ thuộc vào hướng xuất hiện trong dữ liệu huấn luyện. Nói cách khác, nếu không có inductive bias hình học, CNN thông thường không tự động suy ra rằng một chữ số sau khi xoay vẫn phải được xử lý theo một quy luật nhất quán.



7.2.3. Augmented CNN

Mô hình Augmented giữ nguyên kiến trúc ở phương trình (7.1), nhưng dữ liệu huấn luyện được biến đổi bằng phép xoay ngẫu nhiên:

$$\text{RandomRotation}(180) \rightarrow \text{ToTensor}() \rightarrow \text{Normalize}(0.1307, 0.3081). \quad (7.2)$$

Trong notebook, mô hình Augmented cũng được huấn luyện 3 epoch. Loss giảm từ khoảng 0.960 ở các batch đầu epoch 1 xuống khoảng 0.162 ở cuối epoch 3. So với Baseline, loss ban đầu cao hơn vì bài toán khó hơn: mô hình phải học chữ số trong nhiều tư thế khác nhau. Đổi lại, mô hình có khả năng ổn định hơn khi người dùng xoay ảnh đầu vào.

Tuy nhiên, data augmentation chỉ tạo ra tính bất biến ở mức xấp xỉ. Với một số cặp chữ số có hình dạng gần nhau sau khi xoay, chẳng hạn 6 và 9 ở góc 180°, bản thân nhãn trở nên mơ hồ. Trong trường hợp này, việc bổ sung thêm ảnh xoay không giải quyết triệt để vấn đề, vì cùng một hình dạng quan sát được có thể tương ứng với hai nhãn khác nhau tùy theo quy ước hướng ban đầu.

7.2.4. Frame Averaging CNN

Mô hình Frame Averaging sử dụng cùng backbone CNN, nhưng bọc bên ngoài bằng lớp `FrameAveragingCNN`. Cơ chế này dựa trên ý tưởng đã trình bày ở Mục 3.1.4: thay vì yêu cầu backbone tự học mọi góc xoay, ta xây dựng một tập khung gồm nhiều phiên bản đã căn chỉnh của đầu vào, đưa từng phiên bản qua backbone, sau đó lấy trung bình logits.

Bước đầu tiên là ước lượng hướng chính của nét chữ bằng PCA trên các điểm ảnh có giá trị lớn hơn ngưỡng:

$$\Sigma = \frac{1}{|P| - 1} \sum_{(x,y) \in P} \begin{pmatrix} x - \bar{x} \\ y - \bar{y} \end{pmatrix} \begin{pmatrix} x - \bar{x} \\ y - \bar{y} \end{pmatrix}^T, \quad P = \{(x, y) : I(x, y) > 0.2\}. \quad (7.3)$$

Sau đó, mô hình tạo bốn bản sao xoay lệch nhau 90°:


$$\mathcal{F}(I) = \{\text{Rot}(I, -\theta_{\text{PCA}} + k \cdot 90^\circ) \mid k = 0, 1, 2, 3\}. \quad (7.4)$$



Logits cuối cùng được tính bằng trung bình cộng:

$$\hat{y} = \frac{1}{4} \sum_{k=0}^3 f_{\theta}(\text{Rot}(I, -\theta_{\text{PCA}} + k \cdot 90^\circ)). \quad (7.5)$$

Trong notebook, loss của mô hình Frame Averaging giảm từ khoảng 0.769 ở các batch đầu epoch 1 xuống khoảng 0.076 ở cuối epoch 3. Kết quả này cho thấy mô hình vẫn học ổn định dù phải xử lý nhiều phiên bản xoay của cùng một ảnh. So với Augmented CNN, điểm khác biệt quan trọng là tính bất biến được đưa vào quy trình suy luận bằng phép lấy trung bình trên frame, thay vì chỉ được hy vọng học thông qua dữ liệu xoay.



Hình 7.1: So sánh trực giác giữa ba hướng xử lý phép xoay trong demo MNIST.

Phương pháp	Thay đổi kiến trúc	Cách xử lý xoay	Ghi nhận chính
Baseline CNN	Không	Không xử lý trực tiếp	Tốt trên ảnh thẳng, yếu khi OOD theo góc
Augmented CNN	Không	Học từ ảnh xoay ngẫu nhiên	Ổn định hơn, nhưng chỉ là bất biến xấp xỉ
Frame Averaging CNN	Có wrapper	Trung bình trên 4 frame	Đưa đối xứng vào bước suy luận

Bảng 7.4: Tổng hợp đặc tính của ba mô hình trong demo Part 1.

7.3 Demo thực nghiệm Part 2: Phân loại đám mây điểm ba chiều với PointNet

Demo thứ hai minh họa bài toán phân loại point cloud 3D. Người dùng chọn một trong năm lớp vật thể gồm `airplane`, `car`, `chair`, `lamp` và `table`; sau đó có thể thay đổi

số điểm đầu vào, thêm nhiều Gaussian, xoay point cloud hoặc bỏ ngẫu nhiên một tỉ lệ điểm. Backend chạy đồng thời `PointNetBasic` và `PointNetFull`, sau đó trả về nhãn dự đoán, top-3 xác suất và tập critical points.


7.3.1. Dữ liệu và tiền xử lý

Demo hiện tại sử dụng 5 lớp đại diện từ ModelNet40 thay vì toàn bộ 40 lớp. Đây là lựa chọn phù hợp với mục tiêu minh họa vì năm lớp này có hình dạng tương đối khác nhau, giúp người dùng quan sát rõ cơ chế hoạt động của PointNet mà không cần tải toàn bộ dataset lớn. Các point cloud mẫu được lưu tại `storage/data/sample_clouds/` dưới định dạng `.npy`.

Trong notebook `pointnet_classification.ipynb`, tập huấn luyện gồm 1000 mẫu, tương ứng 200 mẫu cho mỗi lớp; tập validation gồm 250 mẫu, tương ứng 50 mẫu cho mỗi lớp. Mỗi mẫu có 1024 điểm trong không gian ba chiều. Trước khi đưa vào mạng, point cloud được chuẩn hóa về hình cầu đơn vị:

$$\tilde{P}_i = \frac{P_i - \bar{P}}{\max_j \|P_j - \bar{P}\|}, \quad \bar{P} = \frac{1}{n} \sum_{i=1}^n P_i. \quad (7.6)$$

Phép chuẩn hóa này loại bỏ ảnh hưởng của tịnh tiến bằng cách trừ centroid và giảm ảnh hưởng của thang đo bằng cách chia cho khoảng cách cực đại. Do đó, mô hình tập trung hơn vào hình dạng tương đối của vật thể thay vì vị trí hoặc kích thước tuyệt đối.



Hình 7.2: Năm lớp point cloud được sử dụng trong demo Part 2.

7.3.2. Hai biến thể PointNet được so sánh

`PointNetBasic` triển khai ý tưởng cốt lõi của PointNet: áp dụng shared MLP lên từng điểm độc lập, sau đó dùng global max pooling để gom toàn bộ tập điểm thành một vector đặc trưng toàn cục. Công thức tổng quát có thể viết dưới dạng:

$$f(\{x_1, \dots, x_n\}) \approx \gamma\left(\max_{i=1}^n h(x_i)\right), \quad (7.7)$$

trong đó h là shared MLP xử lý từng điểm, $\max$ là phép gộp đối xứng theo trục điểm, và γ là mạng phân loại phía sau. Vì phép $\max$ không phụ thuộc vào thứ tự các điểm, đầu ra của mô hình bất biến với mọi hoán vị của point cloud.

PointNetFull bổ sung hai T-Net. Input T-Net dự đoán ma trận 3×3 để căn chỉnh tọa độ đầu vào, còn Feature T-Net dự đoán ma trận 64×64 để căn chỉnh không gian đặc trưng. Khi huấn luyện, mô hình sử dụng thêm ràng buộc trực giao:


$$\mathcal{L} = \mathcal{L}_{\text{CE}} + \lambda \|I - AA^T\|_F^2, \quad \lambda = 10^{-3}, \quad (7.8)$$

trong đó A là ma trận biến đổi do Feature T-Net dự đoán. Trong thiết lập demo, T-Net được giữ ổn định để tránh hiện tượng học không ổn định trên tập nhỏ.

Notebook ghi nhận số tham số của hai mô hình như sau: **PointNetBasic** có 810,629 tham số, còn **PointNetFull** có 3,471,054 tham số. Phần chênh lệch 2,660,425 tham số chủ yếu đến từ hai mạng T-Net.

7.3.3. Thiết lập huấn luyện và kết quả

Hai mô hình được huấn luyện trong 30 epoch trên tập 5 lớp. **PointNetBasic** đạt validation accuracy tốt nhất 100.0% từ epoch 5 và duy trì ổn định trong các lần đánh giá sau. **PointNetFull** cũng đạt validation accuracy tốt nhất 100.0%, nhưng đường huấn luyện dao động mạnh hơn ở một vài epoch giữa, ví dụ validation accuracy giảm xuống 80.0% tại epoch 15 trước khi phục hồi. Điều này phù hợp với trực giác rằng mô hình lớn hơn không nhất thiết ổn định hơn trên tập dữ liệu nhỏ.



Hình 7.3: Đường cong huấn luyện của hai biến thể PointNet trên tập 5 lớp.



Mô hình	Số tham số	Best validation accuracy	Nhận xét
PointNetBasic	810,629	100.0%	Nhẹ hơn, hội tụ nhanh và ổn định trên tập nhỏ
PointNetFull	3,471,054	100.0%	Nhiều tham số hơn, có T-Net, dao động lớn hơn ở giữa quá trình train

Bảng 7.6: Kết quả huấn luyện hai biến thể PointNet.

Kết quả 100.0% cần được hiểu đúng trong phạm vi demo: tập dữ liệu chỉ gồm 5 lớp có hình dạng khác biệt rõ và được tạo ra nhằm phục vụ minh họa tương tác. Vì vậy, con số này không nên được diễn giải như kết quả đại diện cho toàn bộ ModelNet40. Điểm quan trọng của demo nằm ở việc kiểm chứng tính bất biến hoán vị, cơ chế critical points và khả năng bền vững trước perturbation.

7.3.4. Kiểm tra tính bất biến hoán vị

Một kiểm tra trực tiếp được thực hiện trong notebook là xáo trộn thứ tự điểm đầu vào 10 lần liên tiếp và so sánh logits của `PointNetFull`. Kết quả cho thấy cả 10 lần shuffle đều cho logits giống nhau trong sai số tính toán. Đây là minh chứng thực nghiệm cho bất biến hoán vị: thứ tự lưu trữ point cloud không làm thay đổi dự đoán, vì kiến trúc chỉ dùng shared MLP và max pooling trên tập điểm.


Kiểm tra	Kết quả
Số lần shuffle thứ tự điểm	10
Logits giữ nguyên sau mỗi lần shuffle	True
Kết luận	Mô hình bất biến với hoán vị điểm

Bảng 7.7: Kết quả kiểm tra tính bất biến hoán vị của PointNetFull.

7.3.5. Robustness và critical points


Demo hỗ trợ ba dạng perturbation: thay đổi số điểm đầu vào, thêm nhiễu Gaussian và bỏ ngẫu nhiên một tỉ lệ điểm. Các phép thử này giúp quan sát cơ chế mà PointNet sử dụng để tóm tắt hình dạng. Do global max pooling chỉ giữ lại điểm tạo giá trị cực đại ở

từng chiều đặc trưng, mô hình thường phụ thuộc vào một tập con nhỏ gồm các điểm có vai trò quyết định, gọi là critical point set.



Hình 7.4: Minh họa critical points được trích xuất từ PointNet trên point cloud mẫu.

Khi người dùng giảm số điểm hoặc bỏ ngẫu nhiên một phần point cloud, mô hình vẫn có thể dự đoán đúng nếu các critical points quan trọng còn được giữ lại. Ngược lại, khi tỉ lệ bỏ điểm quá cao hoặc nhiễu Gaussian làm biến dạng mạnh các vùng biên, đặc trưng toàn cục bị thay đổi và dự đoán bắt đầu kém ổn định. Quan sát này phù hợp với phân tích ở Mục 3.4, trong đó PointNet không ghi nhớ toàn bộ bề mặt vật thể mà học một biểu diễn thưa nhưng có khả năng phân biệt.



Hình 7.5: Minh họa xu hướng robustness của PointNet khi point cloud chịu perturbation.

7.4 Demo thực nghiệm Part 3: Dự đoán năng lượng phân tử với NequIP

Demo thứ ba minh họa bài toán dự đoán năng lượng nội năng U_0 của một phân tử có lập bằng mạng nơ-ron đồ thị đẳng biến $E(3)$. Người dùng chọn một trong bảy phân tử



mẫu hoặc tự biên tập tọa độ nguyên tử trong bảng editor, sau đó nhấn nút dự đoán để nhận về giá trị U_0 (eV) cùng thời gian inference. Backend xây dựng đồ thị phân tử, chạy NequIP và trả về kết quả qua REST API.


7.4.1. Bài toán và tính bất biến $E(3)$

Năng lượng nội năng U_0 là đại lượng vô hướng bất biến với mọi phép biến đổi thuộc nhóm $E(3)$: xoay, phản chiếu và tịnh tiến không làm thay đổi giá trị này. NequIP đảm bảo tính bất biến đó không phải bằng cách học từ dữ liệu, mà bằng cách xây dựng các đặc trưng *đẳng biến* theo biểu diễn nhóm tương ứng. Khi tổng gộp toàn cục thu gọn các đặc trưng đẳng biến thành một đại lượng vô hướng, tính bất biến $E(3)$ của đầu ra được đảm bảo tự động từ cấu trúc kiến trúc mà không cần học từ dữ liệu.

7.4.2. Dữ liệu và thiết lập thực nghiệm

Demo huấn luyện trên tập con của QM9, tập dữ liệu hóa học lượng tử gồm khoảng 134.000 phân tử hữu cơ nhỏ với tối đa 9 nguyên tử nặng (C, N, O, F), tạo thành từ năm nguyên tố H, C, N, O, F. Nhân U_0 của mỗi phân tử được tính bằng lý thuyết phiên hàm mật độ (DFT). Để quan sát hiệu quả dữ liệu, đề án tạo hai tập con: 100 phân tử và 1000 phân tử. Các tập được chia theo tỉ lệ 80/10/10 (train/validation/test) và được dùng cho checkpoint triển khai trong demo.

Phân tử mẫu từ QM9 - Biểu diễn đồ thị 3D



Hình 7.6: Bảy phân tử mẫu cài sẵn trong giao diện demo Part 3.

Ghi chú: Bảy cấu trúc gồm H_2O , CH_4 , NH_3 , CO_2 , $\text{C}_2\text{H}_5\text{OH}$, CH_2O và CH_3F . Fluoromethane là trường hợp thử nghiệm đặc biệt: nếu checkpoint không hỗ trợ nguyên tố F, backend trả về lỗi 422 kèm thông báo rõ ràng thay vì crash server.

7.4.3. Kiến trúc NequIP

NequIP biểu diễn mỗi nguyên tử như một nút trong đồ thị; hai nút i và j được nối bằng cạnh khi khoảng cách $\|\vec{r}_{ij}\| < r_{\max} = 5.0\text{\AA}$. Đặc trưng cạnh kết hợp phần hướng kính (8 hàm Bessel với hàm cắt đa thức bậc $p = 6$) và phần góc (hàm điều hòa cầu $Y_\ell^m(\hat{r}_{ij})$ đến bậc $\ell_{\max}$). Quá trình message passing qua 4 tầng tương tác dùng tích Clebsch-Gordan để duy trì tính đẳng biến của các irreducible representation xuyên suốt. Sau 4 tầng, từ thành phần vô hướng ($\ell = 0$) của mỗi nút, mạng đọc ra một năng lượng nguyên tử riêng; tổng các năng lượng nguyên tử này trên toàn đồ thị cho ra U_0 .




Siêu tham số	Ý nghĩa	Giá trị
Nguyên tố được hỗ trợ	Tập nguyên tử mô hình nhận được, trùng với 5 nguyên tố trong QM9	H, C, N, O, F
Bán kính cắt $r_{\max}$	Khoảng cách tối đa để nối cạnh; chỉ các cặp nguyên tử gần hơn ngưỡng này mới tương tác trực tiếp	5,0 Å
Số tầng tương tác	Số lớp message passing; càng nhiều tầng, thông tin lan truyền càng xa trên đồ thị	4
$\ell_{\max}$ (cấu hình đẳng biến)	Bậc irreps cao nhất; $\ell_{\max} = 1$ cho phép dùng đặc trưng vector có hướng, không chỉ vô hướng	1
Parity	Cho phép cả irrep chẵn và lẻ, giúp xử lý đúng phép phản chiếu (phân biệt vector và giả vector)	true (cả irrep chẵn và lẻ)
Số kênh đặc trưng	Độ rộng vector đặc trưng ẩn ở mỗi nút, quyết định dung lượng biểu diễn của mô hình	32
Hàm Bessel / bậc cắt p	8 hàm Bessel mã hóa khoảng cách thành biểu diễn liên tục; envelope đa thức bậc 6 làm đặc trưng cạnh tắt mượt về 0 tại $r_{\max}$	8 / 6
Radial MLP	Mạng sinh trọng số phụ thuộc khoảng cách cho tích tensor, điều khiển cường độ tương tác theo r	2 tầng ẩn, 64 đơn vị
EMA decay	Trung bình động hàm mũ của trọng số, làm mượt và ổn định mô hình ở giai đoạn cuối	0,999
Optimizer / learning rate	Thuật toán tối ưu adaptive với tốc độ học ban đầu	Adam / 5×10^{-3}
LR scheduler	Giảm tốc độ học $\times 0,6$ khi val loss không cải thiện sau 10 epoch	ReduceLROnPlateau (factor 0,6, patience 10)
Max epoch / early stopping	Huấn luyện tối đa 200 epoch, dừng sớm nếu val MAE không cải thiện sau 30 epoch	200 / patience 30

Bảng 7.8: Siêu tham số của mô hình NequIP triển khai trong demo Part 3.

7.4.4. Luồng inference trong demo


Khi người dùng nhấn nút dự đoán, frontend gửi danh sách (`atomic_numbers`, `positions`) đến endpoint `/api/part3/predict-energy`. Backend thực hiện tuần tự: (1) xây dựng đối tượng ASE Atoms không tuần hoàn, (2) áp dụng `ChemicalSpeciesToAtomTypeMapper` để ánh xạ số nguyên tử sang chỉ số loại trong mô hình, (3) xây dựng danh sách lân cận trong bán kính $r_{\max}$ bằng `NeighborListTransform`, (4) chạy forward pass qua NequIP và trả về U_0 (eV). Toàn bộ pipeline chạy trên CPU với thời gian inference dưới 200 ms cho phân tử có ít hơn 10 nguyên tử.



Hình 7.7: Luồng chuyển đổi từ dữ liệu người dùng nhập vào đến đầu ra năng lượng U_0 .

7.4.5. So sánh bất biến và đẳng biến: hiệu quả dữ liệu

Hai cấu hình được so sánh trên hai kích thước tập dữ liệu. *Baseline* ($\ell_{\max} = 0$) chỉ dùng đặc trưng vô hướng, bất biến $E(3)$ theo thiết kế nhưng thiếu thông tin hướng trong các biểu diễn ẩn. *NequIP* ($\ell_{\max} = 1$) bổ sung đặc trưng vector, cho phép mạng học các tương tác có hướng như liên kết cộng hóa trị và hiệu ứng cảm ứng.




Hình 7.8: So sánh đường học của Baseline ($\ell_{\max} = 0$) và NequIP ($\ell_{\max} = 1$) trên hai kích thước tập dữ liệu.

Ghi chú: Trục x là kích thước tập dữ liệu theo thang log; trục y là MAE năng lượng theo thang log.

Nhận xét

- **Đẳng biến luôn tốt hơn:** Đường $\ell_{\max} = 1$ nằm dưới đường $\ell_{\max} = 0$ ở cả $N = 100$ và $N = 1000$, xác nhận lợi thế của việc mã hóa thông tin hướng qua hàm điều hòa cầu bậc 1.
- **Hiệu quả dữ liệu:** Khoảng cách giữa hai đường lớn hơn ở vùng N nhỏ. Khi dữ liệu ít, việc cài sẵn đối xứng vật lý vào kiến trúc giúp mô hình đạt sai số thấp mà không cần nhiều mẫu huấn luyện.
- **Về độ dốc (slope log-log):** Mô hình bất biến dốc hơn ($-1,46$ so với $-1,37$), tức cải thiện theo dữ liệu nhanh hơn một chút; nhưng mô hình đẳng biến luôn xuất phát từ MAE thấp hơn nên vẫn tốt hơn ở mọi quy mô. Lợi thế chính của tính đẳng biến nằm ở mức sai số nền, không phải tốc độ scale.
- **Ý nghĩa thang log-log:** Đường thẳng trên trục log-log ứng với quan hệ lũy thừa $\text{MAE} \propto N^\alpha$, với α là slope; slope càng âm thì MAE giảm càng nhanh khi tăng dữ liệu.



Hình 7.9: Đường cong training loss (a) và validation MAE (b) theo epoch cho bốn thí nghiệm: bất biến ($\ell_{\max} = 0$) và đẳng biến ($\ell_{\max} = 1$) trên hai kích thước tập dữ liệu $N = 100$ và $N = 1000$.

Ghi chú: Early stopping kích hoạt khi validation MAE không cải thiện trong 30 epoch liên tiếp. EMA ($\text{ema_decay} = 0,999$) ổn định quá trình tối ưu hóa ở giai đoạn cuối.



Nhận xét

- **(a) Training loss:** Cả bốn mô hình đều hội tụ. Ở cùng kích thước dữ liệu, loss của $\ell_{\max} = 1$ giảm nhanh hơn $\ell_{\max} = 0$ trong giai đoạn đầu, cho thấy tính đẳng biến giúp tối ưu hàm mất mát hiệu quả hơn.
- **(b) Validation MAE:** Trong khoảng epoch 0–50, mô hình $\ell_{\max} = 1$ giảm MAE nhanh và rõ rệt hơn; sau khi hội tụ, khoảng cách giữa các mô hình thu hẹp lại.
- **Ảnh hưởng kích thước dữ liệu:** Các đường nét đứt ($N = 100$, 10 phân tử validation) dao động mạnh hơn, trong khi nét liền ($N = 1000$, 100 phân tử validation) mượt và ổn định hơn.
- **Cơ chế ổn định:** Mô hình $N = 1000$ cần nhiều epoch hơn để ổn định do tập huấn luyện lớn hơn; early stopping (patience 30) và EMA (0,999) giúp tránh overfitting và làm mượt giai đoạn cuối.

7.5 Thảo luận chung và liên kết lý thuyết

7.5.1. Tính bất biến xấp xỉ và tính bất biến do kiến trúc

Ba demo cho thấy ba cách khác nhau để đưa inductive bias hình học vào mô hình. Trong Part 1, Augmented CNN học tính bất biến từ dữ liệu, nên tính bất biến chỉ là xấp xỉ và có thể thất bại ở các trường hợp nhãn mơ hồ. Frame Averaging CNN đưa cấu trúc frame vào bước suy luận, nhờ đó có cơ chế xử lý xoay rõ ràng hơn. Trong Part 2, tính bất biến với hoán vị không cần học từ dữ liệu: nó xuất hiện trực tiếp từ thiết kế shared MLP và max pooling. Trong Part 3, tính bất biến $E(3)$ của đầu ra được đảm bảo qua lý thuyết biểu diễn nhóm: các đặc trưng ẩn đẳng biến theo irreducible representation, và phép tổng gộp toàn cục tự động kết nạp tính bất biến mà không cần bất kỳ xử lý hậu kỳ nào.

7.5.2. Hiệu quả dữ liệu và giới hạn của demo

Các kết quả trong chương này cần được hiểu như minh họa thực nghiệm cho lý thuyết, không phải benchmark đầy đủ trên quy mô lớn. Part 1 dùng MNIST để làm rõ ảnh hưởng của phép xoay trong môi trường dễ quan sát. Part 2 dùng 5 lớp trích từ ModelNet40 để giao diện demo nhẹ và phản hồi nhanh. Part 3 dùng tập con 1000 phân tử của QM9 để minh họa lợi ích của đẳng biến $E(3)$ trên dữ liệu phân tử thực tế. Giá trị MAE trong



Part 3 phản ánh tập huấn luyện nhỏ và không nên so sánh trực tiếp với các kết quả công bố trên toàn bộ QM9.

Dù vậy, xu hướng chung vẫn nhất quán với lý thuyết ở Chương 3: khi cấu trúc đối xứng được đưa vào mô hình, mô hình cần ít dữ liệu hơn để học cùng một quy luật và có hành vi ổn định hơn trước các biến đổi không làm thay đổi bản chất đối tượng.

7.5.3. Đối chiếu hai hướng tiếp cận

Tiêu chí	Part 1: MNIST xoay	Part 2: PointNet	Part 3: NequIP
Đối tượng dữ liệu	Ảnh 28×28 trên lưới 2D	Tập điểm không có thứ tự trong không gian 3D	Phân tử hóa học với tọa độ nguyên tử 3D
Nhóm đối xứng	$SO(2)$, phép xoay liên tục	S_n , phép hoán vị hữu hạn	$E(3)$, nhóm Euclidean trong $\mathbb{R}^3$
Cách đưa đối xứng vào mô hình	Data augmentation hoặc frame averaging	Shared MLP và max pooling	Equivariant message passing với irrep
Loại bất biến	Xấp xỉ với augmentation, rõ ràng hơn với frame averaging	Bất biến hoán vị ngay từ kiến trúc	Bất biến $E(3)$ được đảm bảo bằng biểu diễn nhóm
Giới hạn chính	Ambiguity nhân khi xoay một số chữ số	Demo chỉ dùng 5 lớp, chưa đại diện toàn bộ ModelNet40	Tập huấn luyện nhỏ (1000 phân tử), chưa tính lực

Bảng 7.10: Đối chiếu ba demo thực nghiệm qua lăng kính ba hướng tiếp cận geometric machine learning.

Từ ba demo, có thể rút ra kết luận rằng inductive bias hình học không chỉ giúp tăng độ chính xác trong một số thiết lập, mà quan trọng hơn là làm cho hành vi của mô hình nhất quán hơn với cấu trúc của dữ liệu. Với ảnh xoay, mô hình cần hiểu quan hệ giữa các góc. Với point cloud, mô hình cần bỏ qua thứ tự lưu trữ điểm. Với phân tử hóa học, mô hình cần đảm bảo rằng xoay hay phản chiếu toàn bộ phân tử không thay đổi năng lượng



dự đoán. Ba yêu cầu này tương ứng với ba cơ chế khác nhau để tích hợp đối xứng vào học máy, và đây chính là vai trò trung tâm của geometric machine learning: thiết kế mô hình không chỉ dựa trên dữ liệu đầu vào, mà còn dựa trên những phép biến đổi mà bài toán cho phép hoặc cần bất biến theo.



Phụ lục: Phân công công việc nhóm

STT	Họ và tên	MSSV	Nhiệm vụ chính
1	Lê Hà Thanh Chương	23120195	• Quản lý dự án & Tổng hợp: Quản lý tiến độ tổng thể, thiết lập môi trường latex; chuẩn hóa định dạng, mục lục, danh mục thuật ngữ và ráp nối toàn bộ báo cáo. • Nghiên cứu & Báo cáo: Phụ trách Chương 1 (Giới thiệu, bối cảnh và động lực) và Chương 5 (Thực nghiệm chi tiết, đặc biệt nghiên cứu sâu kiến trúc NequIP). • Thực nghiệm & Ứng dụng: Trực tiếp xây dựng hệ thống Demo Web toàn bộ Part 3 (NequIP, QM9) để trực quan hóa năng lực dự đoán cấu trúc phân tử.
2	Trà Văn Sỹ	23120197	• Nghiên cứu & Báo cáo: Phụ trách Mục 3.1 và 3.2 của Chương 3 (Các phương pháp xây dựng mô hình bảo toàn đối xứng cơ bản) và Chương 6 (Đánh giá tổng thể & Kết luận). • Thực nghiệm & Kỹ thuật: Khởi tạo và thiết lập nền tảng Web Frontend ban đầu cho dự án. Xây dựng mã nguồn Demo Part 1 (MNIST xoay, CNN Tương biến) và soạn thảo Jupyter Notebook minh họa.
3	Huỳnh Đức Thịnh	23120199	• Nghiên cứu & Báo cáo: Phụ trách các phần còn lại của Chương 3 (tập trung phân tích chuyên sâu kiến trúc mạng PointNet và các cơ chế trích xuất đặc trưng bất biến/đẳng biến trên dữ liệu đám mây điểm (Point Clouds)). • Thực nghiệm & Ứng dụng: Triển khai và xây dựng mã nguồn lõi cho Demo Part 2 (Huấn luyện PointNet trên đám mây điểm ModelNet40).



STT	Họ và tên	MSSV	Nhiệm vụ chính (tiếp theo)
4	Bùi Trung Hiếu	23120257	• Nghiên cứu & Báo cáo: Phụ trách toàn bộ Chương 2 (Kiến thức nền tảng: Lý thuyết nhóm, tác động nhóm, quỹ đạo, biểu diễn toán học của bất biến và đẳng biến) cùng các sơ đồ TikZ minh họa. • Thực nghiệm & Kỹ thuật: Hỗ trợ Thanh Chương phân tích mã nguồn và soạn thảo Jupyter Notebook minh họa chi tiết cho thực nghiệm Part 3 (Mạng NequIP). • Thiết kế Slide & Trực quan hóa: Phối hợp cùng Công Phúc tổng hợp toàn bộ nội dung đồ án để thiết kế bộ slide thuyết trình, trực quan hóa các khái niệm hình học phức tạp.
5	Lê Công Phúc	23120330	• Nghiên cứu & Báo cáo: Phụ trách toàn bộ Chương 4 (Lý thuyết nâng cao: Độ phức tạp mẫu, học không gian trọng số, đối xứng tham số và kiểm định đối xứng). • Thực nghiệm & Kỹ thuật: Chịu trách nhiệm viết Jupyter Notebook phân tích thực nghiệm, trực quan hóa và đánh giá kết quả cho phần Demo Part 2 (Point-Net, ModelNet40). • Thiết kế Slide & Trực quan hóa: Đồng trách nhiệm cùng Trung Hiếu chọn lọc các điểm nhấn từ báo cáo, dàn trang slide đảm bảo tính thẩm mỹ, súc tích.



Bảng 7.12: Bảng tự đánh giá mức độ đóng góp

MSSV	Họ và tên	Tự đánh giá (%)	Ghi chú
23120195	Lê Hà Thanh Chương	20%	
23120197	Trà Văn Sỹ	20%	
23120199	Huỳnh Đức Thịnh	20%	
23120257	Bùi Trung Hiếu	20%	
23120330	Lê Công Phúc	20%	
Tổng		100%	



Tài liệu tham khảo

- [1] S. Jegelka and B. Tahmasebi, “Recent developments in geometric machine learning: Foundations, models, and more,” Tutorial at NeurIPS 2025, San Diego, CA, 2025.
- [2] M. M. Bronstein, J. Bruna, T. Cohen, and P. Veličković, “Geometric deep learning: Grids, groups, graphs, geodesics, and gauges,” arXiv preprint arXiv:2104.13478, 2021.
- [3] B. Zhao, R. Walters, and R. Yu, “Symmetry in neural network parameter spaces,” *Transactions on Machine Learning Research*, 2026.
- [4] T. Cohen and M. Welling, “Group equivariant convolutional networks,” in *Proceedings of the International Conference on Machine Learning (ICML)*, 2016, pp. 2990–2999.
- [5] S. Batzner, A. Musaelian, L. Sun, M. Geiger, J. P. Mailoa, M. Kornbluth, N. Molinari, T. E. Smidt, and B. Kozinsky, “E(3)-equivariant graph neural networks for data-efficient and accurate interatomic potentials,” *Nature Communications*, vol. 13, no. 1, p. 2453, 2022.
- [6] A. Soleymani, B. Tahmasebi, S. Jegelka, and P. Jaillet, “Learning with exact invariances in polynomial time,” *arXiv preprint arXiv:2502.19758*, 2025.
- [7] S.-O. Kaba, A. K. Mondal, Y. Zhang, Y. Bengio, and S. Ravanbakhsh, “Equivariance with learned canonicalization functions,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [8] N. Dym, H. Lawrence, and J. W. Siegel, “Equivariant frames and the impossibility of continuous canonicalization,” in *International Conference on Machine Learning (ICML)*, 2024.
- [9] R. L. Murphy, B. Srinivasan, V. Rao, and B. Ribeiro, “Janossy pooling: Learning deep permutation-invariant functions for variable-size inputs,” in *International Conference on Learning Representations (ICLR)*, 2019.
- [10] M. Zaheer, S. Kottur, S. Ravanbakhsh, B. Póczos, R. R. Salakhutdinov, and A. J. Smola, “Deep sets,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.



- [11] O. Puny, M. Atzmon, E. J. Smith, I. Misra, A. Grover, H. Ben-Hamu, and Y. Lipman, “Frame averaging for invariant and equivariant network design,” in *International Conference on Learning Representations (ICLR)*, 2022.
- [12] D. Wang, R. Walters, and R. Platt, “Equivariant Q learning in spatial action spaces,” in *5th Annual Conference on Robot Learning (CoRL)*, 2021. [Online]. Available: <https://openreview.net/forum?id=IScz42A3iCI>
- [13] D. Wang, R. Walters, X. Zhu, and R. Platt, “SO(2)-equivariant reinforcement learning,” in *International Conference on Learning Representations (ICLR)*, 2022. [Online]. Available: https://openreview.net/forum?id=7F9cOhdvfk_
- [14] D. Wang, M. Jia, X. Zhu, R. Walters, and R. Platt, “On-robot learning with equivariant models,” in *6th Annual Conference on Robot Learning (CoRL)*, 2022. [Online]. Available: <https://openreview.net/forum?id=K8W6ObPZQyh>
- [15] X. Zhu, D. Wang, G. Su, O. Biza, R. Walters, and R. Platt, “On robot grasp learning using equivariant models,” in *Autonomous Robots*, vol. 47, 2023, pp. 1175–1193.
- [16] B. Hu, X. Zhu, D. Wang, Z. Dong, H. Huang, C. Wang, R. Walters, and R. Platt, “OrbitGrasp: SE(3)-equivariant grasp learning,” in *8th Annual Conference on Robot Learning (CoRL)*, 2024. [Online]. Available: <https://openreview.net/forum?id=LHrPTXb4Dy>
- [17] B. Tahmasebi and S. Jegelka, “The exact sample complexity gain from invariances for kernel regression,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [18] A. Bietti, L. Venturi, and J. Bruna, “On the sample complexity of learning under geometric stability,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- [19] S. Jegelka and B. Tahmasebi, “Sample complexity bounds for estimating probability divergences under invariances,” in *Proceedings of the 41st International Conference on Machine Learning (ICML)*, 2024.
- [20] Z. Chen, M. A. Katsoulakis, L. Rey-Bellet, and W. Zhu, “Sample complexity of probability divergences under group symmetry,” in *Proceedings of the 40th International Conference on Machine Learning (ICML)*, 2023.



- [21] B. Elesedy, “Provably strict generalisation benefit for invariance in kernel methods,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.
- [22] S. Mei, T. Misiakiewicz, and A. Montanari, “Learning with invariances in random features and kernel models,” in *Proceedings of the 34th Conference on Learning Theory (COLT)*, ser. Proceedings of Machine Learning Research, vol. 134, 2021.
- [23] A. Soleymani, B. Tahmasebi, S. Jegelka, and P. Jaillet, “Learning with exact invariances in polynomial time,” in *Proceedings of the 42nd International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research. PMLR, 2025, iCML 2025.
- [24] B. Tahmasebi, M. Weber, and S. Jegelka, “Data augmentation: A fourier analysis perspective,” NeurIPS 2025 Workshop on Symmetry and Geometry in Neural Representations, 2025.
- [25] A. Theus, A. Cabodi, S. Anagnostidis, A. Orvieto, S. P. Singh, and V. Boeva, “Generalized linear mode connectivity for transformers,” in *Advances in Neural Information Processing Systems*, 2025, neurIPS 2025 oral. [Online]. Available: <https://arxiv.org/abs/2506.22712>
- [26] T. Garipov, P. Izmailov, D. Podoprikin, D. P. Vetrov, and A. G. Wilson, “Loss surfaces, mode connectivity, and fast ensembling of dnns,” in *Advances in Neural Information Processing Systems*, vol. 31, 2018.
- [27] F. Draxler, K. Veschgini, M. Salmhofer, and F. A. Hamprecht, “Essentially no barriers in neural network energy landscape,” in *Proceedings of the 35th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 80. PMLR, 2018, pp. 1309–1318.
- [28] S. K. Ainsworth, J. Hayase, and S. Srinivasa, “Git re-basin: Merging models modulo permutation symmetries,” in *International Conference on Learning Representations*, 2023.
- [29] B. Neyshabur, R. Salakhutdinov, and N. Srebro, “Path-sgd: Path-normalized optimization in deep neural networks,” in *Advances in Neural Information Processing Systems*, vol. 28, 2015, pp. 2422–2430.
- [30] A. Navon, A. Shamsian, I. Achituve, E. Fetaya, G. Chechik, and H. Maron, “Equivariant architectures for learning in deep weight spaces,” in *Proceedings of the 40th*



- International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 202. PMLR, 2023, pp. 25 790–25 816.
- [31] A. Zhou, K. Yang, Y. Jiang, K. Burns, W. Xu, S. Sokota, J. Z. Kolter, and C. Finn, “Neural functional transformers,” in *Advances in Neural Information Processing Systems*, vol. 36, 2023, pp. 77 485–77 502.
- [32] D. Lim, H. Maron, M. T. Law, J. Lorraine, and J. Lucas, “Graph metanetworks for processing diverse neural architectures,” in *International Conference on Learning Representations*, 2024.
- [33] S. Gupta, C. Wang, Y. Wang, T. Jaakkola, and S. Jegelka, “In-context symmetries: Self-supervised learning through contextual world models,” in *Advances in Neural Information Processing Systems*, vol. 37, 2024.
- [34] A. Goel, D. Lim, H. Lawrence, S. Jegelka, and N. Huang, “Any-subgroup equivariant networks via symmetry breaking,” NeurIPS 2025 Workshop on Symmetry and Geometry in Neural Representations, 2025.
- [35] B. Farb, “Representation stability,” *arXiv preprint arXiv:1404.4065*, 2014.
- [36] J. Brehmer *et al.*, “Scaling laws for equivariant neural networks,” Preprint / NeurIPS Workshop, 2025.
- [37] Putterman *et al.*, “Evaluating model performance via lora metanetworks,” Preprint / NeurIPS Workshop, 2025.
- [38] A. Soleymani, B. Tahmasebi, S. Jegelka, and P. Jaillet, “A robust kernel statistical test of invariance: Detecting subtle asymmetries,” in *Proceedings of The 28th International Conference on Artificial Intelligence and Statistics*, ser. Proceedings of Machine Learning Research, vol. 258. PMLR, 2025, pp. 4816–4824.
- [39] H. Lawrence *et al.*, “Implicit canonicalization in molecular datasets,” Preprint, 2025.
- [40] Y. Eitan, M. T. Schaub, and C. Bodnar, “Topological blindspots: Understanding and extending topological deep learning through the lens of expressivity,” *arXiv preprint arXiv:2408.05486*, 2024.
- [41] M. Shakerinava and S. Ravanbakhsh, “Equivariant contrastive learning,” in *International Conference on Learning Representations (ICLR)*, 2022.



- [42] A. Gupta, L. Fan, S. Ganguli, and L. Fei-Fei, “Structuring representation geometry with rotationally equivariant contrastive learning,” in *International Conference on Machine Learning (ICML)*, 2023.
- [43] Y. Zhang, S. Reddy, D. Zhao, and X. Wang, “Deep geometric representations for equivariant networks,” *arXiv preprint arXiv:2002.00809*, 2020.
- [44] V. G. Satorras, E. Hoogeboom, and M. Welling, “E(n) equivariant graph neural networks,” in *Proceedings of the International Conference on Machine Learning (ICML)*, 2021, pp. 9323–9332.
- [45] R. Wang, E. Hofgard, H. Gao, R. Walters, and T. E. Smidt, “Discovering symmetry breaking in physical systems with relaxed group convolution,” in *Proceedings of the International Conference on Machine Learning (ICML)*, 2024.
- [46] M. Hajij, G. Zamzmi, T. Papamarkou, N. Miolane, A. Guzmán-Sáenz, K. N. Ramamurthy, T. Birdal, T. K. Dey, S. Mukherjee, S. N. Samaga, N. Livesay, R. Walters, P. Rosen, and M. T. Schaub, “Topological deep learning: Going beyond graph data,” *arXiv preprint arXiv:2206.00606*, 2022.